FACULTAD DE CIENCIAS
ECONÓMICAS Y EMPRESARIALES

Ingeniería Informática + ADE

Universidad de Granada (UGR)

Autor: Ismael Sallami Moreno

Asignatura: Formulario y Resumen Econometría

Índice

1. Tema 2 **4**
1.1. Modelo Lineal Simple . . . 4
1.2. Modelo Lineal Múltiple . . . 4
1.3. Notación MLP . . . 4
1.4. Supuestos . . . 4
1.4.1. Linealidad . . . 4
1.4.2. Rango Completo Por Columnas . . . 5
1.4.3. Exogeneidad . . . 5
1.4.4. Causalidad . . . 5
1.4.5. Perturbación . . . 5
1.4.6. Normalidad de la perturbación . . . 5
1.5. Estimación Míminos Cuadrados Ordinarios (MCO) . . . 6
1.5.1. Pasos a seguir . . . 6
1.6. Propiedades Algebraicas de los MCO . . . 7
1.7. Bondad del Ajuste . . . 7
1.8. Bondad del Ajuste Corregido . . . 7
1.9. Criterio de Akaike . . . 8
1.10. Criterio de Schwarz . . . 8

2. Tema 3 **8**
2.1. Valor Esperado y Varianza de los EMCO (Estimadores mínimos cuadrados ordinarios) . . . 8
2.1.1. Valor Esperado de los EMCO . . . 8
2.1.2. Varianza de los EMCO . . . 8
2.2. Teorema de Gauss-Markov . . . 9
2.2.1. Demos . . . 9
2.3. Estimación de σ_u^2 . . . 11
2.4. Estimación de la varianza de los EMCO . . . 12
2.5. Supuesto de Normalidad e Inferencia . . . 12
2.6. Supuesto de Normalidad e Inferencia . . . 13
2.7. Intervalos de Confianza . . . 14
2.7.1. IC para β_i . . . 14
2.7.2. IC para σ^2 . . . 14
2.8. Contraste de hipótesis . . . 14
2.8.1. Estadístico de contraste . . . 14
2.8.2. Casos particulares . . . 15
2.9. Cota R^2 . . . 16
2.10. Predicción puntual . . . 16
2.10.1. Para el valor individual . . . 16
2.10.2. Para el valor esperado . . . 17
2.10.3. Por intervalo . . . 17
2.11. Construcción de las distribuciones . . . 17
2.11.1. Distribución χ^2 de Pearson . . . 17

2.11.2. Distribución t de Student 17
2.11.3. Distribución F de Fisher-Snedecor 18

1 Tema 2

1.1. Modelo Lineal Simple

$$Y_i \sim a + bx_i \tag{1}$$

1.2. Modelo Lineal Múltiple

$$Y_i = \beta_1 + \beta_2 x_{i2} + \beta_3 x_{i3} + \ldots + \beta_k x_{ik} + u_i \tag{2}$$

- El subíndice i indica la observación.
- El subíndice k indica el número de variables explicativas.
- El subíndice u indica el término de error.
- Nota: β_1 es la constante, lleva asociado el valor $1 = x_{i1}$ (por eso no se pone).

1.3. Notación MLP

$$\vec{y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} \tag{3}$$

$$X = \begin{pmatrix} 1 & X_{21} & \cdots & X_{k1} \\ 1 & X_{22} & \cdots & X_{k2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{2n} & \cdots & X_{kn} \end{pmatrix} \tag{4}$$

$$\vec{\beta} = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix} \tag{5}$$

$$\vec{u} = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix} \tag{6}$$

1.4. Supuestos

1.4.1. Linealidad

$$Y_i = \beta_1 + \beta_2 x_{i2} + \beta_3 x_{i3} + \ldots + \beta_k x_{ik} + u_i \tag{7}$$

1.4.2. Rango Completo Por Columnas

$$rango(X) = k \tag{8}$$

1.4.3. Exogeneidad

$$E(u_i|X_i) = 0 \tag{9}$$

- El valor esperado de la esperanza que toman las variables explicativas es 0.

Por lo que si tenemos que: $Y_i = \vec{X}_i^t\vec{\beta}$, tenemos de forma inmediata que:

$$E(Y_i|X_i) = \vec{X}_i^t\vec{\beta} \tag{10}$$

1.4.4. Causalidad

- Relación de causalidad es unidireccional.
- Las variables aparecen en el lado derecho de la ecuación, pero no al contrario.
- La variable dependiente Y_i adoptará un carácter aleatorio.

1.4.5. Perturbación

- Esta centrada, es decir, $E(u_i) = 0 \forall i = 1, 2, \ldots, n$
- Es homocedástica, es decir, $Var(u_i) = E[u_i^2] = \sigma^2 \forall i = 1, 2, \ldots, n$
- Si es incorrelada implica que $cov[u_i u_j] = E[u_i u_j] = 0$. Cuando es neq 0 decimos que hay un problema de autocorrelación.

Como consecuencia tenemos que:

$$var[\vec{u}] = E[(\vec{u} - E[\vec{u}])(\vec{u} - E[\vec{u}])^t] = E[\vec{u}\vec{u}^t] \tag{11}$$

Para la demostración de esta operación pincha aquí para verla.

1.4.6. Normalidad de la perturbación

Se considera que la perturbación aleatoria u_i se distribuye normalmente con media 0 y varianza σ^2, es decir, $u_i \sim N(0, \sigma^2) \forall i = 1, \ldots, n$.

En este caso supondremos que $\vec{u}$ se distribuye normalmente, es decir, $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$[1].

[1] distribución normal multivariante con vector de medias nulo y matriz de varianzas-covarianzas $\sigma^2 I_n$

1.5. Estimación Míminos Cuadrados Ordinarios (MCO)

Para estimar los parámetros β utilizaremos el MCO, denotando a $\hat{\vec{y}}$ el valor ajustado de $\vec{y}$, es decir, $\hat{\vec{y}} = X\hat{\vec{\beta}}$.

En este caso el valor de los residuos se obtiene como:

$$\vec{e} = \vec{y} - \hat{\vec{y}} = \vec{y} - X\hat{\vec{\beta}} \tag{12}$$

Debemos de minimizar la suma de los cuadrados de los residuos:

$$\min_{\vec{\beta}} \sum_{i=1}^{n} e_i^2 \tag{13}$$

Tendremos como función a minimizar: $f(\hat{\vec{\beta}}) = \vec{e}\,^t\vec{e}$

1.5.1. Pasos a seguir

1. Definimos la expresión a minimizar. Se debe de definir la suma de los cuadrados de los residuos:
$$f(\hat{\vec{\beta}}) = (\vec{y} - X\hat{\vec{\beta}})^t(\vec{y} - X\hat{\vec{\beta}}) \tag{14}$$

2. Derivamos con respecto a $\hat{\vec{\beta}}$ e igualamos a 0:
$$\frac{\partial f(\hat{\vec{\beta}})}{\partial \hat{\vec{\beta}}} = 0 \tag{15}$$

3. Despejamos el vector de parámetros, debemos de considerar el supuesto del rango completo por columnas, verificándose que $\rho(X^tX) = 1$, condición necesaria para que exista $(X^tX)^{-1}$

4. Para que la solución sea mínimo se ha de cumplir:
$$\text{Hess}(f) = 2X^tX > 0 \text{ and } (A > 0 \text{ si } z^tAz > 0\ \forall z \neq 0) \tag{16}$$

Si el modelo tiene término independiente entonces se tiene

$$\vec{\beta} = \begin{pmatrix} n & \sum_{i=1}^n X_{2i} & \cdots & \sum_{i=1}^n X_{ki} \\ \sum_{i=1}^n X_{2i} & \sum_{i=1}^n X_{2i}^2 & \cdots & \sum_{i=1}^n X_{2i}X_{ki} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n X_{ki} & \sum_{i=1}^n X_{ki}X_{2i} & \cdots & \sum_{i=1}^n X_{ki}^2 \end{pmatrix}^{-1} \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n X_{2i}Y_i \\ \vdots \\ \sum_{i=1}^n X_{ki}Y_i \end{pmatrix}$$

En el caso de que el modelo carezca del término independiente entonces:

$$\vec{\beta} = \begin{pmatrix} \sum_{i=1}^n X_{1i}^2 & \sum_{i=1}^n X_{1i}X_{2i} & \cdots & \sum_{i=1}^n X_{1i}X_{ki} \\ \sum_{i=1}^n X_{2i}X_{1i} & \sum_{i=1}^n X_{2i}^2 & \cdots & \sum_{i=1}^n X_{2i}X_{ki} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n X_{ki}X_{1i} & \sum_{i=1}^n X_{ki}X_{2i} & \cdots & \sum_{i=1}^n X_{ki}^2 \end{pmatrix}^{-1} \begin{pmatrix} \sum_{i=1}^n X_{1i}Y_i \\ \sum_{i=1}^n X_{2i}Y_i \\ \vdots \\ \sum_{i=1}^n X_{ki}Y_i \end{pmatrix}$$

1.6. Propiedades Algebraicas de los MCO

Considerando que SI hay ti

- Las variables exógenas son ortogonales al vector de los residuos: $X^t\vec{e} = \vec{0}$

  Demostración

  1. Tenemos que $-2X^t\vec{y} + 2X^tX\vec{\hat{\beta}} = \vec{0}$
  2. Si operamos nos queda que $X^t(\vec{y} - X\vec{\hat{\beta}}) = \vec{0}$
  3. Aplicando que $\vec{\hat{y}} = X\vec{\hat{\beta}}$
  4. Queda demostrado que $X^t\vec{e} = \vec{0}$

- La suma de los residuos mínimos cuadráticos es 0: $\sum_{i=1}^{n} e_i = 0$
- La suma de los valores observados coincide con la suma de los valores estimados: $\sum_{i=1}^{n} y_i = \sum_{i=1}^{n} \hat{y}_i$
- Suma Cuadrados
  - $SCT = \sum_{i=1}^{n}(y_i - \bar{y})^2 = \vec{y}\ ^t\vec{y} - n \cdot \bar{Y}^2$
  - $SCR = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 = \vec{y}\ ^t\vec{y} - \vec{\beta}^t\vec{X}^t\vec{y}$
  - $SCE = \sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2 = \vec{\beta}^t\vec{X}^t\vec{y} - n \cdot \bar{Y}^2$
- SCT = SCR + SCE
- $\vec{\hat{y}}\vec{e} = 0$

1.7. Bondad del Ajuste

$$R^2 = \frac{SCE}{SCT} = \frac{\sum_{i=1}^{n}(\hat{Y} - \bar{Y})^2}{\sum_{i=1}^{n}(Y_i - \bar{Y})^2} \tag{17}$$

NOTA IMPORTANTE:

Si el modelo tiene término independiente entonces R^2 se puede expresar como:

$$R^2 = 1 - \frac{SCR}{SCT} \tag{18}$$

1.8. Bondad del Ajuste Corregido

$$\bar{R^2} = 1 - \frac{SCR/(n-k)}{SCT/n-1} = 1 - (1 - R^2) * \frac{n-1}{n-k} \tag{19}$$

1.9. Criterio de Akaike

$$AIC = \ln(\frac{SCR}{n}) + \frac{2k}{n} \tag{20}$$

1.10. Criterio de Schwarz

$$BIC = \ln(\frac{SCR}{n}) + \frac{k\ln(n)}{n} \tag{21}$$

2 Tema 3

2.1. Valor Esperado y Varianza de los EMCO (Estimadores mínimos cuadrados ordinarios)

2.1.1. Valor Esperado de los EMCO

1. El estimador de $\vec{\beta}$ del modelo $\vec{y} = X\vec{\beta} + \vec{u}$ es:

$$\hat{\vec{\beta}} = (X^tX)^{-1}X^t\vec{y}$$

2. Si en esta sustituimos $\vec{y} = X\vec{\beta} + \vec{u}$ nos quedaría:

$$\hat{\vec{\beta}} = (X^tX)^{-1}X^t(X\vec{\beta} + \vec{u}) = \vec{\beta} + (X^tX)^{-1}X^t\vec{u}$$

3. Por lo que $E[\hat{\vec{\beta}}] = \vec{\beta}$

   - Debido a que $E[\vec{u}] = \vec{0} \rightarrow \hat{\vec{B}}$ **es un estimador insesgado de** $\vec{\beta}$

2.1.2. Varianza de los EMCO

1. $var(\hat{\vec{\beta}}) = \sigma^2(X^tX)^{-1}$ Para ello debemos de seguir estos pasos:

   a) La varianza es igual a:

$$var(\hat{\vec{\beta}}) = E[(\hat{\vec{\beta}} - E[\hat{\beta}])(\hat{\vec{\beta}} - E[\hat{\beta}])^t]$$

   b) Si en la ecuación anterior sustituiimos $\hat{\vec{\beta}} = \vec{\beta} + (X^tX)^{-1}X^t\vec{u}$ nos queda:

$$var(\hat{\vec{\beta}}) = E[((X^tX)^{-1}X^t\vec{u})((X^tX)^{-1}X^t\vec{u})^t]$$

   c) Acto seguido, debemos de aplicar la propiedad de las matrices de $(AB)^t = B^tA^t$:

$$var(\hat{\vec{\beta}}) = E[(X^tX)^{-1}X^t\vec{u}\vec{u}^tX(X^tX)^{-1}]$$

d) Si aplicamos la propiedad de la esperanza de un producto de matrices $E[AB] = E[A]E[B]$:

$$var(\hat{\vec{\beta}}) = (X^tX)^{-1}X^tE[\vec{u}\vec{u}^t]X(X^tX)^{-1}$$

e) Si aplicamos la propiedad de la varianza de un vector $E[\vec{u}\vec{u}^t] = \sigma^2 I_n$:

$$var(\hat{\vec{\beta}}) = \sigma^2(X^tX)^{-1}X^tX(X^tX)^{-1} = \sigma^2(X^tX)^{-1}$$

f) Con esto quedaría demostrado que $var(\hat{\vec{\beta}}) = \sigma^2(X^tX)^{-1}$

2.2. Teorema de Gauss-Markov

Según este teorema tenemos que los estimadores de los mínimos cuadrados ordinarios son:

- óptimos
- lineales
- insesgados

Nota:

Podemos decir que de todos los estimadores de $\vec{\beta}$ el EMCO es el que presenta *menor matriz de varianzas-covarianzas*.

2.2.1. Demos

- **Demo I**: $\hat{\vec{\beta}}$ es lineal con respecto a $\vec{y}$

  Demostración

  1. si definimos una matriz de dimensiones k*n $W = (X^tX)^{-1}X^t$
  2. es fácil demostrar que que $\vec{B} = W\vec{y}$ ya que $\vec{B} = (X^tX)^{-1}X^t\vec{y}$

- **Demo II**: $\hat{\vec{\beta}}$ es insesgado de $\vec{\beta}$[2]

- **Demo III**: $\hat{\vec{\beta}}$ es un estimador óptimo de $\vec{\beta}$

[2]Queda demostrado anteriormente ya que se verificaba que la esperanza del parámetro a estimar era igual al parámetro.

Demostración

- Esperanza

Para la demostración debemos de seguir los siguientes pasos:

1. Suponemos un estimador alternativo $\vec{\hat{\beta}}^*$
2. Como se cumple que es lineal respecto de $\vec{\beta}$, entonces tenemos que $\vec{\hat{\beta}}^* = C\vec{y}$, es decir, existe un C que cumple la anterior condición de dimensiones k*n
3. Además ha de ser insesgado, por lo que tenemos que $E[\vec{\hat{\beta}}^*] = \vec{\beta}$
4. Si seguimos resolviendo tenemos que:

$$E[\vec{\hat{\beta}}^*] = E[C\vec{y}]$$

5. Aplicamos que $\vec{y} = X\vec{\beta} + \vec{u}$:

$$E[C\vec{y}] = E[C(X\vec{\beta} + \vec{u})] = E[CX\vec{\beta} + C\vec{u}] = CX\vec{\beta} + C\vec{u}$$

6. Como sabemos que $E[\vec{u}] = 0$, nos queda:

$$CX\vec{\beta} + C\vec{u} = CX\vec{\beta}$$

7. Volvemos al tema de insesgadez, para que sea insesgado (que se debe de cumplir en este punto) debe de que $Cx = I_k$
8. Por lo que tenemos de nuevo nuestro estimado anterior, podemos concluir la demostración afirmando que $\vec{\hat{\beta}}$ es un estimador óptimo de $\vec{\beta}$

- Varianza

- Si la calulamos de igual manera a la anterior y usando la matriz C, nos queda que:

$$= E[C\vec{u} * \vec{u}^t C^t] = C\sigma^2 I_n C^t = \sigma^2 CC^t$$ [3]

- Sabiendo que $\vec{\hat{\beta}} = W\vec{y}$ y $\vec{\hat{\beta}}^* = C\vec{y}$
- Denotamos D = C-W
- Tenemos que:

$$DX = (C - W)X = CX - WX = CX - (X^tX)^{-1}X^tX = I_k - I_k = 0_k$$

- podemos afirmar además, que en base a lo definido anteriormente:

$$var(\vec{\hat{\beta}}^*) = \sigma^2 CC^t = \sigma^2(W+D)^4(W+D)^t = \sigma^2(WW^t + WD^t + DW^t + DD^t)^5$$

[3] Hemos usado que $E[\vec{u}\vec{u}^t] = \sigma^2 I_n$

[4] Usamos que $C = W + D$

[5] De la anterior forma también es válida esta es más extensa, esta sirve para comparar las varianzas como vamos a ver a continuación

Comparación de varianzas

- $WW^t = ((X^tX)^{-1}X^t)((X^tX)^{-1}X^t) = (X^tX)^{-1}X^tX(X^tX)^{-1} = (X^tX)^{-1}$
- $WD^t = ((X^tX)^{-1}X^t)(D)^t = (X^tX)^{-1}X^t(C-W)^t = (X^tX)^{-1}X^t(C^t-W^t) = (X^tX)^{-1}X^tC^t - (X^tX)^{-1}X^tW^t = 0$
- $D((X^tX)^{-1}X^t)^t = 0$

- Aplicando esto nos queda que:

$$\text{var}(\vec{\hat{\beta}}^*) = \sigma^2 DD^t + \text{var}(\vec{\hat{\beta}})$$

- Como sabemos el primer término es siempre positivo, por lo que podemos afirmar que:

$$\text{var}(\vec{\hat{\beta}}^*) - \text{var}(\vec{\hat{\beta}}) = \sigma^2 DD^t \geqslant 0 \rightarrow \text{var}(\vec{\hat{\beta}}^*) \geqslant \text{var}(\vec{\hat{\beta}})$$

- Vemos que la varianza también es mayor, por lo que podemos concluir que $\vec{\hat{\beta}}^*$ es un estimador peor que $\vec{\hat{\beta}}$

2.3. Estimación de σ_u^2

Sabemos que el vector de los residuos es;

$$\vec{e} = \vec{y} - \hat{\vec{y}} = \vec{y} - X\hat{\vec{\beta}}$$

Si desarrollamos nos queda que:

$$(I_n - X(X^tX)^{-1}X^t)\vec{y} = M_x\vec{y}$$

La matriz M_x se conoce como la matriz complemento del proyector ortogonal, cuyas propiedades son:

- simétrica[6]
- idempotente[7]
- traza(M_x) = n - k
- M_xX = X - X = 0

Si sustituimos $\vec{y} = X\vec{\beta} + \vec{u}$ en la ecuación anterior nos queda que:

$$\vec{y} = M_x\vec{y} = M_xX\vec{\beta} + M_x\vec{u} = M_x\vec{u}^8$$

Si tomamos valores esperados obtenemos que ($E[\vec{e^t}\vec{e}] =$):

1. $E[(M_x\vec{u})^t(M_x\vec{u})]$

[6]Una matriz es simétrica si es igual a su traspuesta $A = A^t$
[7]Una matriz es idempotente si al elevarla al cuadrado nos da la misma matriz $A^2 = A$
[8]Ya que $M_xX = 0$

2. $= E[\vec{u}^t M_x \vec{u}]$[9]
3. $= E[\text{traza}(\vec{u^t} M_x)\vec{u}]$
4. $= \text{traza}(M_x E[\vec{u^t}\vec{u}])$
5. $= \text{traza}(\sigma^2 M_x)$
6. $= \sigma^2 \text{traza}(M_x)$
7. $= \sigma^2(n-k)$

Finalmente, nos queda que $E[\vec{e^t}\vec{e}] = \sigma^2(n-k)$, por lo que como $E[\frac{\vec{e^t}\vec{e}}{n-k}] = \sigma^2$ podemos afirmar que $\hat{\sigma}^2 = \frac{\vec{e^t}\vec{e}}{n-k} = \frac{SCR}{n-k}$ es un estimador insesgado de σ_u^2

2.4. Estimación de la varianza de los EMCO

Como sabemos la varianza del EMCO $\vec{\beta}$ es $\sigma^2(X^tX)^{-1}$, por lo que depende de la varianza de la perturbación y como sabemos el estimador de la varianza de la perturbación es: $\hat{\sigma}^2 = \frac{SCR}{n-k}$.

Por lo que nos queda que la varianza del EMCO es:

$$\text{var}(\vec{\hat{\beta}}) = \frac{SCR}{n-k} * (X^tX)^{-1} \tag{22}$$

2.5. Supuesto de Normalidad e Inferencia

Supuesto de normalidad: Supongamos que $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$.
Propiedades del estimador:

- Dado que $\vec{\hat{\beta}} = \vec{\beta} + (X^tX)^{-1}X^t\vec{u}$, por el Teorema de Gauss-Markov, se tiene que:

$$\vec{\hat{\beta}} \sim N(E[\vec{\hat{\beta}}], \text{var}(\vec{\hat{\beta}})) = N(\vec{\beta}, \sigma^2(X^tX)^{-1}).$$

- Equivalentemente, se cumple:

$$(\vec{\hat{\beta}} - \vec{\beta}) \sim N(\vec{0}, \sigma^2(X^tX)^{-1}).$$

Distribución del residuo:

- Como se verifica que $\vec{e}^{\,t}\vec{e} = \vec{u}^t M_X \vec{u}$, y dado que $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$, y que M_X es simétrica, idempotente y tiene rango $\rho(M_X) = n-k$, concluimos que:

$$\frac{1}{\sigma^2}\vec{u}^t M_X \vec{u} \sim \chi^2_{n-k}.$$

- Por tanto, se tiene que:

$$\frac{(n-k)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-k}.$$

[9] Ya que M_x es simétrica e idempotente

Más desarrollado, paso a paso:

2.6. Supuesto de Normalidad e Inferencia

Supuesto de normalidad: Supongamos que $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$.

Paso 1: Propiedades del estimador $\vec{\hat{\beta}}$

- Recordemos que el estimador $\vec{\hat{\beta}}$ se define como:

$$\vec{\hat{\beta}} = \vec{\beta} + (X^t X)^{-1} X^t \vec{u}.$$

- Dado que $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$, el término $(X^t X)^{-1} X^t \vec{u}$ también tiene distribución normal, ya que es una combinación lineal de $\vec{u}$.

- Por lo tanto, $\vec{\hat{\beta}}$ sigue una distribución normal:

$$\vec{\hat{\beta}} \sim N(\vec{\beta}, \sigma^2 (X^t X)^{-1}).$$

Paso 2: Distribución de $\vec{\hat{\beta}} - \vec{\beta}$

- Al restar $\vec{\beta}$ del estimador $\vec{\hat{\beta}}$:

$$\vec{\hat{\beta}} - \vec{\beta} = (X^t X)^{-1} X^t \vec{u}.$$

- Este término sigue una distribución normal con media cero y varianza $\sigma^2 (X^t X)^{-1}$:

$$(\vec{\hat{\beta}} - \vec{\beta}) \sim N(\vec{0}, \sigma^2 (X^t X)^{-1}).$$

Paso 3: Distribución del residuo $\vec{e}$

- Recordemos que el residuo se define como:

$$\vec{e} = \vec{y} - \hat{\vec{y}} = \vec{y} - X\vec{\hat{\beta}}.$$

- Sustituyendo $\vec{y} = X\vec{\beta} + \vec{u}$:

$$\vec{e} = \vec{y} - X\vec{\hat{\beta}} = (X\vec{\beta} + \vec{u}) - X\vec{\hat{\beta}}.$$

- Simplificando:

$$\vec{e} = \vec{u} - X(\vec{\hat{\beta}} - \vec{\beta}).$$

- Como $\vec{\hat{\beta}}$ depende de $\vec{u}$, al aplicar propiedades de matrices y el operador $M_X = I_n - X(X^t X)^{-1} X^t$:

$$\vec{e} = M_X \vec{u}.$$

Paso 4: Distribución de $\vec{e}^t \vec{e}$

- El término $\vec{e}^t\vec{e}$ puede escribirse como:

$$\vec{e}^t\vec{e} = \vec{u}^t M_X \vec{u}.$$

- Dado que $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$ y que M_X es simétrica, idempotente, y tiene rango $n-k$:

$$\frac{1}{\sigma^2}\vec{u}^t M_X \vec{u} \sim \chi^2_{n-k}.$$

- Por lo tanto, podemos concluir que:

$$\frac{(n-k)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-k},$$

donde $\hat{\sigma}^2 = \frac{\vec{e}^t\vec{e}}{n-k}$ es el estimador insesgado de σ^2.

2.7. Intervalos de Confianza

2.7.1. IC para β_i

$$\hat{\beta}_i \pm t_{n-k,1-\frac{\alpha}{2}} * \sqrt{\hat{\text{var}}\hat{\beta}_i}\ , i = 1, \ldots, k. \tag{23}$$

2.7.2. IC para σ^2

$$\left[\frac{(n-k)\sigma^2}{\chi^2_{n-k,1-\frac{\alpha}{2}}}, \frac{(n-k)\sigma^2}{\chi^2_{n-k,\frac{\alpha}{2}}}\right] \tag{24}$$

2.8. Contraste de hipótesis

$$H_0 : R\vec{\beta} = \vec{r} \tag{25}$$

donde:

$$R = \begin{pmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mk} \end{pmatrix}_{m\times k} \quad , \quad \vec{r} = \begin{pmatrix} r_1 \\ \vdots \\ r_m \end{pmatrix}_{m\times 1} \tag{26}$$

2.8.1. Estadístico de contraste

$$F_{exp} \sim F_{m,n-k}{}^{10} \tag{27}$$

[10] Cabe destacar que el estadístico desarrollado se encuentra en las diapositivas de la asignatura, en específico en la diapositiva 15/34 del tema 3

- Siendo m el número de restricciones.
- Siendo n el número de observaciones.
- Siendo k el número de variables explicativas.

¿Cuando se rechazará?

Cuando $F_{exp} > F_{m,n-k,1-\alpha}$.

2.8.2. Casos particulares

Contraste de significación individual

Si m = 1 y $r_i = 0\ \forall i$, tenemos las siguientes hipótesis:

$$\begin{cases} H_0 : \beta_i = 0 \\ H_1 : \beta_i \neq 0 \end{cases} \tag{28}$$

Con un estadístico de contraste:

$$t_{exp} = \frac{\hat{\beta}_i}{\sqrt{\hat{var}\hat{\beta}_i}} \tag{29}$$

Se rechazaría la hipótesis nula si $|t_{exp}| > t_{n-k,1-\frac{\alpha}{2}}$.

Única restricción lineal

Cuando m = 1 y $r_i \neq 0\ \forall i$, se tiene un contraste de hipótesis de la forma:

$$\begin{cases} H_0 : \beta_i = r_i \\ H_1 : \beta_i \neq r_i \end{cases} \tag{30}$$

Con un estadístico de contraste:

$$t_{exp} = \frac{\hat{\beta}_i - r_i}{\sqrt{\hat{var}\hat{\beta}_i}} \tag{31}$$

Se rechazaría la hipótesis nula si $|t_{exp}| > t_{n-k,1-\frac{\alpha}{2}}$.

Contraste de significación global

Si m = k-1 y $r_i = 0\ i = 2, 3, \ldots, k$.

$$\begin{cases} H_0 : \beta_2 = \beta_3 = \ldots = \beta_k = 0 \\ H_1 : \exists \beta_i \neq 0 \text{ con } i = 2, 3, \ldots, k \end{cases} \tag{32}$$

Con un estadístico de contraste:

$$F_{exp} = (R\vec{\hat{\beta}})^t \times \frac{[R(X^tX)^{-1}R^t]^{-1}}{(k-1) \times \sigma^2} \times (R\vec{\hat{\beta}}) \tag{33}$$

Se rechazaría la hipótesis nula si $F_{exp} > F_{k-1,n-k,1-\alpha}$.

Nota: Según la cronología de la asignatura, ahora tocaría la demostración del contraste de significación global, pero en clase se afirmó que no se iba a preguntar en el examen.

ANOVA

Teniendo en cuenta que se verifica:

1. $\vec{y}^t A \vec{y} = \vec{\hat{\beta}}_2^t X_2^t A X_2 \vec{\hat{\beta}}_2 + \vec{e}^t \vec{e}$
2. SCT = SCR + SCE

ANOVA → Análisis de la varianza donde se estudia la significación global del modelo donde[11]:

$$\begin{cases} H_0 : \beta_2 = \beta_3 = \ldots = \beta_k = 0 \\ H_1 : \exists \beta_i \neq 0 \text{ con } i = 2, 3, \ldots, k \end{cases} \qquad F_{exp} = \frac{SCE/k-1}{SCR/n-k} \quad \text{Se rechazará } H_0 \text{ si } F_{exp} > F_{k-1,n-k,1-\alpha} \tag{34}$$

2.9. Cota R^2

Se rechazará la hipótesis nula si $F_{exp} > F_{k-1,n-k,1-\alpha}$:

$$\frac{n-k}{k-1} \frac{R^2}{1-R^2} > F_{k-1,n-k,1-\alpha} \tag{35}$$

2.10. Predicción puntual

2.10.1. Para el valor individual

Suponiendo que tenemos permanencia estructural[12], podemos tomar como predictor para el valor medio y para el valor individual de la variable endógena:

$$\vec{x_0^t} \vec{\hat{\beta}} = \hat{y_0} = E[\widehat{y_0 \mid \vec{x_0}}]^{13} \tag{36}$$

Tenemos que:

- $E[e_0] = 0$[14]
- $var(e_0) = \sigma^2(1 + \vec{x_0^t}(X^t X)^{-1} \vec{x_0})$[15]

[11] Para un extra se puede mirar la diapositiva 24/34 del tema 3

[12] En este contexto, la permanencia estructural se refiere a la estabilidad de los parámetros del modelo a lo largo del tiempo. El proceso de generación de los datos para la nueva observación $\vec{x_0}$ es el mismo que ha generado la infromación muestral

[13] El predictor mínimo cuadrático es lineal, insesgado y óptimo

[14] La demostración se encuentra en la diapositiva 27/34 del tema 3

[15] La demostración se encuentra en la diapositiva 28/34 del tema 3

2.10.2. Para el valor esperado

$e_0^* \sim N(0, \sigma^2(1 + \vec{x_0^t}(X^tX)^{-1}\vec{x_0}))$[16]

2.10.3. Por intervalo

- Intervalo de confianza para el valor individual y_0:

$$IC_{y_0} = \hat{y_0} \pm t_{n-k,1-\frac{\alpha}{2}} \sqrt{\hat{\sigma}^2(1 + \vec{x_0^t}(X^tX)^{-1}\vec{x_0})} \tag{37}$$

  Teniendo en cuanta que podemos sacar el sigma de raíz y de que $\hat{y_0} = \vec{x_0^t}\vec{\hat{\beta}}$, nos queda:

$$IC_{y_0} = \vec{x_0^t}\vec{\hat{\beta}} \pm t_{n-k,1-\frac{\alpha}{2}} \hat{\sigma}\sqrt{1 + \vec{x_0^t}(X^tX)^{-1}\vec{x_0}} \tag{38}$$

- Intervalo de confianza para el valor esperado $E[y_0 \mid \vec{x_0}]$:

$$IC_{E[y_0|\vec{x_0}]} = \vec{x_0^t}\vec{\hat{\beta}} \pm t_{n-k,1-\frac{\alpha}{2}} \hat{\sigma}\sqrt{\vec{x_0^t}(X^tX)^{-1}\vec{x_0}} \tag{39}$$

2.11. Construcción de las distribuciones

2.11.1. Distribución χ^2 de Pearson

Suma de los cuadrados de n variables aleatorias independientes e idénticamente distribuidas que siguen una distribución normal estándar[17].

$$\chi_n^2 = \sum_{i=1}^{n} X_i^2 \quad \text{donde } X_i \sim N(0,1) \quad \forall i \tag{40}$$

- No simétrica
- No negativa
- No acotada
- Su media es n y su varianza es $2n$

2.11.2. Distribución t de Student

Cociente entre una variable aleatoria normal estándar y la raíz cuadrada de una χ^2 de Pearson dividida por sus grados de libertad, siendo ambas independientes.

$$t_n = \frac{Z}{\sqrt{\frac{X}{n}}} \quad \text{donde } Z \sim N(0,1) \text{ e } X \sim \chi_n^2 \tag{41}$$

[16] La demostración se encuentra en la diapositiva 29/34 del tema 3

[17] $N(0,1)$

- Simétrica
- Para n>30 se puede aproximar a una normal
- Su media es 0
- Su varianza es $\frac{n}{n-2}$
- Acotada

2.11.3. Distribución F de Fisher-Snedecor

Cociente entre dos χ^2 de Pearson divididas por sus grados de libertad, siendo ambas independientes.

$$F_{m,n} = \frac{X_1/m}{X_2/n} \quad \text{donde } X_1 \sim \chi^2_m \text{ e } X_2 \sim \chi^2_n \tag{42}$$

- No simétrica
- $F_{m,n,1-\alpha} = \frac{1}{F_{n,m,\alpha}}$
- $t^2_n = F_{1,n}$