FACULTAD DE CIENCIAS
ECONÓMICAS Y EMPRESARIALES

Ingeniería Informática + ADE

Universidad de Granada (UGR)

Autor: Ismael Sallami Moreno

Asignatura: Formulario y Resumen Econometría

Índice

1. Tema 2 **4**
1.1. Modelo Lineal Simple . . . 4
1.2. Modelo Lineal Múltiple . . . 4
1.3. Notación MLP . . . 4
1.3.1. Notación Extra . . . 5
1.4. Supuestos . . . 5
1.4.1. Linealidad . . . 5
1.4.2. Rango Completo Por Columnas . . . 5
1.4.3. Exogeneidad . . . 5
1.4.4. Causalidad . . . 5
1.4.5. Perturbación . . . 6
1.4.6. Normalidad de la perturbación . . . 6
1.5. Estimación Míminos Cuadrados Ordinarios (MCO) . . . 6
1.5.1. Pasos a seguir . . . 6
1.6. Estimación Míminos Cuadrados Ordinarios Restringidos(MCO(R)) . . . 7
1.7. Propiedades Algebraicas de los MCO . . . 7
1.8. Bondad del Ajuste . . . 8
1.9. Bondad del Ajuste Corregido . . . 8
1.10. Criterio de Akaike . . . 8
1.11. Criterio de Schwarz . . . 8

2. Tema 3 **9**
2.1. Valor Esperado y Varianza de los EMCO (Estimadores mínimos cuadrados ordinarios) . . . 9
2.1.1. Valor Esperado de los EMCO . . . 9
2.1.2. Varianza de los EMCO . . . 9
2.2. Teorema de Gauss-Markov . . . 10
2.2.1. Demos . . . 10
2.3. Estimación de σ_u^2 . . . 12
2.4. Estimación de la varianza de los EMCO . . . 13
2.5. Supuesto de Normalidad e Inferencia . . . 13
2.6. Supuesto de Normalidad e Inferencia . . . 13
2.7. Intervalos de Confianza . . . 15
2.7.1. IC para β_i . . . 15
2.7.2. IC para σ^2 . . . 15
2.8. Contraste de hipótesis . . . 15
2.8.1. Estadístico de contraste . . . 15
2.8.2. Casos particulares . . . 16
2.9. Cota R^2 . . . 17
2.10. Predicción puntual . . . 17
2.10.1. Para el valor individual . . . 17
2.10.2. Para el valor esperado . . . 17
2.10.3. Por intervalo . . . 18

2.11. Construcción de las distribuciones 18
2.11.1. Distribución χ^2 de Pearson 18
2.11.2. Distribución t de Student 18
2.11.3. Distribución F de Fisher-Snedecor 19

3. Tema 4: Multicolinealidadad **19**
3.1. Concepto 19
3.2. Clasificación 19
3.2.1. Clasificaciones de la multicolinealidadad aproximada 20
3.3. Factor de inflación de la varianza 20
3.4. Número de condición 20
3.5. Otras Medidas 21
3.5.1. Matriz de Correlaciones (R) 21
3.5.2. Determinante de la matriz de correlaciones *det(R)* 21
3.5.3. Coeficiente de variación de las variables explicativas 21
3.6. Soluciones 21

1 Tema 2

1.1. Modelo Lineal Simple

$$Y_i \sim a + bx_i \tag{1}$$

1.2. Modelo Lineal Múltiple

$$Y_i = \beta_1 + \beta_2 x_{i2} + \beta_3 x_{i3} + \ldots + \beta_k x_{ik} + u_i \tag{2}$$

- El subíndice i indica la observación.
- El subíndice k indica el número de variables explicativas.
- El subíndice u indica el término de error.
- Nota: β_1 es la constante, lleva asociado el valor $1 = x_{i1}$ (por eso no se pone).

1.3. Notación MLP

$$\vec{y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} \tag{3}$$

$$X = \begin{pmatrix} 1 & X_{21} & \cdots & X_{k1} \\ 1 & X_{22} & \cdots & X_{k2} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & X_{2n} & \cdots & X_{kn} \end{pmatrix} \tag{4}$$

$$\vec{\beta} = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix} \tag{5}$$

$$\vec{u} = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix} \tag{6}$$

1.3.1. Notación Extra

Matriz $X'X$

$$\begin{pmatrix} n & \sum_{i=0}^{n} X_{1i} & \cdots & \sum_{i=0}^{n} X_{ki} \\ \sum_{i=0}^{n} X_{1i} & \sum_{i=0}^{n} X_{1i}^2 & \cdots & \sum_{i=0}^{n} X_{1i}X_{ki} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=0}^{n} X_{ki} & \sum_{i=0}^{n} X_{ki}X_{1i} & \cdots & \sum_{i=0}^{n} X_{ki}^2 \end{pmatrix} \tag{7}$$

Matriz $X'Y$

$$\begin{pmatrix} \sum_{i=0}^{n} Y_i \\ \sum_{i=0}^{n} X_{2i}Y_i \\ \vdots \\ \sum_{i=0}^{n} X_{ki}Y_i \end{pmatrix} \tag{8}$$

1.4. Supuestos

1.4.1. Linealidad

$$Y_i = \beta_1 + \beta_2 x_{i2} + \beta_3 x_{i3} + \ldots + \beta_k x_{ik} + u_i \tag{9}$$

1.4.2. Rango Completo Por Columnas

$$rango(X) = k \tag{10}$$

1.4.3. Exogeneidad

$$E(u_i|X_i) = 0 \tag{11}$$

- El valor esperado de la esperanza que toman las variables explicativas es 0.

Por lo que si tenemos que: $Y_i = \vec{X}_i^t \vec{\beta}$, tenemos de forma inmediata que:

$$E(Y_i|X_i) = \vec{X}_i^t \vec{\beta} \tag{12}$$

1.4.4. Causalidad

- Relación de causalidad es unidireccional.
- Las variables aparecen en el lado derecho de la ecuación, pero no al contrario.
- La variable dependiente Y_i adoptará un carácter aleatorio.

1.4.5. Perturbación

- Esta centrada, es decir, $E(u_i) = 0 \forall i = 1, 2, \ldots, n$
- Es homocedástica, es decir, $Var(u_i) = E[u_i^2] = \sigma^2 \forall i = 1, 2, \ldots, n$
- Si es incorrelada implica que $cov[u_i u_j] = E[u_i u_j] = 0$. Cuando es neq 0 decimos que hay un problema de autocorrelación.

Como consecuencia tenemos que:

$$var[\vec{u}] = E[(\vec{u} - E[\vec{u}])(\vec{u} - E[\vec{u}])^t] = E[\vec{u}\vec{u}^t] \tag{13}$$

Para la demostración de esta operación pincha aquí para verla.

1.4.6. Normalidad de la perturbación

Se considera que la perturbación aleatoria u_i se distribuye normalmente con media 0 y varianza σ^2, es decir, $u_i \sim N(0, \sigma^2) \forall i = 1, \ldots, n$.

En este caso supondremos que $\vec{u}$ se distribuye normalmente, es decir, $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$[1].

1.5. Estimación Míminos Cuadrados Ordinarios (MCO)

Para estimar los parámetros β utilizaremos el MCO, denotando a $\hat{\vec{y}}$ el valor ajustado de $\vec{y}$, es decir, $\hat{\vec{y}} = X\hat{\vec{\beta}}$.

En este caso el valor de los residuos se obtiene como:

$$\vec{e} = \vec{y} - \hat{\vec{y}} = \vec{y} - X\hat{\vec{\beta}} \tag{14}$$

Debemos de minimizar la suma de los cuadrados de los residuos:

$$\min_{\vec{\beta}} \sum_{i=1}^{n} e_i^2 \tag{15}$$

Tendremos como función a minimizar: $f(\hat{\vec{\beta}}) = \vec{e}^{\,t}\vec{e}$

1.5.1. Pasos a seguir

1. Definimos la expresión a minimizar. Se debe de definir la suma de los cuadrados de los residuos:
$$f(\vec{\hat{\beta}}) = (\vec{y} - X\vec{\hat{\beta}})^t(\vec{y} - X\vec{\hat{\beta}}) \tag{16}$$
2. Derivamos con respecto a $\vec{\hat{\beta}}$ e igualamos a 0:
$$\frac{\partial f(\vec{\hat{\beta}})}{\partial \vec{\hat{\beta}}} = 0 \tag{17}$$

[1] distribución normal multivariante con vector de medias nulo y matriz de varianzas-covarianzas $\sigma^2 I_n$

3. Despejamos el vector de parámetros, debemos de considerar el supuesto del rango completo por columnas, verificándose que $\rho(X^tX) = 1$, condición necesaria para que exista $(X^tX)^{-1}$

4. Para que la solución sea mínimo se ha de cumplir:

$$\text{Hess}(f) = 2X^tX > 0 \text{ and } (A > 0 \text{ si } z^tAz > 0 \ \forall z \neq 0) \tag{18}$$

Si el modelo tiene término independiente entonces se tiene

$$\vec{\beta} = \begin{pmatrix} n & \sum_{i=1}^n X_{2i} & \cdots & \sum_{i=1}^n X_{ki} \\ \sum_{i=1}^n X_{2i} & \sum_{i=1}^n X_{2i}^2 & \cdots & \sum_{i=1}^n X_{2i}X_{ki} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n X_{ki} & \sum_{i=1}^n X_{ki}X_{2i} & \cdots & \sum_{i=1}^n X_{ki}^2 \end{pmatrix}^{-1} \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n X_{2i}Y_i \\ \vdots \\ \sum_{i=1}^n X_{ki}Y_i \end{pmatrix}$$

En el caso de que el modelo carezca del término independiente entonces:

$$\vec{\beta} = \begin{pmatrix} \sum_{i=1}^n X_{1i}^2 & \sum_{i=1}^n X_{1i}X_{2i} & \cdots & \sum_{i=1}^n X_{1i}X_{ki} \\ \sum_{i=1}^n X_{2i}X_{1i} & \sum_{i=1}^n X_{2i}^2 & \cdots & \sum_{i=1}^n X_{2i}X_{ki} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n X_{ki}X_{1i} & \sum_{i=1}^n X_{ki}X_{2i} & \cdots & \sum_{i=1}^n X_{ki}^2 \end{pmatrix}^{-1} \begin{pmatrix} \sum_{i=1}^n X_{1i}Y_i \\ \sum_{i=1}^n X_{2i}Y_i \\ \vdots \\ \sum_{i=1}^n X_{ki}Y_i \end{pmatrix}$$

1.6. Estimación Míminos Cuadrados Ordinarios Restringidos(MCO(R))

$$\widehat{\beta_R} = \widehat{\beta} - (R(X'X)^{-1})^t \times [R(X'X)^{-1}R']^{-1} \times R\widehat{\beta} \tag{19}$$

1.7. Propiedades Algebraicas de los MCO

Considerando que SI hay ti

- Las variables exógenas son ortogonales al vector de los residuos: $X^t\vec{e} = \vec{0}$

  Demostración

  1. Tenemos que $-2X^t\vec{y} + 2X^tX\vec{\hat{\beta}} = \vec{0}$
  2. Si operamos nos queda que $X^t(\vec{y} - X\vec{\hat{\beta}}) = \vec{0}$
  3. Aplicando que $\vec{\hat{y}} = X\vec{\hat{\beta}}$
  4. Queda demostrado que $X^t\vec{e} = \vec{0}$

- La suma de los residuos mínimos cuadráticos es 0: $\sum_{i=1}^n e_i = 0$
- La suma de los valores observados coincide con la suma de los valores estimados: $\sum_{i=1}^n y_i = \sum_{i=1}^n \hat{y}_i$

- Suma Cuadrados
  - $SCT = \sum_{i=1}^{n}(y_i - \bar{y})^2 = \vec{y}\ ^t\vec{y} - n \cdot \bar{Y}^2$
  - $SCR = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 = \vec{y}\ ^t\vec{y} - \vec{\beta}^t\vec{X}^t\vec{y}$
  - $SCE = \sum_{i=1}^{n}(\hat{y}_i - \bar{y})^2 = \vec{\beta}^{t2}\vec{X}^t\vec{y} - n \cdot \bar{Y}^2$
- SCT = SCR + SCE
- $\vec{\hat{y}}\vec{e} = 0$

1.8. Bondad del Ajuste

$$R^2 = \frac{SCE}{SCT} = \frac{\sum_{i=1}^{n}(\hat{Y} - \bar{Y})^2}{\sum_{i=1}^{n}(Y_i - \bar{Y})^2} \tag{20}$$

NOTA IMPORTANTE:

Si el modelo tiene término independiente entonces R^2 se puede expresar como:

$$R^2 = 1 - \frac{SCR}{SCT} \tag{21}$$

1.9. Bondad del Ajuste Corregido

$$\bar{R^2} = 1 - \frac{SCR/(n-k)}{SCT/n-1} = 1 - (1 - R^2) * \frac{n-1}{n-k} \tag{22}$$

1.10. Criterio de Akaike

$$AIC = ln(\frac{SCR}{n}) + \frac{2k}{n} \tag{23}$$

1.11. Criterio de Schwarz

$$BIC = ln(\frac{SCR}{n}) + \frac{kln(n)}{n} \tag{24}$$

[2]En la práctica la simbología de t = traspuesta = *prima* = ′

2 Tema 3

2.1. Valor Esperado y Varianza de los EMCO (Estimadores mínimos cuadrados ordinarios)

2.1.1. Valor Esperado de los EMCO

1. El estimador de $\vec{\beta}$ del modelo $\vec{y} = X\vec{\beta} + \vec{u}$ es:

$$\hat{\vec{\beta}} = (X^tX)^{-1}X^t\vec{y}$$

2. Si en esta sustituimos $\vec{y} = X\vec{\beta} + \vec{u}$ nos quedaría:

$$\hat{\vec{\beta}} = (X^tX)^{-1}X^t(X\vec{\beta} + \vec{u}) = \vec{\beta} + (X^tX)^{-1}X^t\vec{u}$$

3. Por lo que $E[\hat{\vec{\beta}}] = \vec{\beta}$

   - Debido a que $E[\vec{u}] = \vec{0} \rightarrow \hat{\vec{B}}$ **es un estimador insesgado de** $\vec{\beta}$

2.1.2. Varianza de los EMCO

1. $var(\hat{\vec{\beta}}) = \sigma^2(X^tX)^{-1}$ Para ello debemos de seguir estos pasos:

   a) La varianza es igual a:

$$var(\hat{\vec{\beta}}) = E[(\hat{\vec{\beta}} - E[\hat{\beta}])(\hat{\vec{\beta}} - E[\hat{\beta}])^t]$$

   b) Si en la ecuación anterior sustituiimos $\hat{\vec{\beta}} = \vec{\beta} + (X^tX)^{-1}X^t\vec{u}$ nos queda:

$$var(\hat{\vec{\beta}}) = E[((X^tX)^{-1}X^t\vec{u})((X^tX)^{-1}X^t\vec{u})^t]$$

   c) Acto seguido, debemos de aplicar la propiedad de las matrices de $(AB)^t = B^tA^t$:

$$var(\hat{\vec{\beta}}) = E[(X^tX)^{-1}X^t\vec{u}\vec{u}^tX(X^tX)^{-1}]$$

   d) Si aplicamos la propiedad de la esperanza de un producto de matrices $E[AB] = E[A]E[B]$:

$$var(\hat{\vec{\beta}}) = (X^tX)^{-1}X^tE[\vec{u}\vec{u}^t]X(X^tX)^{-1}$$

   e) Si aplicamos la propiedad de la varianza de un vector $E[\vec{u}\vec{u}^t] = \sigma^2 I_n$:

$$var(\hat{\vec{\beta}}) = \sigma^2(X^tX)^{-1}X^tX(X^tX)^{-1} = \sigma^2(X^tX)^{-1}$$

   f) Con esto quedaría demostrado que $var(\hat{\vec{\beta}}) = \sigma^2(X^tX)^{-1}$

2.2. Teorema de Gauss-Markov

Según este teorema tenemos que los estimadores de los mínimos cuadrados ordinarios son:

- óptimos
- lineales
- insesgados

Nota:

Podemos decir que de todos los estimadores de $\vec{\beta}$ el EMCO es el que presenta *menor matriz de varianzas-covarianzas*.

2.2.1. Demos

- **Demo I**: $\vec{\hat{\beta}}$ es lineal con respecto a $\vec{y}$

  Demostración

  1. si definimos una matriz de dimensiones k*n $W = (X^tX)^{-1}X^t$
  2. es fácil demostrar que que $\vec{B} = W\vec{y}$ ya que $\vec{B} = (X^tX)^{-1}X^t\vec{y}$

- **Demo II**: $\vec{\hat{\beta}}$ es insesgado de $\vec{\beta}$[3]

- **Demo III**: $\vec{\hat{\beta}}$ es un estimador óptimo de $\vec{\beta}$

  Demostración

  - Esperanza

  Para la demostración debemos de seguir los siguientes pasos:

  1. Suponemos un estimador alternativo $\vec{\hat{\beta}}^*$
  2. Como se cumple que es lineal respecto de $\vec{\beta}$, entonces tenemos que $\vec{\hat{\beta}}^* = C\vec{y}$, es decir, existe un C que cumple la anterior condición de dimensiones k*n
  3. Además ha de ser insesgado, por lo que tenemos que $E[\vec{\hat{\beta}}^*] = \vec{\beta}$
  4. Si seguimos resolviendo tenemos que:

$$E[\vec{\hat{\beta}}^*] = E[C\vec{y}]$$

[3]Queda demostrado anteriormente ya que se verificaba que la esperanza del parámetro a estimar era igual al parámetro.

5. Aplicamos que $\vec{y} = X\vec{\beta} + \vec{u}$:
$$E[C\vec{y}] = E[C(X\vec{\beta} + \vec{u})] = E[CX\vec{\beta} + C\vec{u}] = CX\vec{\beta} + C\vec{u}$$
6. Como sabemos que $E[\vec{u}] = 0$, nos queda:
$$CX\vec{\beta} + C\vec{u} = CX\vec{\beta}$$
7. Volvemos al tema de insesgadez, para que sea insesgado (que se debe de cumplir en este punto) debe de que $Cx = I_k$
8. Por lo que tenemos de nuevo nuestro estimado anterior, podemos concluir la demostración afirmando que $\vec{\hat{\beta}}$ es un estimador óptimo de $\vec{\beta}$

- Varianza

- Si la calulamos de igual manera a la anterior y usando la matriz C, nos queda que:
$$= E[C\vec{u} * \vec{u}^t C^t] = C\sigma^2 I_n C^t = \sigma^2 CC^t$$[4]
- Sabiendo que $\vec{\hat{\beta}} = W\vec{y}$ y $\vec{\hat{\beta}}^* = C\vec{y}$
- Denotamos D = C-W
- Tenemos que:
$$DX = (C - W)X = CX - WX = CX - (X^tX)^{-1}X^tX = I_k - I_k = 0_k$$
- podemos afirmar además, que en base a lo definido anteriormente:
$$var(\vec{\hat{\beta}}^*) = \sigma^2 CC^t = \sigma^2(W+D)^5(W+D)^t = \sigma^2(WW^t + WD^t + DW^t + DD^t)^6$$

Comparación de varianzas

- $WW^t = ((X^tX)^{-1}X^t)((X^tX)^{-1}X^t) = (X^tX)^{-1}X^tX(X^tX)^{-1} = (X^tX)^{-1}$
- $WD^t = ((X^tX)^{-1}X^t)(D)^t = (X^tX)^{-1}X^t(C-W)^t = (X^tX)^{-1}X^t(C^t - W^t) = (X^tX)^{-1}X^tC^t - (X^tX)^{-1}X^tW^t = 0$
- $D((X^tX)^{-1}X^t)^t = 0$

- Aplicando esto nos queda que:
$$var(\vec{\hat{\beta}}^*) = \sigma^2 DD^t + var(\vec{\hat{\beta}})$$
- Como sabemos el primer término es siempre positivo, por lo que podemos afirmar que:
$$var(\vec{\hat{\beta}}^*) - var(\vec{\hat{\beta}}) = \sigma^2 DD^t \geqslant 0 \rightarrow var(\vec{\hat{\beta}}^*) \geqslant var(\vec{\hat{\beta}})$$
- Vemos que la varianza también es mayor, por lo que podemos concluir que $\vec{\hat{\beta}}^*$ es un estimador peor que $\vec{\hat{\beta}}$

[4] Hemos usado que $E[\vec{u}\vec{u}^t] = \sigma^2 I_n$
[5] Usamos que $C = W + D$
[6] De la anterior forma también es válida esta es más extensa, esta sirve para comparar las varianzas como vamos a ver a continuación

2.3. Estimación de σ_u^2

Sabemos que el vector de los residuos es;

$$\vec{e} = \vec{y} - \hat{\vec{y}} = \vec{y} - X\hat{\vec{\beta}}$$

Si desarrollamos nos queda que:

$$(I_n - X(X^tX)^{-1}X^t)\vec{y} = M_x\vec{y}$$

La matriz M_x se conoce como la matriz complemento del proyector ortogonal, cuyas propiedades son:

- simétrica[7]
- idempotente[8]
- traza(M_x) = n - k
- M_xX = X - X = 0

Si sustituimos $\vec{y} = X\vec{\beta} + \vec{u}$ en la ecuación anterior nos queda que:

$$\vec{y} = M_x\vec{y} = M_xX\vec{\beta} + M_x\vec{u} = M_x\vec{u}^{9}$$

Si tomamos valores esperados obtenemos que ($E[\vec{e^t}\vec{e}] =$):

1. $E[(M_x\vec{u})^t(M_x\vec{u})]$
2. $= E[\vec{u}^tM_x\vec{u}]^{10}$
3. $= E[\text{traza}(\vec{u^t}M_x)\vec{u}]$
4. $= \text{traza}(M_xE[\vec{u^t}\vec{u}])$
5. $= \text{traza}(\sigma^2M_x)$
6. $= \sigma^2\text{traza}(M_x)$
7. $= \sigma^2(n-k)$

Finalmente, nos queda que $E[\vec{e^t}\vec{e}] = \sigma^2(n-k)$, por lo que como $E[\frac{\vec{e^t}\vec{e}}{n-k}] = \sigma^2$ podemos afirmar que $\hat{\sigma}^2 = \frac{\vec{e^t}\vec{e}}{n-k} = \frac{SCR}{n-k}$ es un estimador insesgado de σ_u^2

[7] Una matriz es simétrica si es igual a su traspuesta $A = A^t$
[8] Una matriz es idempotente si al elevarla al cuadrado nos da la misma matriz $A^2 = A$
[9] Ya que $M_xX = 0$
[10] Ya que M_x es simétrica e idempotente

2.4. Estimación de la varianza de los EMCO

Como sabemos la varianza del EMCO $\vec{\beta}$ es $\sigma^2(X^tX)^{-1}$, por lo que depende de la varianza de la perturbación y como sabemos el estimador de la varianza de la perturbación es: $\hat{\sigma}^2 = \frac{SCR}{n-k}$.

Por lo que nos queda que la varianza del EMCO es:

$$\text{var}(\vec{\hat{\beta}}) = \frac{SCR}{n-k} * (X^tX)^{-1} \tag{25}$$

2.5. Supuesto de Normalidad e Inferencia

Supuesto de normalidad: Supongamos que $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$.
Propiedades del estimador:

- Dado que $\vec{\hat{\beta}} = \vec{\beta} + (X^tX)^{-1}X^t\vec{u}$, por el Teorema de Gauss-Markov, se tiene que:

$$\vec{\hat{\beta}} \sim N(E[\vec{\hat{\beta}}], \text{var}(\vec{\hat{\beta}})) = N(\vec{\beta}, \sigma^2(X^tX)^{-1}).$$

- Equivalentemente, se cumple:

$$(\vec{\hat{\beta}} - \vec{\beta}) \sim N(\vec{0}, \sigma^2(X^tX)^{-1}).$$

Distribución del residuo:

- Como se verifica que $\vec{e}^{\,t}\vec{e} = \vec{u}^tM_X\vec{u}$, y dado que $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$, y que M_X es simétrica, idempotente y tiene rango $\rho(M_X) = n-k$, concluimos que:

$$\frac{1}{\sigma^2}\vec{u}^tM_X\vec{u} \sim \chi^2_{n-k}.$$

- Por tanto, se tiene que:

$$\frac{(n-k)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-k}.$$

Más desarrollado, paso a paso:

2.6. Supuesto de Normalidad e Inferencia

Supuesto de normalidad: Supongamos que $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$.
Paso 1: Propiedades del estimador $\vec{\hat{\beta}}$

- Recordemos que el estimador $\vec{\hat{\beta}}$ se define como:

$$\vec{\hat{\beta}} = \vec{\beta} + (X^tX)^{-1}X^t\vec{u}.$$

- Dado que $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$, el término $(X^t X)^{-1} X^t \vec{u}$ también tiene distribución normal, ya que es una combinación lineal de $\vec{u}$.
- Por lo tanto, $\hat{\vec{\beta}}$ sigue una distribución normal:

$$\hat{\vec{\beta}} \sim N(\vec{\beta}, \sigma^2 (X^t X)^{-1}).$$

Paso 2: Distribución de $\hat{\vec{\beta}} - \vec{\beta}$

- Al restar $\vec{\beta}$ del estimador $\hat{\vec{\beta}}$:

$$\hat{\vec{\beta}} - \vec{\beta} = (X^t X)^{-1} X^t \vec{u}.$$

- Este término sigue una distribución normal con media cero y varianza $\sigma^2 (X^t X)^{-1}$:

$$(\hat{\vec{\beta}} - \vec{\beta}) \sim N(\vec{0}, \sigma^2 (X^t X)^{-1}).$$

Paso 3: Distribución del residuo $\vec{e}$

- Recordemos que el residuo se define como:

$$\vec{e} = \vec{y} - \hat{\vec{y}} = \vec{y} - X\hat{\vec{\beta}}.$$

- Sustituyendo $\vec{y} = X\vec{\beta} + \vec{u}$:

$$\vec{e} = \vec{y} - X\hat{\vec{\beta}} = (X\vec{\beta} + \vec{u}) - X\hat{\vec{\beta}}.$$

- Simplificando:

$$\vec{e} = \vec{u} - X(\hat{\vec{\beta}} - \vec{\beta}).$$

- Como $\hat{\vec{\beta}}$ depende de $\vec{u}$, al aplicar propiedades de matrices y el operador $M_X = I_n - X(X^t X)^{-1} X^t$:

$$\vec{e} = M_X \vec{u}.$$

Paso 4: Distribución de $\vec{e}^t \vec{e}$

- El término $\vec{e}^t \vec{e}$ puede escribirse como:

$$\vec{e}^t \vec{e} = \vec{u}^t M_X \vec{u}.$$

- Dado que $\vec{u} \sim N(\vec{0}, \sigma^2 I_n)$ y que M_X es simétrica, idempotente, y tiene rango $n - k$:

$$\frac{1}{\sigma^2} \vec{u}^t M_X \vec{u} \sim \chi^2_{n-k}.$$

- Por lo tanto, podemos concluir que:

$$\frac{(n-k)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-k},$$

donde $\hat{\sigma}^2 = \frac{\vec{e}^t \vec{e}}{n-k}$ es el estimador insesgado de σ^2.

2.7. Intervalos de Confianza

2.7.1. IC para β_i

$$\hat{\beta}_i \pm t_{n-k,1-\frac{\alpha}{2}} * \sqrt{\hat{var}\hat{\beta}_i}\ , i = 1, \ldots, k. \tag{26}$$

2.7.2. IC para σ^2

$$\left[\frac{(n-k)\sigma^2}{\chi^2_{n-k,1-\frac{\alpha}{2}}}, \frac{(n-k)\sigma^2}{\chi^2_{n-k,\frac{\alpha}{2}}}\right] \tag{27}$$

2.8. Contraste de hipótesis

$$H_0 : R^{11}\vec{\beta} = \vec{r}$$

donde:

$$R = \begin{pmatrix} a_{11} & \cdots & a_{1k} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mk} \end{pmatrix}_{m\times k} \quad , \quad \vec{r} = \begin{pmatrix} r_1 \\ \vdots \\ r_m \end{pmatrix}_{m\times 1} \tag{28}$$

2.8.1. Estadístico de contraste

$$F_{exp} \sim F_{m,n-k}{}^{12} \tag{29}$$

- Siendo m el número de restricciones.
- Siendo n el número de observaciones.
- Siendo k el número de variables explicativas.

¿Cuando se rechazará?

Cuando $F_{exp} > F_{m,n-k,1-\alpha}$.

[11] En la práctica hace referencia a la matriz de restricciones que se saca mediante el enunciado y/o los datos que se proporcionan

[12] Cabe destacar que el estadístico desarrollado se encuentra en las diapositivas de la asignatura, en específico en la diapositiva 15/34 del tema 3

2.8.2. Casos particulares

Contraste de significación individual

Si m = 1 y $r_i = 0\ \forall i$, tenemos las siguientes hipótesis:

$$\begin{cases} H_0 : \beta_i = 0 \\ H_1 : \beta_i \neq 0 \end{cases} \tag{30}$$

Con un estadístico de contraste:

$$t_{exp} = \frac{\hat{\beta}_i}{\sqrt{\hat{var}\hat{\beta}_i}} \tag{31}$$

Se rechazaría la hipótesis nula si $|t_{exp}| > t_{n-k,1-\frac{\alpha}{2}}$.

Única restricción lineal

Cuando m = 1 y $r_i \neq 0\ \forall i$, se tiene un contraste de hipótesis de la forma:

$$\begin{cases} H_0 : \beta_i = r_i \\ H_1 : \beta_i \neq r_i \end{cases} \tag{32}$$

Con un estadístico de contraste:

$$t_{exp} = \frac{\hat{\beta}_i - r_i}{\sqrt{\hat{var}\hat{\beta}_i}} \tag{33}$$

Se rechazaría la hipótesis nula si $|t_{exp}| > t_{n-k,1-\frac{\alpha}{2}}$.

Contraste de significación global

Si m = k-1 y $r_i = 0\ i = 2, 3, \ldots, k$.

$$\begin{cases} H_0 : \beta_2 = \beta_3 = \ldots = \beta_k = 0 \\ H_1 : \exists \beta_i \neq 0 \text{ con } i = 2, 3, \ldots, k \end{cases} \tag{34}$$

Con un estadístico de contraste:

$$F_{exp} = (R\vec{\hat{\beta}})^t \times \frac{[R(X^tX)^{-1}R^t]^{-1}}{(k-1) \times \sigma^2} \times (R\vec{\hat{\beta}}) \quad \text{ó} \quad F_{exp} = \frac{\frac{R^2}{k-1}}{\frac{1-R^2}{n-k}} \tag{35}$$

Se rechazaría la hipótesis nula si $F_{exp} > F_{k-1,n-k,1-\alpha}$.

Nota: Según la cronología de la asignatura, ahora tocaría la demostración del contraste de significación global, pero en clase se afirmó que no se iba a preguntar en el examen.

ANOVA

Teniendo en cuenta que se verifica:

1. $\vec{y}^{\,t}A\vec{y} = \vec{\hat{\beta}}_2^{\,t}X_2^tAX_2\vec{\hat{\beta}}_2 + \vec{e}^{\,t}\vec{e}$
2. SCT = SCR + SCE

ANOVA $\rightarrow$ Análisis de la varianza donde se estudia la significación global del modelo donde[13]:

$$\begin{cases} H_0 : \beta_2 = \beta_3 = \ldots = \beta_k = 0 \\ H_1 : \exists \beta_i \neq 0 \text{ con } i = 2, 3, \ldots, k \end{cases} \qquad F_{exp} = \frac{SCE/k-1}{SCR/n-k} \quad \text{Se rechazará } H_0 \text{ si } F_{exp} > F_{k-1,n-k,1-\alpha} \tag{36}$$

2.9. Cota R^2

Se rechazará la hipótesis nula si $F_{exp} > F_{k-1,n-k,1-\alpha}$:

$$\frac{n-k}{k-1}\frac{R^2}{1-R^2} > F_{k-1,n-k,1-\alpha} \tag{37}$$

2.10. Predicción puntual

2.10.1. Para el valor individual

Suponiendo que tenemos permanencia estructural[14], podemos tomar como predictor para el valor medio y para el valor individual de la variable endógena:

$$\vec{x_0^t}\vec{\hat{\beta}} = \hat{y_0} = E[\widehat{y_0 \mid \vec{x_0}}]^{15} \tag{38}$$

Tenemos que:

- $E[e_0] = 0$[16]
- $var(e_0) = \sigma^2(1 + \vec{x_0^t}(X^tX)^{-1}\vec{x_0})$[17]

2.10.2. Para el valor esperado

$e_0^* \sim N(0, \sigma^2(1 + \vec{x_0^t}(X^tX)^{-1}\vec{x_0}))$[18]

[13] Para un extra se puede mirar la diapositiva 24/34 del tema 3

[14] En este contexto, la permanencia estructural se refiere a la estabilidad de los parámetros del modelo a lo largo del tiempo. El proceso de generación de los datos para la nueva observación $\vec{x_0}$ es el mismo que ha generado la infromación muestral

[15] El predictor mínimo cuadrático es lineal, insesgado y óptimo

[16] La demostración se encuentra en la diapositiva 27/34 del tema 3

[17] La demostración se encuentra en la diapositiva 28/34 del tema 3

[18] La demostración se encuentra en la diapositiva 29/34 del tema 3

2.10.3. Por intervalo

- Intervalo de confianza para el valor individual y_0:

$$IC_{y_0} = \hat{y_0} \pm t_{n-k,1-\frac{\alpha}{2}} \sqrt{\hat{\sigma}^2(1 + \vec{x_0^t}(X^tX)^{-1}\vec{x_0})} \tag{39}$$

Teniendo en cuanta que podemos sacar el sigma de raíz y de que $\hat{y_0} = \vec{x_0^t}\vec{\hat{\beta}}$, nos queda:

$$IC_{y_0} = \vec{x_0^t}^{19}\vec{\hat{\beta}} \pm t_{n-k,1-\frac{\alpha}{2}} \hat{\sigma}\sqrt{1 + \vec{x_0^t}(X^tX)^{-1}\vec{x_0}} \tag{40}$$

- Intervalo de confianza para el valor esperado $E[y_0 \mid \vec{x_0}]$:

$$IC_{E[y_0|\vec{x_0}]} = \vec{x_0^t}\vec{\hat{\beta}} \pm t_{n-k,1-\frac{\alpha}{2}} \hat{\sigma}\sqrt{\vec{x_0^t}(X^tX)^{-1}\vec{x_0}} \tag{41}$$

2.11. Construcción de las distribuciones

2.11.1. Distribución χ^2 de Pearson

Suma de los cuadrados de n variables aleatorias independientes e idénticamente distribuidas que siguen una distribución normal estándar[20].

$$\chi_n^2 = \sum_{i=1}^{n} X_i^2 \quad \text{donde } X_i \sim N(0,1) \quad \forall i \tag{42}$$

- No simétrica
- No negativa
- No acotada
- Su media es n y su varianza es $2n$

2.11.2. Distribución t de Student

Cociente entre una variable aleatoria normal estándar y la raíz cuadrada de una χ^2 de Pearson dividida por sus grados de libertad, siendo ambas independientes.

$$t_n = \frac{Z}{\sqrt{\frac{X}{n}}} \quad \text{donde } Z \sim N(0,1) \text{ e } X \sim \chi_n^2 \tag{43}$$

- Simétrica
- Para n>30 se puede aproximar a una normal

[19] Este término se refiere, por simplicidad, a algún punto en específico, es decir, en la práctica corresponde con unos valores que nos da el enunciado para sacar el IC en base a esos valores.

[20] $N(0,1)$

- Su media es 0
- Su varianza es $\frac{n}{n-2}$
- Acotada

2.11.3. Distribución F de Fisher-Snedecor

Cociente entre dos χ^2 de Pearson divididas por sus grados de libertad, siendo ambas independientes.

$$F_{m,n} = \frac{X_1/m}{X_2/n} \quad \text{donde } X_1 \sim \chi^2_m \text{ e } X_2 \sim \chi^2_n \tag{44}$$

- No simétrica
- $F_{m,n,1-\alpha} = \frac{1}{F_{n,m,\alpha}}$
- $t^2_n = F_{1,n}$

3 Tema 4: Multicolinealidadad

3.1. Concepto

Existencia de relaciones entre dos o más variables independientes del modelo lineal uniecuacional múltiple.

3.2. Clasificación

- **Multicolinealidadad exacta:** Existencia de una relación exacta entre dos o más variables independientes. Las **causas** son básicamente el incumplimientos de una de las hipótesis del modelo uniecuacional múltiple, la matriz X no es de rango completo por columnas: $\mathtt{rango}(X) < k$. Esto tiene como **consecuencias** que no se pueda invertir la matriz X^tX y que no se pueda estimar el modelo, haciendo que el sistema sea indeterminado y por ende, no haya una solución única para $\hat{\beta}$, sino que haya infinitas soluciones.
- **Multicolinealidadad aproximada:** Existencia de una relación aproximada entre dos o más variables independientes. Las causas son:
  - relación causal entre las variables explicativas del modelo.
  - escasa variabilidad de las observaciones.
  - tamaño de la muestra pequeño.

3.2.1. Clasificaciones de la multicolinealidadad aproximada

- Según *Spanos y McGuirk*:
  - Sistemática: alta correlación lineal entre las variables exógenas.
  - Errática: mal condicionamiento de los datos considerados.
- Según *Marquardt y Snee*:
  - No esencial: relacion lineal de las variables exógenas, incluyendo la constante.
  - Esencial: relación lineal de las variables exógenas sin incluir la constante.

  Las **consecuencias** de la multicolinealidadad aproximada son:
  - En este caso si se puede invertir la matriz X^tX, pero el determinante de la matriz es muy pequeño, lo que hace que la varianza de los estimadores sea muy grande, lo que hace que los estimadores sean poco precisos.
  - Contrastes individuales no rechazaran la hipótesis nula y los globales si.
  - Coeficientes estimados serán sensibles a pequeñas variaciones en los datos.
  - Coeficiente de determinación alto.

3.3. Factor de inflación de la varianza

Sirve para detectar el grado de multicolinealidadad de las variables, se define como:

$$FIV_i = \frac{1}{1 - R_i^2} \quad i = 2, 3, \ldots, p \tag{45}$$

Si esta medida es superior a 10, se considera que hay multicolinealidadad de grado preocupante. Al no tener en cuenta la relación de las varibales exógenes con la constante no detecta si hay multicolinealidadad no esencial.

Nota: No detecta la multicolinealidadad entre variables cualitaticas ni dicotómicas.

3.4. Número de condición

Se define como:

$$\text{Número de condición} = \sqrt{\frac{\lambda_{max}}{\lambda_{min}}} \tag{46}$$

Donde λ_{max} y λ_{min} son los autovalores máximos y mínimos de la matriz X^tX.Si el número de condición alcanza valores superiores a 20 es moderado y si el número de condición es mayor que 30, se considera que hay multicolinealidadad de grado preocupante. *En este caso si tiene en cuenta la relación de las variables exógenas con la constante.*

3.5. Otras Medidas

3.5.1. Matriz de Correlaciones (R)

Ignora la constante y solo es capaz de detectar la multicolinealidad aproximada del tipo esencial dos a dos.

3.5.2. Determinante de la matriz de correlaciones *det(R)*

Sigue ignorando la relación con la constante, por lo que solo detecta la multicolinealidad aproximada del tipo esencial. En este caso valores cercanos a 0 indican un caso preocupante.

3.5.3. Coeficiente de variación de las variables explicativas

Detectar una escasa variabilidad de las observaciones, lo que puede ser una causa de la multicolinealidad aproximada del tipo no esencial.

3.6. Soluciones

- Mejora del diseño de la investigación, extrayendo información máxima de las variables observadas.
- Eliminación de variables redundantes o que sean sospechosas en cuanto a las causantes de la multicolinealidad.
- Aumentar el tamaño de la muestra.
- Utilizar la relación extramuestral entre las variables, es decir, utilizar información de otras fuentes.