

UNIVERSIDAD DE GRANADA

Visión por Computador

Temario y Cuestiones de Examen — Temas 1 y 2

Ismael Sallami Moreno

Recursos Ingeniería Informática y Ade

Licencia

Este trabajo está bajo una Licencia Creative Commons BY-NC-ND 4.0.

Permisos: Se permite compartir, copiar y redistribuir el material en cualquier medio o formato.

Condiciones: Es necesario dar crédito adecuado, proporcionar un enlace a la licencia e indicar si se han realizado cambios. No se permite usar el material con fines comerciales ni distribuir material modificado.



Visión por Computador

Ismael Sallami Moreno

https://elblogdeismael.github.io

Índice general

1 Introducción y Fundamentos de la Visión por Computador **7**

1.1 Tema 1: Concepto, Disciplinas Afines y Estado del Arte **7**

2 Representación, Filtrado Espacial y Detección de Bordes **13**

2.1 Tema 2: Fundamentos del Procesado Bidimensional y Operadores Diferenciales **13**

3 Cuestiones y Problemas Resueltos **21**

3.1 Tema 2: Representación, Filtrado Espacial y Detección de Bordes **21**

Capítulo 1

Introducción y Fundamentos de la Visión por Computador

1.1 Tema 1: Concepto, Disciplinas Afines y Estado del Arte

La visión por computador constituye una de las disciplinas troncales de la inteligencia artificial. Su propósito formal consiste en dotar a sistemas computacionales de la capacidad de interpretar, modelar y reconstruir el mundo físico tridimensional a partir de señales visuales bidimensionales o secuencias de vídeo. Como señalan Russell y Norvig (2021), la visión no representa un módulo aislado, sino un componente indispensable para superar el test de Turing completo en entornos físicos, ya que exige interacción perceptiva directa con objetos y personas.

Desde una perspectiva operativa, el procesamiento visual invierte el flujo clásico de la computación gráfica. Mientras los gráficos por computador transforman representaciones geométricas y propiedades de iluminación en proyecciones bidimensionales de píxeles, la visión por computador se enfrenta al problema inverso: reconstruir la física, la geometría y el significado semántico de la escena a partir de una matriz discreta de mediciones ópticas.

1.1.1 1. Definición Formal y Modelos Jerárquicos

Diversos autores canónicos han delimitado el alcance de la disciplina:

- **Richard Szeliski (2022):** Define la visión computacional como el intento de describir el mundo observado en una o varias imágenes y reconstruir sus propiedades intrínsecas, tales como la forma volumétrica, las fuentes de iluminación y las distribuciones espectrales de color.
- **Milan Sonka, Vaclav Hlavac y Roger Boyle (2015):** Enfatizan el objetivo de duplicar las capacidades del sistema visual biológico mediante la percepción electrónica y la comprensión semántica de escenas del mundo real.
- **David Forsyth y Jean Ponce (2012):** Describen la disciplina como la aplicación de métodos estadísticos, geométricos y de teoría del aprendizaje para desenredar los datos ópticos y extraer descripciones estructuradas del mundo.

Niveles de Procesamiento Visual

Para estructurar la complejidad de las tareas, la literatura establece una jerarquía en función del nivel de abstracción representacional. Siguiendo la taxonomía clásica de Gonzalez y Woods (2018),

contrastada con los esquemas de Forsyth y Ponce (2012) y Sonka et al. (2015), distinguimos tres estratos bien diferenciados:

1. **Bajo Nivel (*Low-Level Vision* o *Early Vision*):** Las operaciones toman como entrada imágenes matriciales y devuelven como salida imágenes procesadas. Carecen de conocimiento contextual semántico sobre el contenido. Incluye el preprocesamiento para reducción de ruido, realce de contraste, operaciones morfológicas, transformaciones en el dominio de la frecuencia y detección de bordes primitivos.
2. **Nivel Medio (*Mid-Level Vision*):** La entrada sigue siendo una señal visual, pero la salida consiste en atributos y entidades estructuradas extraídas de los píxeles (esquinas, contornos continuos, regiones homogéneas o identidades preliminares). Comprende la segmentación semántica, el seguimiento de trayectorias (*tracking*), el emparejamiento de características locales y el agrupamiento perceptual.
3. **Alto Nivel (*High-Level Vision* o *Image Understanding*):** Opera sobre las representaciones intermedias para dotar de significado semántico al conjunto de elementos detectados, emulando procesos cognitivos complejos. Agrupa el reconocimiento y categorización de objetos, la estimación de posturas humanas, el registro volumétrico de imágenes, la navegación autónoma y el razonamiento visual compositivo.

1.1.2 2. Disciplinas Conexas y Límites Epistemológicos

El análisis visual converge en una intersección multidisciplinar donde conviven cuatro ramas del conocimiento:

- **Procesamiento Digital de Imágenes (*Digital Image Processing*):** Se centra en la manipulación de la señal de imagen para mejorar su calidad para observación humana o prepararla para almacenamiento y transmisión eficiente (filtrado, restauración, compresión JPEG).
- **Gráficos por Computador (*Computer Graphics*):** Proceso directo (*forward model*) que parte de modelos 3D matemáticos, cámaras virtuales y parámetros de reflectancia para sintetizar matrices de píxeles realistas.
- **Visión por Computador (*Computer Vision*):** Proceso inverso (*inverse problem*) que toma las matrices de intensidad captadas por sensores físicos e infiere las configuraciones 3D, propiedades de los materiales y relaciones funcionales.
- **Reconocimiento de Patrones y Aprendizaje Automático (*Pattern Recognition / Machine Learning*):** Proporciona el marco probabilístico, algebraico y estadístico para inferir modelos de decisión a partir de vectores de características visuales o directamente de tensores de datos crudos (*end-to-end*).

1.1.3 3. Las Dos Grandes Vertientes Metodológicas

A lo largo del curso y de la práctica investigadora contemporánea, la visión por computador se estructura en dos aproximaciones complementarias:

- **La Vertiente Geométrica (Modelado Físico y Proyectivo):** Se apoya en la geometría proyectiva, la óptica física y la estimación lineal y robusta. Formula la relación entre el espacio euclídeo $\mathbb{R}^3$ y el plano sensor $\mathbb{R}^2$ mediante coordenadas homogéneas y matrices de proyección de cámara. Resuelve problemas fundamentales como la geometría epipolar (matriz esencial

E y matriz fundamental F), la reconstrucción tridimensional a partir de múltiples vistas (*Structure from Motion*, SfM), el ajuste de haces (*Bundle Adjustment*) y la estimación robusta con RANSAC.

- **La Vertiente de Aprendizaje (*Data-Driven Vision*):** Trata de inferir patrones visuales a partir de grandes volúmenes de datos empíricos. Abarca desde los clasificadores clásicos basados en descriptores artesanales (*handcrafted features* como SIFT, HOG o LBP) combinados con SVM o árboles de decisión, hasta los paradigmas modernos de aprendizaje profundo:
  - *Supervised Learning:* Entrenamiento supervisado con etiquetas densas (*bounding boxes*, máscaras de segmentación).
  - *Self-Supervised Learning:* Extracción de representaciones visuales invariantes a partir de secuencias de vídeo o tareas pretextuales sin supervisión humana directa.
  - *Fine-Tuning y RLHF:* Ajuste supervisado y alineación con refuerzo humano para modelos multimodales visión-lenguaje (VLMs).
  - *Modelos Generativos:* Difusión probabilística y redes antagónicas (GANs) para síntesis y restauración visual.

Un elemento determinante en el éxito contemporáneo de la vertiente de aprendizaje ha sido la disponibilidad de conjuntos de datos masivos. Mientras ImageNet (Deng et al., 2009) supuso la chispa del aprendizaje profundo convolucional con más de 14 millones de imágenes anotadas, conjuntos a escala de internet como LAION-5B (Schuhmann et al., 2022), con más de 5.800 millones de pares de imagen y texto, han permitido el entrenamiento de modelos fundacionales multimodales capaces de generalización visual de disparo cero (*zero-shot*).

1.1.4 4. Por Qué la Visión por Computador es un Problema Difícil

Para los seres humanos, la visión resulta intuitiva y aparentemente inmediata, pues más del 50 % de la corteza cerebral de los primates está involucrada directa o indirectamente en el procesamiento visual. Sin embargo, en términos computacionales se trata de un problema formalmente mal condicionado (*ill-posed inverse problem*).

1. **Pérdida de Dimensionalidad (Ambigüedad 3D a 2D):** La proyección de una escena tridimensional sobre una superficie sensora bidimensional destruye la coordenada de profundidad. Infinitas configuraciones tridimensionales de distinta escala y distancia pueden proyectar exactamente la misma configuración de intensidades sobre la imagen (el principio del trampantojo o las ilusiones anamórficas de Ames).
2. **Variabilidad Fotométrica y de Iluminación:** El valor registrado en cada píxel es el producto de la radiancia de la fuente de luz incidente por la función de reflectancia bidireccional (BRDF) de la superficie del material. Variaciones en la posición del foco solar, sombras arrojadas o reflexiones especulares alteran los valores RGB de un mismo objeto de forma mucho más drástica que un cambio radical de categoría.
3. **Variabilidad Geométrica y de Punto de Vista:** La pose de la cámara respecto al objeto introduce rotaciones fuera del plano, deformaciones afines y distorsiones de perspectiva que desalinean por completo la disposición de las intensidades en la matriz.
4. **Oclusión Parcial y Desorden de Fondo (*Clutter*):** En entornos naturales, los objetos raras veces aparecen aislados sobre fondos planos. Frecuentemente se intersecan, quedan parcialmente ocultos por otros elementos o presentan texturas indistinguibles de los patrones de fondo.

5. **Variabilidad Intra-Clase y Deformabilidad:** Objetos pertenecientes a la misma categoría semántica (por ejemplo, sillas o animales) presentan una infinita variabilidad de formas, colores, dimensiones y configuraciones cinemáticas no rígidas.

1.1.5 5. Hitos Históricos Fundamentales

La disciplina ha transitado por diversas etapas conceptuales desde sus inicios a mediados del siglo XX:

- **1966 — El Proyecto de Verano de Marvin Minsky (MIT):** Al inicio de la IA, Minsky encargó al estudiante de grado Gerald Sussman *"conectar una cámara a un ordenador y hacer que describiera lo que veía"* como proyecto de verano de unas diez semanas. La anécdota ilustra cómo se subestimó profundamente la complejidad de la percepción biológica y la visión de bajo nivel.
- **Década de 1970 — El Mundo de los Bloques y Procesado Primitivo:** Investigaciones centradas en entornos sintéticos controlados (*blocks world* de Roberts) y extracción de aristas lineales mediante operadores heurísticos (Roberts, Sobel, Prewitt).
- **1982 — El Paradigma Computacional de David Marr:** Marr publica su obra seminal *Vision*, proponiendo que la visión es un sistema de procesamiento de información estructurado en tres niveles (computacional, algorítmico y de implementación física) que transita secuencialmente desde el esbozo primario (*primal sketch*), pasando por el esbozo 2.5D (orientación de superficies y profundidad relativa centrada en el observador), hasta el modelo 3D centrado en el objeto.
- **Décadas de 1980 y 1990 — Madurez Geométrica y Filtros Óptimos:** Formulación del detector de bordes óptimo de Canny (1986), espacios de escala (*scale-space theory*) de Witkin y Koenderink, la Laplaciana de Gaussiana y la consolidación de la visión multivista con Hartley, Zisserman y Faugeras.
- **Años 2000 — Ingeniería de Características Locales Robustas:** Aparición de detectores invariantes a escala y rotación como SIFT (Lowe, 2004), SURF y descriptores de gradientes orientados HOG (Dalal y Triggs, 2005), combinados con modelos de bolsas de palabras visuales (*Bag of Visual Words*) y el detector en tiempo real de Viola-Jones (2001) para caras.
- **2012 — La Revolución del Aprendizaje Profundo (AlexNet):** Krizhevsky, Sutskever y Hinton reducen drásticamente el error de clasificación en el reto ImageNet mediante una red convolucional profunda entrenada en GPUs, desplazando los enfoques artesanales por representaciones aprendidas directamente de los datos.
- **Actualidad — Modelos Fundacionales y Transformers Visuales:** Generalización de arquitecturas Vision Transformer (ViT), modelos multimodales contrastivos (CLIP), modelos de segmentación universales (Segment Anything - SAM) y modelos generativos de difusión probabilística.

1.1.6 6. Limitaciones Contemporáneas y Retos Abiertos

A pesar de que los modelos modernos superan con frecuencia el rendimiento medio humano en tareas cerradas y específicas de laboratorio (como la clasificación a 1.000 clases de ImageNet), presentan fragilidades estructurales cuando se enfrentan a situaciones reales:

1. **Inconsistencia de Sentido Común Físico:** Los modelos actuales carecen de un modelo intuitivo del mundo físico (gravedad, soporte, permanencia de los objetos, masa o fricción). Se

basan en correlaciones estadísticas de alta dimensión y pueden segmentar un objeto flotando en el vacío o predecir interpenetraciones de materia que violan las leyes físicas elementales.

2. **Vulnerabilidad ante Ataques Adversarios (*Adversarial Perturbations*):** Modificaciones imperceptibles para el ojo humano añadidas a una imagen pueden inducir a una red neuronal profunda a clasificar un vehículo escolar como un avestruz con una certidumbre superior al 99 %, demostrando que las representaciones neuronales difieren notablemente de los mecanismos perceptivos de la corteza biológica.
3. **Dependencia Extrema de Datos y Huella Energética:** El entrenamiento de redes profundas requiere millones de muestras etiquetadas y consumos energéticos considerables. Un ser humano es capaz de asimilar un concepto visual nuevo con uno o dos ejemplos (*few-shot learning*), mientras que un modelo de visión suele necesitar miles de iteraciones de optimización.
4. **Opacidad y Falta de Interpretabilidad (*Black-Box*):** En aplicaciones críticas como el diagnóstico biomédico o la conducción autónoma, la ausencia de trazabilidad explicativa dificulta garantizar el comportamiento del sistema ante condiciones de fallo o distribuciones no vistas (*out-of-distribution*).
5. **Sesgos Algorítmicos y Alucinaciones:** Los modelos replican y amplifican los sesgos sociodemográficos, geográficos y culturales presentes en los datos masivos de internet. Asimismo, los modelos generativos y los decodificadores visuales modernos pueden inventar texturas o detalles inexistentes (*alucinaciones visuales*), comprometiendo su uso en contextos periciales y forenses.

Capítulo 2

Representación, Filtrado Espacial y Detección de Bordes

2.1 Tema 2: Fundamentos del Procesado Bidimensional y Operadores Diferenciales

El presente capítulo aborda los principios matemáticos y algorítmicos que gobiernan la manipulación de la señal de imagen en el dominio espacial. Comprende desde la naturaleza física de la formación de la imagen y su discretización digital, pasando por la teoría del filtrado lineal y no lineal, hasta los operadores de gradiente y el detector de bordes óptimo de Canny.

2.1.1 1. Formación y Representación de la Imagen Digital

Una imagen en el plano continuo puede modelarse como una función bidimensional de intensidad lumínica $f(x, y)$, donde (x, y) denotan las coordenadas espaciales en el plano de proyección y el valor escalar $f(x, y)$ representa la irradiancia o energía luminosa por unidad de área recibida por el sensor.

Desde el punto de vista radiométrico, la energía captada en cada punto de la escena viene determinada por dos componentes primordiales:

$$f(x, y) = i(x, y) \cdot r(x, y)$$

donde $i(x, y) \in (0, \infty)$ representa la componente de iluminación incidente procedente de las fuentes luminosas del entorno, y $r(x, y) \in [0, 1]$ es el coeficiente de reflectancia intrínseco de los materiales de la superficie observada.

Muestreo y Cuantización

Para su procesamiento en arquitecturas digitales, la señal continua $f(x, y)$ debe someterse a dos etapas sucesivas de discretización:

1. **Muestreo Espacial (*Sampling*):** Discretización de las coordenadas espaciales (x, y) sobre una rejilla regular de $M \times N$ elementos, dando lugar a los píxeles (*picture elements*). Si el periodo de muestreo no cumple el teorema de Nyquist-Shannon respecto a las frecuencias espaciales más altas de la escena óptica, se producen artefactos de solapamiento espectral (*aliasing*).

2. **Cuantización de Amplitud (*Quantization*):** Mapeo del rango continuo de irradiancia a un conjunto finito de L niveles discretos. Habitualmente se emplean representaciones de 8 bits por canal ($L = 2^8 = 256$, en el rango entero $[0, 255]$), o representaciones normalizadas en coma flotante $\in [0{,}0, 1{,}0]$.

En imágenes multicanal o a color, la señal se representa mediante una función vectorial:

$$\mathbf{I}(x, y) = \begin{bmatrix} I_R(x, y) \\ I_G(x, y) \\ I_B(x, y) \end{bmatrix}$$

La conversión estándar a escala de grises combina los canales ponderando la sensibilidad fototópica de la fóvea humana según la recomendación ITU-R BT.601:

$$Y(x, y) = 0{,}299 \cdot I_R(x, y) + 0{,}587 \cdot I_G(x, y) + 0{,}114 \cdot I_B(x, y)$$

2.1.2 2. Filtrado Espacial Lineal: Correlación y Convolución

El filtrado en el dominio espacial consiste en sustituir el valor de cada píxel de la imagen de entrada por una combinación ponderada de las intensidades de sus píxeles vecinos dentro de una ventana de soporte local. La matriz de ponderaciones que define los coeficientes de dicha ventana recibe el nombre de máscara, filtro o *kernel* h de tamaño $(2k + 1) \times (2k + 1)$.

*Correlación Cruzada (*Cross-Correlation*)*

La correlación cruzada bidimensional desplaza directamente el kernel h sobre la imagen I sin modificar la orientación relativa de sus índices:

$$(I \otimes h)(x, y) = \sum_{u=-k}^{k} \sum_{v=-k}^{k} I(x + u, y + v)\, h(u, v)$$

La correlación cruzada mide el grado de coincidencia o similitud local entre la estructura del kernel y el vecindario del píxel. Se emplea extensamente en técnicas de emparejamiento de plantillas (*template matching*). Sin embargo, la correlación carece de la propiedad asociativa y conmutativa respecto a la combinación sucesiva de filtros.

*Convolución Lineal Bidimensional (*Convolution*)*

La convolución lineal invierte espacialmente el kernel en ambos ejes coordenados (equivalente a una rotación de 180°) antes de calcular el producto escalar ponderado:

$$(I * h)(x, y) = \sum_{u=-k}^{k} \sum_{v=-k}^{k} I(x - u, y - v)\, h(u, v) = \sum_{u=-k}^{k} \sum_{v=-k}^{k} I(x + u, y + v)\, h(-u, -v)$$

La inversión de índices dota a la convolución de propiedades algebraicas fundamentales en el análisis de sistemas lineales e invariantes a la traslación (LTI):

- **Conmutatividad:** $I * h = h * I$.
- **Asociatividad:** $I * (h_1 * h_2) = (I * h_1) * h_2$. Permite prefusionar múltiples filtros en un único kernel equivalente mediante $h_{eq} = h_1 * h_2$, reduciendo el coste computacional.
- **Distributividad respecto a la suma:** $I * (h_1 + h_2) = (I * h_1) + (I * h_2)$.
- **Equivariancia ante traslación:** Si T_Δ es un operador de desplazamiento espacial puro tal que $T_\Delta(I)(x, y) = I(x - x_0, y - y_0)$, entonces $T_\Delta(I * h) = (T_\Delta I) * h$.

Tratamiento de Condiciones de Frontera

Al evaluar la convolución cerca de los bordes exteriores de la matriz de tamaño $M \times N$, el soporte del kernel sobresale de las dimensiones válidas de la imagen. Existen cuatro estrategias analíticas para resolver estas discontinuidades de frontera:

1. **Relleno con ceros (*Zero Padding*):** Asume que todos los píxeles fuera del dominio de la imagen tienen intensidad nula. Introduce una caída artificial de energía que oscurece el perímetro de la imagen filtrada.
2. **Replicación de borde (*Clamp / Border Replicate*):** Extiende el valor del píxel frontera más próximo de forma constante. Evita contrastes bruscos espurios.
3. **Reflexión o Simetría (*Reflect / Mirroring*):** Refleja la señal hacia el interior en torno al eje de la frontera. Preserva la continuidad de las derivadas de primer orden y minimiza artefactos de alta frecuencia.
4. **Periódica o Toroidal (*Wrap around*):** Conecta el borde superior con el inferior y el izquierdo con el derecho. Es la condición implícita en la convolución circular mediante la Transformada Rápida de Fourier (FFT).

2.1.3 3. Filtros Lineales de Suavizado: Box Filter frente al Filtro Gaussiano

El suavizado espacial (*smoothing*) tiene por objeto atenuar las fluctuaciones rápidas debidas a ruido aditivo independiente, actuando como un filtro paso bajo (*low-pass filter*).

Filtro de Media (*Box Filter*)

El filtro de caja asigna ponderaciones uniformes a todas las posiciones del vecindario dentro de un soporte $K \times K$:

$$h_{\text{box}}(u, v) = \frac{1}{K^2}, \quad \forall (u, v) \in \left[-\frac{K-1}{2}, \frac{K-1}{2} \right]^2$$

Aunque resulta computacionalmente trivial, presenta dos desventajas analíticas graves: - Asigna el mismo peso a un píxel contiguo al centro que a un píxel ubicado en los vértices del vecindario. - Su respuesta en el dominio frecuencial es una función sinc bidimensional ($\text{sinc}(u)\text{sinc}(v)$), caracterizada por lóbulos secundarios prominentes que introducen frecuencias espurias y artefactos visuales en forma de bandas rectangulares (*ringing* y efecto de cuadrícula).

El Filtro Gaussiano y sus Propiedades Analíticas

La función gaussiana continua bidimensional isotrópica centrada en el origen se formula como:

$$G_\sigma(x,y) = \frac{1}{2\pi\sigma^2}\exp\left(-\frac{x^2+y^2}{2\sigma^2}\right)$$

donde σ es la desviación típica que parametriza la escala o anchura efectiva del filtro. Sus propiedades distintivas son:

- **Isotropía (Simetría Circular):** La respuesta depende exclusivamente de la distancia euclídea al origen $r = \sqrt{x^2+y^2}$. Suaviza con igual intensidad en todas las direcciones del plano.
- **Respuesta Frecuencial Óptima:** La transformada de Fourier de una gaussiana en el espacio es otra gaussiana en la frecuencia. Carece de lóbulos secundarios, lo que garantiza que no introduce artefactos oscilatorios ni altas frecuencias espurias.
- **Teorema de Convolución de Gaussianas:** La convolución sucesiva de dos filtros gaussianos con parámetros σ_1 y σ_2 equivale a aplicar una única gaussiana con varianza acumulada:

$$G_{\sigma_1} * G_{\sigma_2} = G_{\sqrt{\sigma_1^2+\sigma_2^2}}$$

- **Separabilidad Computacional:** La función gaussiana bidimensional se descompone en el producto exacto de dos gaussianas unidimensionales independientes:

$$G_\sigma(x,y) = \left(\frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{x^2}{2\sigma^2}\right)\right)\cdot\left(\frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{y^2}{2\sigma^2}\right)\right) = G_\sigma(x)\cdot G_\sigma(y)$$

  En virtud de la asociatividad de la convolución:

$$I * G_\sigma(x,y) = (I * G_\sigma(x)) * G_\sigma(y)$$

  Esta descomposición reduce la complejidad algorítmica de aplicar un kernel de $K\times K$ píxeles de $O(K^2)$ operaciones por píxel a tan solo $O(2K)$, permitiendo aceleraciones de más de un orden de magnitud en kernels medianos y grandes.

Para discretizar el kernel en una matriz de tamaño $(2k+1)\times(2k+1)$, se trunca habitualmente el soporte a una distancia de $k = \lceil 3\sigma \rceil$, abarcando el 99,73 % de la masa probabilística, y se normalizan los coeficientes resultantes dividiendo entre la suma total para garantizar ganancia unitaria en continua (preservación del nivel medio de iluminación).

2.1.4 4. Filtros No Lineales y Transformaciones Estadísticas

Cuando el ruido de la imagen no es de naturaleza gaussiana aditiva, los operadores lineales no consiguen desacoplar el ruido de las aristas genuinas.

Filtro de Mediana (*Median Filter*)

El filtro de mediana sustituye el píxel central por el valor mediano estadístico de las intensidades contenidas en su ventana local:

$$I_{\text{med}}(x,y) = \text{mediana}\left(\{I(x+u, y+v) \mid -k \leq u, v \leq k\}\right)$$

Es especialmente efectivo frente a ruido de tipo impulso (*sal y pimienta*). Debido a que la mediana es un estimador estadístico robusto de orden, descarta valores extremos atípicos sin promediarlos, preservando con gran fidelidad la nitidez de los bordes rectilíneos y contrastados.

Umbralización Óptima: Algoritmo de Otsu

La umbralización global (*thresholding*) segmenta una imagen I en dos clases (fondo y primer plano) mediante un valor de corte T:

$$B(x,y) = \begin{cases} 1 & \text{si } I(x,y) \geq T \\ 0 & \text{si } I(x,y) < T \end{cases}$$

El algoritmo de Otsu (1979) calcula de forma analítica el umbral óptimo T^* maximizando la varianza entre clases $\sigma_B^2(T)$, o equivalentemente minimizando la varianza intraclase $\sigma_W^2(T)$:

$$\sigma_B^2(T) = \omega_0(T)\omega_1(T)[\mu_0(T) - \mu_1(T)]^2$$

donde $\omega_0(T)$ y $\omega_1(T)$ son las probabilidades acumuladas de cada clase bajo el histograma normalizado, y $\mu_0(T), \mu_1(T)$ son sus medias respectivas. Este criterio no requiere parámetros heurísticos y converge evaluando directamente las frecuencias acumuladas del histograma.

2.1.5 5. Detección de Bordes y Operadores Diferenciales

Un borde o arista (*edge*) en una imagen se define como una discontinuidad local significativa en la función de intensidad luminosa, originada comúnmente por saltos de profundidad geométrica, cambios en la orientación normal de la superficie o variaciones en la reflectancia del material.

Operadores de Gradiente de Primer Orden

Para una función continua $f(x,y)$, el gradiente espacial es un campo vectorial bidimensional orientado en la dirección de máxima variación de intensidad:

$$\nabla f(x,y) = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix}$$

En el dominio discreto de la imagen digital, las derivadas parciales se aproximan mediante diferencias finitas: - Diferencia hacia adelante: $\frac{\partial I}{\partial x} \approx I(x+1,y) - I(x,y)$ - Diferencia centrada: $\frac{\partial I}{\partial x} \approx \frac{I(x+1,y) - I(x-1,y)}{2}$

Los núcleos de derivación combinan la diferenciación en un eje con el suavizado en el eje ortogonal para amortiguar el ruido:

– **Filtro de Sobel (3x3):**

$$S_x = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix}, \quad S_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ +1 & +2 & +1 \end{bmatrix}$$

El operador de Sobel es separable en el producto de una máscara de suavizado binomial $[1, 2, 1]^T$ y un operador de diferencia finita centrada $[-1, 0, 1]$.

A partir de los mapas de respuesta $g_x = I * S_x$ y $g_y = I * S_y$, se obtienen la magnitud escalar y el ángulo de orientación del gradiente en cada píxel:

$$M(x, y) = \|\nabla I(x, y)\| = \sqrt{g_x^2(x, y) + g_y^2(x, y)}$$

$$\theta(x, y) = \text{atan2}(g_y(x, y), g_x(x, y)) \in [-\pi, \pi]$$

La magnitud mide la fuerza del contraste local, mientras que $\theta(x, y)$ es el vector normal ortogonal a la dirección tangente a lo largo del contorno del borde.

Operadores de Segundo Orden: La Laplaciana y Laplaciana de Gaussiana (LoG)

La Laplaciana es un operador diferencial isotrópico de segundo orden definido como la divergencia del gradiente:

$$\nabla^2 f(x, y) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

Los puntos donde se localizan los máximos de pendiente en la función de intensidad corresponden a los cruces por cero (*zero-crossings*) de la segunda derivada. No obstante, la diferenciación de segundo orden amplifica drásticamente el ruido de alta frecuencia. Por este motivo, David Marr y Ellen Hildreth (1980) propusieron prefilar la imagen con un núcleo gaussiano antes de aplicar el operador de Laplace:

$$\nabla^2 (I * G_\sigma) = I * (\nabla^2 G_\sigma)$$

El núcleo combinado resultante es la Laplaciana de Gaussiana (LoG), formulada como:

$$\text{LoG}_\sigma(x, y) = \nabla^2 G_\sigma(x, y) = \frac{1}{\pi \sigma^4} \left(\frac{x^2 + y^2}{2\sigma^2} - 1 \right) \exp\left(-\frac{x^2 + y^2}{2\sigma^2} \right)$$

Este filtro adopta el característico perfil de *"sombrero mexicano"* (*Mexican hat*). Asimismo, puede aproximarse de forma computacionalmente eficiente mediante la Diferencia de Gaussianas (DoG):

$$\text{DoG}(x, y) = G_{\sigma_1}(x, y) - G_{\sigma_2}(x, y) \approx (\sigma_1 - \sigma_2) \nabla^2 G_\sigma$$

2.1.6 6. El Detector de Bordes de Canny

John F. Canny formalizó en 1986 una formulación analítica de la detección de bordes a partir de tres criterios de optimalidad matemática:

1. **Baja Tasa de Error:** Debe detectar todas las aristas genuinas minimizando falsos positivos provocados por ruido y falsos negativos causados por contrastes débiles.
2. **Localización Exacta:** Los puntos detectados deben situarse lo más próximos posible al verdadero centro físico del borde.
3. **Respuesta Única:** No debe generar múltiples detecciones espurias adyacentes para una única transición física de borde (*aristas de un solo píxel de espesor*).

Para satisfacer estas condiciones de forma rigurosa, el algoritmo de Canny se ejecuta en cuatro fases secuenciales:

- **Fase 1: Suavizado Gaussiano:** La imagen de entrada se convoluciona con un filtro gaussiano de escala σ para eliminar componentes de ruido estocástico de alta frecuencia:

$$I_\sigma = I * G_\sigma$$

- **Fase 2: Cálculo del Gradiente:** Se aplican operadores diferenciales (habitualmente Sobel) para calcular las componentes ortogonales del gradiente g_x y g_y. Se obtienen la magnitud $M(x, y)$ y la dirección $\theta(x, y)$, cuantizando este ángulo en cuatro orientaciones discretas principales: horizontal (0°), diagonal principal (45°), vertical (90°) y diagonal secundaria (135°).
- **Fase 3: Supresión de No Máximos (*Non-Maximum Suppression*, NMS):** Para garantizar la respuesta única y reducir el espesor del contorno a un solo píxel, se examina si la magnitud $M(x, y)$ es un máximo local respecto a sus dos vecinos situados a lo largo de la dirección ortogonal al borde $\theta(x, y)$:

$$M_{\text{NMS}}(x, y) = \begin{cases} M(x, y) & \text{si } M(x, y) \geq M(x + d_x, y + d_y) \text{ y } M(x, y) \geq M(x - d_x, y - d_y) \\ 0 & \text{en caso contrario} \end{cases}$$

  Todos los píxeles que no superan a sus vecinos directos en la línea del gradiente se anulan a cero, produciendo crestas de arista perfectamente delgadas.
- **Fase 4: Umbralización con Histéresis y Conectividad (*Hysteresis Thresholding*):** Un único umbral global introduce aristas rotas si es demasiado alto o contornos ruidosos espurios si es demasiado bajo. Canny introduce dos umbrales complementarios, T_{alto} y T_{bajo} (habitualmente fijados en relación $T_{\text{alto}}/T_{\text{bajo}} \approx 2:1$ o $3:1$):
  - Los píxeles con magnitud $M_{\text{NMS}} \geq T_{\text{alto}}$ se declaran bordes firmes (*aristas fuertes*).
  - Los píxeles con $M_{\text{NMS}} < T_{\text{bajo}}$ se descartan definitivamente como ruido.
  - Los píxeles con $T_{\text{bajo}} \leq M_{\text{NMS}} < T_{\text{alto}}$ (*aristas débiles*) solo se aceptan como bordes legítimos si se encuentran conectados topológicamente (mediante vecindad de 8) con algún píxel perteneciente a una arista fuerte.

Capítulo 3

Cuestiones y Problemas Resueltos

3.1 Tema 2: Representación, Filtrado Espacial y Detección de Bordes

Este capítulo recoge la resolución analítica, matemática y conceptual de las cuestiones teóricas, problemas de diseño de kernels y baterías de autoevaluación planteadas al cierre del Tema 2 (dividido en los bloques 2.1 *Image Representation and Filtering* y 2.2 *Gaussian Filtering and Edges*) del programa oficial de Visión por Computador en la Universidad de Granada.

Las deducciones se fundamentan en el tratamiento formal del procesado de señal bidimensional y la teoría clásica de visión computacional, referenciando las obras canónicas de Szeliski (2022), Gonzalez y Woods (2018), Birchfield (2018) y los artículos seminales de Otsu (1979) y Canny (1986).

3.1.1 Bloque I: Cuestiones Teóricas sobre Filtros Lineales

Las siguientes cuestiones corresponden a los ejercicios propuestos en las diapositivas 118 y 119 del bloque temático 2.1.

CUESTIÓN 1: Equivariancia de la convolución frente a rotación y escalado

Enunciado:

¿Es la convolución equivariante frente a la rotación y frente al escalado?

Respuesta breve:

La convolución estándar **no** es equivariante a la rotación ni al escalado; únicamente lo es ante traslaciones. Para la rotación requeriría un kernel estrictamente isotrópico (como una Gaussiana circular), y para el escalado una adaptación dinámica del tamaño del filtro o el uso de pirámides multiescala.

Resolución analítica:

Un operador o transformación T es equivariante respecto a un grupo de transformaciones $g \in G$ si aplicar la transformación a la entrada y luego operar produce exactamente el mismo resultado que operar primero sobre la entrada y transformar posteriormente la salida:

$$T(g \cdot I) = g \cdot (T(I))$$

Analizamos cada caso por separado:

– **1. Equivariancia a la traslación (comportamiento de referencia)**

La convolución continua en $\mathbb{R}^2$ de una imagen $I(\mathbf{x})$ con un kernel $K(\mathbf{x})$ se define como:

$$(I * K)(\mathbf{x}) = \int_{\mathbb{R}^2} I(\boldsymbol{\tau})K(\mathbf{x} - \boldsymbol{\tau})\, d\boldsymbol{\tau}$$

Si aplicamos una traslación espacial pura $\mathbf{x}_0$, de modo que $I'(\mathbf{x}) = I(\mathbf{x} - \mathbf{x}_0)$, la respuesta del filtro es:

$$(I' * K)(\mathbf{x}) = \int_{\mathbb{R}^2} I(\boldsymbol{\tau} - \mathbf{x}_0)K(\mathbf{x} - \boldsymbol{\tau})\, d\boldsymbol{\tau}$$

Mediante el cambio de variable $\boldsymbol{\mu} = \boldsymbol{\tau} - \mathbf{x}_0$ ($d\boldsymbol{\mu} = d\boldsymbol{\tau}$):

$$(I' * K)(\mathbf{x}) = \int_{\mathbb{R}^2} I(\boldsymbol{\mu})K((\mathbf{x} - \mathbf{x}_0) - \boldsymbol{\mu})\, d\boldsymbol{\mu} = (I * K)(\mathbf{x} - \mathbf{x}_0)$$

La convolución es intrínsecamente equivariante ante traslaciones. El valor detectado se desplaza exactamente en la misma magnitud espacial que la escena de entrada.

– **2. Equivariancia a la rotación**

Sea R_θ una matriz ortogonal de rotación de ángulo θ en $\mathbb{R}^2$. Definimos la imagen rotada como $I_{rot}(\mathbf{x}) = I(R_\theta^{-1}\mathbf{x})$. Si convolucionamos esta imagen con el kernel estático K:

$$(I_{rot} * K)(\mathbf{x}) = \int_{\mathbb{R}^2} I(R_\theta^{-1}\boldsymbol{\tau})K(\mathbf{x} - \boldsymbol{\tau})\, d\boldsymbol{\tau}$$

Efectuando el cambio de variable $\boldsymbol{\mu} = R_\theta^{-1}\boldsymbol{\tau}$, donde $\boldsymbol{\tau} = R_\theta\boldsymbol{\mu}$ y el jacobiano satisface $|\det(R_\theta)| = 1$:

$$(I_{rot} * K)(\mathbf{x}) = \int_{\mathbb{R}^2} I(\boldsymbol{\mu})K(\mathbf{x} - R_\theta\boldsymbol{\mu})\, d\boldsymbol{\mu}$$

Por otra parte, si calculáramos la convolución sobre la imagen original y rotáramos posteriormente el mapa de salida resultante, obtendríamos:

$$[R_\theta(I * K)](\mathbf{x}) = (I * K)(R_\theta^{-1}\mathbf{x}) = \int_{\mathbb{R}^2} I(\boldsymbol{\mu})K(R_\theta^{-1}\mathbf{x} - \boldsymbol{\mu})\, d\boldsymbol{\mu}$$

Multiplicando el argumento de K por R_θ aprovechando la linealidad de la transformación:

$$K(R_\theta^{-1}\mathbf{x} - \boldsymbol{\mu}) = K(R_\theta^{-1}(\mathbf{x} - R_\theta\boldsymbol{\mu}))$$

Para que ambas expresiones coincidan para cualquier imagen I, es estrictamente necesario que:

$$K(\mathbf{x} - R_\theta\boldsymbol{\mu}) = K(R_\theta^{-1}(\mathbf{x} - R_\theta\boldsymbol{\mu})) \quad \forall\, \mathbf{x}, \boldsymbol{\mu}$$

Esto solo se cumple si el kernel es rotacionalmente invariante (isotrópico), es decir, dependiente exclusivamente del radio euclídeo $\|\mathbf{x}\|$ respecto al origen, como sucede en una Gaussiana circular $G(\mathbf{x}) = \frac{1}{2\pi\sigma^2}e^{-\frac{\|\mathbf{x}\|^2}{2\sigma^2}}$ o en un Laplaciano de Gaussiana (LoG).

Para cualquier kernel direccional común (como los operadores de Sobel, Prewitt, Gabor o derivadas orientadas), el kernel mantiene fija su orientación respecto al sistema de coordenadas de la matriz.

Si la imagen rota 45°, un detector horizontal continuará diferenciando filas horizontales en lugar de seguir la inclinación de la estructura rotada. En consecuencia, en el caso general la convolución **no es equivariante a la rotación**.

– **3. Equivariancia al escalado**

Sea una transformación de escala isotrópica por un factor escalar $s > 0$, de forma que $I_{esc}(\mathbf{x}) = I(s\mathbf{x})$. Al filtrar con un kernel de tamaño fijo K:

$$(I_{esc} * K)(\mathbf{x}) = \int_{\mathbb{R}^2} I(s\boldsymbol{\tau})K(\mathbf{x} - \boldsymbol{\tau})\, d\boldsymbol{\tau}$$

Con el cambio $\boldsymbol{\mu} = s\boldsymbol{\tau}$ ($d\boldsymbol{\tau} = s^{-2}d\boldsymbol{\mu}$):

$$(I_{esc} * K)(\mathbf{x}) = \frac{1}{s^2}\int_{\mathbb{R}^2} I(\boldsymbol{\mu})K\left(\mathbf{x} - \frac{\boldsymbol{\mu}}{s}\right)\, d\boldsymbol{\mu}$$

Sin embargo, filtrar primero y escalar después la respuesta generaría:

$$[S_s(I * K)](\mathbf{x}) = (I * K)(s\mathbf{x}) = \int_{\mathbb{R}^2} I(\boldsymbol{\mu})K(s\mathbf{x} - \boldsymbol{\mu})\, d\boldsymbol{\mu}$$

Ambas integrales difieren sustancialmente: el kernel K posee una huella de píxeles finita fija. Si reducimos la imagen a la mitad, los patrones visuales ocupan menos píxeles y el filtro cubrirá el doble de contexto semántico; si la ampliamos, cubrirá la mitad. Para mantener la equivariancia sería imperativo redimensionar dinámicamente el soporte y la varianza del propio filtro ($K_s(\mathbf{x}) = \frac{1}{s^2}K(\mathbf{x}/s)$).

Por tanto, con máscaras fijas, la convolución estándar **no es equivariante al escalado**. Esta limitación motivó históricamente la teoría del espacio-escala (*scale-space representation*) de Witkin y Lindeberg, así como las pirámides Gaussianas y Laplacianas.

CUESTIÓN 2: Equivalencia entre correlación cruzada y convolución rotando la salida

Enunciado:

¿Es la correlación equivalente a la convolución si rotamos su salida 180 grados? Es decir, ¿se cumple la igualdad:

$$rotate180(Correlation(I, K)) == Convolution(I, K)?$$

Respuesta breve:

No. Rotar la salida invierte todo el marco de coordenadas de la imagen resultante, lo que equivale a convolucionar la imagen original invertida. Para que la correlación sea idéntica a la convolución, lo que debe rotarse 180° es el **kernel** antes de operar ($I * K = I \otimes \mathrm{rot}_{180}(K)$).

Resolución analítica:

La respuesta matemática es **no**. Rotar la salida tras haber calculado la correlación no equivale a convolucionar la imagen original.

Analicemos las definiciones discretas bidimensionales centradas en el origen. Para simplificar la notación y sin pérdida de generalidad, consideramos dominios simétricos indexados por números enteros:

– **1. Correlación cruzada ($I \otimes K$):**

$$(I \otimes K)(x, y) = \sum_u \sum_v I(x + u, y + v)K(u, v)$$

– **2. Convolución ($I * K$):**

$$(I * K)(x, y) = \sum_u \sum_v I(x - u, y - v)K(u, v)$$

Efectuando el cambio de índices mudos $u' = -u$ y $v' = -v$, la convolución se expresa de manera idéntica a una correlación pero invirtiendo los ejes del kernel:

$$(I * K)(x, y) = \sum_{u'} \sum_{v'} I(x + u', y + v')K(-u', -v') = [I \otimes rotate180(K)](x, y)$$

Esta es la relación canónica fundamental: **la convolución equivale a la correlación cruzada cuando se rota el kernel 180 grados antes de operar**.

– **3. Efecto de rotar la salida de la correlación:**

Sea $C(x, y) = (I \otimes K)(x, y)$. La operación $rotate180(C)$ aplicada sobre la imagen de salida invierte simultáneamente ambas coordenadas espaciales:

$$C_{rot180}(x, y) = C(-x, -y)$$

Sustituyendo $(-x, -y)$ en la definición de la correlación:

$$C(-x, -y) = \sum_u \sum_v I(-x + u, -y + v)K(u, v)$$

Haciendo el cambio de variables $u' = -u$ y $v' = -v$:

$$C(-x, -y) = \sum_{u'} \sum_{v'} I(-(x + u'), -(y + v'))K(-u', -v')$$

Definiendo la imagen de entrada rotada 180 grados como $I_{rot180}(x, y) = I(-x, -y)$, reconocemos que la expresión anterior es:

$$C(-x, -y) = \sum_{u'} \sum_{v'} I_{rot180}(x + u', y + v')K(-u', -v') = [rotate180(I) * K](x, y)$$

Rotar la imagen resultante de la correlación equivale a haber convolucionado la imagen original rotada 180 grados con el kernel original sin rotar. Toda la escena resultante queda orientada boca abajo y con el eje horizontal invertido. Para obtener la convolución $I * K$, el giro de 180 grados debe realizarse obligatoriamente sobre el soporte del **filtro** K con carácter previo al cálculo, nunca sobre la imagen de respuesta generada.

CUESTIÓN 3: Linealidad del umbralizado (*Thresholding*)

Enunciado:

¿Puede implementarse el umbralizado mediante un filtro lineal? Dicho de otro modo, ¿es el umbralizado una operación lineal?

Respuesta breve:

No. El umbralizado es una operación estrictamente no lineal (función escalón de Heaviside). Viola tanto la homogeneidad ($T(\alpha I) \neq \alpha T(I)$) como la aditividad ($T(I_1 + I_2) \neq T(I_1) + T(I_2)$) del principio de superposición, por lo que no puede implementarse como un filtro lineal ni mediante convolución.

Resolución analítica:

La respuesta categórica es **no**. El umbralizado es una operación estrictamente **no lineal**.

Para que un operador $T : \mathcal{I} \to \mathcal{I}$ sea lineal en el espacio vectorial de imágenes, debe satisfacer rigurosamente el **principio de superposición**, descompuesto en dos condiciones necesarias y suficientes:

1. **Homogeneidad:** $T(\alpha I) = \alpha T(I)$ para cualquier escalar $\alpha \in \mathbb{R}$.
2. **Aditividad:** $T(I_1 + I_2) = T(I_1) + T(I_2)$ para cualquier par de imágenes I_1, I_2.

Consideremos la definición estándar del operador de umbralizado con valor umbral $\theta > 0$, que mapea la intensidad de cada píxel a un valor binario:

$$T_\theta(I)(x,y) = \begin{cases} 1 & \text{si } I(x,y) \geq \theta \\ 0 & \text{si } I(x,y) < \theta \end{cases}$$

Demostramos la violación de ambas propiedades mediante contraejemplos analíticos directos:

– **Violación de la homogeneidad:**

Tomemos un píxel con intensidad $I(x,y) = 0,5\,\theta$. Al aplicar el umbral:

$$T_\theta(I)(x,y) = 0$$

Multipliquemos la imagen de entrada por el factor de escala escalar $\alpha = 2$. La nueva intensidad es $(\alpha I)(x,y) = 2 \cdot (0,5\,\theta) = \theta$. Evaluando el operador:

$$T_\theta(\alpha I)(x,y) = 1$$

Sin embargo, multiplicar la salida por el escalar produce:

$$\alpha \cdot T_\theta(I)(x,y) = 2 \cdot 0 = 0$$

Dado que $1 \neq 0$, se incumple la homogeneidad: $T_\theta(\alpha I) \neq \alpha T_\theta(I)$.

– **Violación de la aditividad:**

Consideremos dos imágenes I_1 e I_2 que en la posición (x,y) presentan valores $I_1(x,y) = 0,6\,\theta$ e $I_2(x,y) = 0,6\,\theta$. Evaluando por separado:

$$T_\theta(I_1)(x,y) = 0 \quad \text{y} \quad T_\theta(I_2)(x,y) = 0 \implies T_\theta(I_1)(x,y) + T_\theta(I_2)(x,y) = 0$$

Sumando ambas imágenes previamente a la entrada, la intensidad combinada es $(I_1 + I_2)(x,y) =$

$1,2\,\theta \geq \theta$. Por tanto:

$$T_\theta(I_1 + I_2)(x, y) = 1 \neq 0$$

El umbralizado modela una función escalón de Heaviside desplazada, cuya derivada contiene una delta de Dirac. Introduce componentes espectrales inexistentes en la señal original y carece de representación matricial o convolucional mediante máscaras espaciales.

CUESTIÓN 4: Diseño analítico de filtro de contraste local con 4-vecinos

Enunciado:

¿Cuál de los siguientes filtros 3×3 devuelve un valor positivo si el promedio de los cuatro vecinos contiguos (4-conectados) es menor que el centro, y un valor negativo (o cero) en caso contrario?

$$(a)\begin{bmatrix} 0 & 1/4 & 0 \\ 1/4 & -1 & 1/4 \\ 0 & 1/4 & 0 \end{bmatrix} \qquad (b)\begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 2 \end{bmatrix} \qquad (c)\begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

Respuesta breve:

El filtro correcto es el **(c)** (con centro $+4$ y los cuatro vecinos ortogonales con peso -1). Su respuesta es $4(I_c - \bar{I}_{adj})$, estrictamente positiva si y solo si el centro supera la media de los vecinos. Corresponde al Laplaciano discreto negativo ($-\nabla^2$), que actúa como detector de máximos locales y picos de contraste.

Resolución analítica:

Modelamos matemáticamente la condición exigida en el enunciado. Sea $I_c = I(x, y)$ la intensidad del píxel central y definamos el conjunto de sus cuatro vecinos ortogonales $N_4(x, y) = \{I(x, y - 1), I(x - 1, y), I(x + 1, y), I(x, y + 1)\}$.

El promedio aritmético de dichos cuatro vecinos es:

$$\bar{I}_{adj} = \frac{1}{4} \sum_{(u,v)\in N_4} I(u, v)$$

La condición especifica que la respuesta R debe ser estrictamente positiva si y solo si $\bar{I}_{adj} < I_c$:

$$\bar{I}_{adj} < I_c \iff I_c - \bar{I}_{adj} > 0$$

Multiplicando la inecuación por la constante positiva 4:

$$4(I_c - \bar{I}_{adj}) > 0 \iff 4I_c - \sum_{(u,v)\in N_4} I(u, v) > 0$$

Evaluamos la respuesta de convolución de cada uno de los filtros candidatos sobre el entorno local:

- **Filtro (a):**

$$R_a = \frac{1}{4} \sum_{(u,v)\in N_4} I(u, v) - 1 \cdot I_c = \bar{I}_{adj} - I_c = -(I_c - \bar{I}_{adj})$$

Si el promedio de los vecinos es menor que el centro ($\bar{I}_{adj} < I_c$), la diferencia $I_c - \bar{I}_{adj}$ es positiva, por lo que R_a toma un valor **negativo**. Produce exactamente el signo opuesto al buscado.

- **Filtro (b):**

Es un operador diferencial asimétrico orientado en el eje vertical (variante de Sobel con error en el extremo inferior derecho donde figura un 2 en lugar de 1). No evalúa la relación isotrópica entre el centro y sus vecinos, sino un gradiente direccional con peso nulo en la fila central.

- **Filtro (c):**

$$R_c = 4I_c - 1 \cdot \sum_{(u,v)\in N_4} I(u,v) = 4(I_c - \bar{I}_{adj})$$

Analizando su signo: 1. Si $\bar{I}_{adj} < I_c \implies I_c - \bar{I}_{adj} > 0 \implies R_c > 0$ (valor estrictamente positivo). 2. Si $\bar{I}_{adj} \geq I_c \implies I_c - \bar{I}_{adj} \leq 0 \implies R_c \leq 0$ (valor negativo o cero).

La respuesta es unívocamente la **(c)**.

Desde el punto de vista del procesado digital, el filtro (c) representa la aproximación en diferencias finitas del **Laplaciano discreto negativo** ($-\nabla^2 I$). El Laplaciano clásico mide la divergencia del gradiente: en un máximo local (donde la intensidad central sobresale de su entorno inmediato), la curvatura es cóncava ($\nabla^2 I < 0$), por lo que $-\nabla^2 I$ produce una respuesta positiva máxima que detecta picos luminosos y realza detalles finos.

3.1.2 Bloque II: Problema Analítico del Kernel Gaussiano

Este ejercicio corresponde al problema cuantitativo propuesto en la diapositiva 85 del bloque temático 2.2.

Enunciado general:

Imaginemos un kernel Gaussiano bidimensional de tamaño 9×9.

APARTADO 1: Determinación de σ equivalente bajo la cota $k \geq 3\sigma$

Pregunta:

¿Cuál sería el valor equivalente de σ, asumiendo que k debe ser el entero más pequeño mayor o igual que 3σ?

Respuesta breve:

Para un kernel 9×9, el radio es $k = 4$. Al cumplirse $k = \lceil 3\sigma \rceil = 4$, el rango admisible es $1 < \sigma \leq 4/3$, resultando en el límite exacto de diseño que cubre el soporte $[-3\sigma, +3\sigma]$ el valor $\boldsymbol{\sigma = 4/3 \approx 1,333}$.

Resolución:

Un kernel digital bidimensional simétrico centrado en el origen posee dimensiones impares $N \times N$, donde $N = 2k + 1$ y k denota el radio espacial o semiancho del filtro en píxeles (las coordenadas recorren el intervalo $[-k, +k]$ tanto en x como en y).

Para un kernel de tamaño 9×9:

$$2k + 1 = 9 \implies 2k = 8 \implies k = 4$$

La condición impuesta en el enunciado establece que k es el menor número entero mayor o igual que 3σ, lo cual se expresa formalmente mediante la función techo (*ceiling*):

$$k = \lceil 3\sigma \rceil = 4$$

Por definición de la función techo, esto impone el rango de valores admisibles para 3σ:

$$3 < 3\sigma \leq 4 \implies 1 < \sigma \leq \frac{4}{3}$$

En el límite estricto de diseño óptimo donde el soporte del filtro trunca la distribución en exactamente 3σ a cada lado del centro:

$$3\sigma = 4 \implies \sigma = \frac{4}{3} \approx 1,3333$$

Con este valor de σ, el intervalo de discretización $[-4, 4]$ cubre el rango $[-3\sigma, +3\sigma]$, garantizando que el filtro contenga más del $99,73\,\%$ del volumen de la campana Gaussiana continua y minimizando los artefactos de discontinuidad en los bordes del kernel.

APARTADO 2: Tamaño equivalente tras 3 aplicaciones sucesivas mediante soporte discreto

Pregunta:

Si quisiéramos aplicar este mismo kernel de 9×9 un total de 3 veces consecutivas, ¿cuál sería el tamaño del kernel equivalente resultante?

Nota incluida en la diapositiva: Al aplicar el mismo kernel de tamaño N un total de k_{rep} veces, el tamaño del filtro equivalente viene dado por $N_{eq} = N + (k_{rep} - 1)(N - 1)$.

Respuesta breve:

Por la regla del soporte algebraico discreto $N_{eq} = N+(k_{rep}-1)(N-1)$, aplicando el filtro de tamaño $N = 9$ tres veces consecutivas ($k_{rep} = 3$), el tamaño del kernel discreto equivalente resultante es $9 + 2 \times 8 = \mathbf{25} \times \mathbf{25}$.

Resolución:

La fórmula suministrada proviene de la propiedad del soporte algebraico de la convolución discreta. Si convolucionamos dos señales discretas de soportes finitos L_1 y L_2, la longitud del soporte resultante es $L_1 + L_2 - 1$.

Al convolucionar $k_{rep} = 3$ veces un kernel con lado de dimensión $N = 9$:

- Primera convolución: tamaño $N = 9$.
- Segunda convolución: $(N) + (N - 1) = 9 + 8 = 17$.
- Tercera convolución: $(17) + (N - 1) = 17 + 8 = 25$.

Aplicando la expresión compacta:

$$N_{eq} = 9 + (3 - 1)(9 - 1) = 9 + 2 \times 8 = 9 + 16 = 25$$

El kernel discreto resultante equivalente que sintetiza las tres etapas en una sola pasada posee una dimensión de 25×25.

APARTADO 3: Tamaño equivalente por efecto de desenfoque continuo Gaussiano ($\sigma\sqrt{N_{rep}}$)

Pregunta:

Si quisiéramos aplicar este mismo kernel de 9×9 un total de 3 veces consecutivas, ¿cuál sería el tamaño del kernel equivalente utilizando la propiedad de que la Gaussiana es cerrada bajo la convolución (es decir, convolucionar N_{rep} veces consecutivas con desviación σ equivale a una única convolución con una Gaussiana de desviación $\sigma\sqrt{N_{rep}}$)? En este caso, buscamos el filtro que proporcione el efecto de desenfoque (*blurring*) equivalente.

Respuesta breve:

Por la propiedad reproductiva de adición de varianzas Gaussianas, $\sigma_{eq} = \sigma\sqrt{3} = \frac{4}{\sqrt{3}} \approx 2,309$. Aplicando la regla $k_{eq} = \lceil 3\sigma_{eq} \rceil = \lceil 4\sqrt{3} \rceil = 7$, el tamaño de filtro con desenfoque equivalente es $2(7) + 1 = \mathbf{15} \times \mathbf{15}$.

Resolución:

La función de densidad Gaussiana satisface la propiedad reproductiva bajo la operación de convolución continua. Si convolucionamos dos Gaussianas independientes con desviaciones estándar σ_1 y σ_2:

$$G_{\sigma_1}(\mathbf{x}) * G_{\sigma_2}(\mathbf{x}) = G_{\sigma_{eq}}(\mathbf{x}) \quad \text{donde} \quad \sigma_{eq}^2 = \sigma_1^2 + \sigma_2^2$$

Al aplicar $N_{rep} = 3$ convoluciones consecutivas con la misma desviación estándar σ:

$$\sigma_{eq}^2 = \sigma^2 + \sigma^2 + \sigma^2 = 3\sigma^2 \implies \sigma_{eq} = \sigma\sqrt{3}$$

Tomando el valor de $\sigma = 4/3$ obtenido en el Apartado 1:

$$\sigma_{eq} = \frac{4}{3}\sqrt{3} = \frac{4}{\sqrt{3}} \approx 2,3094$$

Para diseñar un nuevo filtro discreto que proporcione exactamente este mismo efecto visual de suavizado respetando la regla inicial ($k_{eq} = \lceil 3\sigma_{eq} \rceil$):

$$3\sigma_{eq} = 3 \cdot \frac{4}{\sqrt{3}} = 4\sqrt{3} \approx 4 \times 1,73205 = 6,9282$$

Calculando el radio entero mínimo necesario:

$$k_{eq} = \lceil 6,9282 \rceil = 7$$

Calculamos la dimensión total del filtro simétrico:

$$N'_{eq} = 2k_{eq} + 1 = 2(7) + 1 = 15$$

Por consiguiente, el tamaño del kernel equivalente en cuanto a desenfoque es de 15×15.

Discusión técnica comparativa (25 vs 15):

Existe una aparente discrepancia entre el resultado del Apartado 2 (25×25) y el del Apartado 3

(15×15). Su justificación radica en la naturaleza de la discretización:

- El cálculo algebraico 25×25 determina el soporte exterior estricto de convolucionar tres matrices truncadas. Sin embargo, los coeficientes en las coronas exteriores (para radios de distancia entre 8 y 12 píxeles respecto al centro) son producto de multiplicar valores ya infinitesimales de las colas de la campana. La suma de todos los pesos en esa franja externa representa menos del $0,05\,\%$ de la masa energética total del filtro.
- Al emplear la propiedad continua y truncar la Gaussiana equivalente en el umbral del $99,73\,\%$ ($3\sigma_{eq}$), un kernel de 15×15 captura prácticamente la totalidad de la función. Convolucionar con una matriz de 15×15 requiere $15^2 = 225$ operaciones por píxel (o $2 \times 15 = 30$ si se descompone de forma separable 1D), mientras que una matriz ingenua de 25×25 exige $25^2 = 625$ multiplicaciones (o $2 \times 25 = 50$). El tratamiento analítico mediante $\sigma\sqrt{3}$ permite reducir el coste computacional en un $64\,\%$ produciendo una salida indistinguible perceptualmente.

3.1.3 Bloque III: Cuestiones de Examen y Autoevaluación

Resolución exhaustiva de los siete quizzes oficiales de examen correspondientes a las diapositivas 86 a 89 del bloque temático 2.2.

QUIZ 1: Composición de filtros complejos (Diapositiva 86)

Enunciado:

¿Qué propiedad o teorema relativo a la convolución es el que, principalmente, permite la creación/-composición de filtros más complejos a partir de filtros más sencillos?

a) Asociativa

b) Conmutativa

c) Distributiva

d) Teorema de la Convolución

Respuesta correcta: **a) Asociativa**

Respuesta breve:

Opción **a) Asociativa**. Permite componer y preconvolucionar filtros en cascada ($K = K_1 * K_2$) antes de aplicarlos a la imagen en una sola pasada, base matemática que permite derivar analíticamente la Gaussiana ($\frac{\partial}{\partial x}(I * G) = I * \frac{\partial G}{\partial x}$).

Justificación analítica:

La propiedad asociativa establece que, dadas una imagen I y dos filtros espaciales K_1 y K_2:

$$[I * K_1] * K_2 = I * [K_1 * K_2]$$

Esta identidad permite convolucionar previamente los dos núcleos elementales entre sí para sintetizar un único operador compuesto $K_{comp} = K_1 * K_2$ de forma estática (*offline*). Al procesar la imagen, basta realizar una única convolución directa $I * K_{comp}$ en lugar de filtrar secuencialmente toda la escena en dos etapas sucesivas.

El ejemplo fundamental en visión por computador es el operador de **Derivada de la Gaussiana** (DoG o gradiente suavizado): en lugar de suavizar la imagen completa con una Gaussiana G y luego derivar numéricamente el resultado $(D * (G * I))$, la propiedad asociativa permite derivar analíticamente la función Gaussiana primero y aplicar directamente el kernel precalculado:

$$\frac{\partial}{\partial x}(I * G) = I * \left(\frac{\partial G}{\partial x}\right)$$

Análisis de las opciones incorrectas:

- **b) Conmutativa ($I * K = K * I$):** Garantiza que el orden de los factores no altera el resultado, pero no permite la agrupación y prefusión de operadores.
- **c) Distributiva ($I * (K_1 + K_2) = I * K_1 + I * K_2$):** Rige la adición de filtros en paralelo, no la aplicación en cascada o composición jerárquica.
- **d) Teorema de la Convolución ($\mathcal{F}\{I * K\} = \mathcal{F}\{I\} \cdot \mathcal{F}\{K\}$):** Transforma la convolución en multiplicación puntual en el dominio frecuencial, pero la propiedad que rige el diseño algorítmico y la composición de máscaras espaciales en el dominio directo es la asociatividad.

QUIZ 2: Identificación del filtro de realce (Diapositiva 86)

Enunciado:

¿Qué tipo de filtro considera que es el siguiente?

$$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

a) Suavizado Gaussiano

b) Laplaciana de la Gaussiana

c) Sharpening

d) Ninguna de las anteriores

Respuesta correcta: **c) Sharpening**

Respuesta breve:

Opción **c) Sharpening**. El filtro descompone en Identidad más Laplaciano negativo ($I - \nabla^2 I$, máscara de desenfoque). Sus pesos suman 1 para no alterar el brillo en zonas homogéneas, mientras que su centro dominante 5 frente a vecinos -1 realza las altas frecuencias (bordes).

Justificación analítica:

Descomponemos matricialmente el kernel dado K:

$$K = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} + \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix} = \delta(x, y) - \nabla^2$$

donde $\delta(x, y)$ representa el operador identidad (filtro delta de Dirac centrado que reproduce el píxel original intacto) y el segundo término es el Laplaciano discreto estándar con signo negativo ($-\nabla^2$).

La acción del filtro sobre un píxel I_c con vecinos ortogonales N_4 es:

$$(I * K)(x,y) = 5I_c - \sum_{(u,v)\in N_4} I(u,v) = I_c + \left(4I_c - \sum_{(u,v)\in N_4} I(u,v)\right) = I_c - \nabla^2 I$$

Esta formulación corresponde exactamente a la técnica clásica de **máscara de desenfoque (*Unsharp Masking*) o Sharpening**: 1. En regiones homogéneas (zonas planas), los vecinos tienen la misma intensidad que el centro ($I_c \approx \bar{I}_{adj}$). La suma de los coeficientes de la máscara es $5 - 4 = 1$, por lo que la ganancia es unitaria y la luminosidad media de la imagen no se altera. 2. En bordes o transiciones bruscas, la segunda derivada $-\nabla^2 I$ detecta la discontinuidad y suma un valor proporcional a la curvatura local, intensificando el salto de contraste y haciendo que los perfiles visuales parezcan más nítidos.

Análisis de las opciones incorrectas:

- **a) Suavizado Gaussiano:** Falsa. Los filtros de suavizado actúan como promedios ponderados paso bajo, por lo que todos sus coeficientes son estrictamente no negativos y normalizados para sumar 1.
- **b) Laplaciana de la Gaussiana (LoG):** Falsa. Los núcleos LoG son operadores derivados puros de segundo orden cuya suma de coeficientes es estrictamente cero (anulan áreas uniformes y solo responden a bordes).

QUIZ 3: Sigma equivalente tras tres etapas de suavizado (Diapositiva 87)

Enunciado:

Si suavizamos una imagen tres veces consecutivas con un filtro Gaussiano σ, ¿cuál sería el sigma equivalente que nos permitiría obtener el mismo resultado suavizando una única vez?

a) $\sigma\sqrt{3}$

b) $\sqrt{3\sigma}$

c) $3\sqrt{\sigma}$

d) Ninguna de las anteriores

Respuesta correcta: **a)** $\sigma\sqrt{3}$

Respuesta breve:

Opción **a)** $\boldsymbol{\sigma\sqrt{3}}$. La convolución continua de filtros Gaussianos suma algebraicamente sus varianzas ($\sigma_{eq}^2 = \sigma^2 + \sigma^2 + \sigma^2 = 3\sigma^2$), lo que proporciona una desviación estándar equivalente resultante de $\sigma_{eq} = \sqrt{3\sigma^2} = \sigma\sqrt{3}$.

Justificación analítica:

La función Gaussiana unidimensional centrada viene dada por:

$$g(x;\sigma) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}}$$

Su transformada de Fourier continua es asimismo otra función Gaussiana:

$$\mathcal{F}\{g(x;\sigma)\}(\omega) = e^{-\frac{\sigma^2\omega^2}{2}}$$

Por el teorema de convolución, convolucionar en el dominio espacial tres veces consecutivas con la misma desviación estándar σ equivale a multiplicar algebraicamente sus espectros de Fourier:

$$\mathcal{F}\{g * g * g\}(\omega) = e^{-\frac{\sigma^2\omega^2}{2}} \cdot e^{-\frac{\sigma^2\omega^2}{2}} \cdot e^{-\frac{\sigma^2\omega^2}{2}} = e^{-\frac{3\sigma^2\omega^2}{2}} = e^{-\frac{\sigma_{eq}^2\omega^2}{2}}$$

Igualando los exponentes:

$$\sigma_{eq}^2 = 3\sigma^2 \implies \sigma_{eq} = \sqrt{3\sigma^2} = \sigma\sqrt{3}$$

El mismo principio aplica directamente a Gaussianas bidimensionales isotrópicas por su propiedad de separabilidad cartesiana ($G(x, y; \sigma) = g(x; \sigma)g(y; \sigma)$).

Análisis de las opciones incorrectas:

- **b) $\sqrt{3\sigma}$:** Falsa. En esta opción la raíz cuadrada abarca tanto al 3 como al parámetro σ. Desde una perspectiva de análisis dimensional, si σ se mide en píxeles, $\sqrt{\sigma}$ tendría unidades de píxeles$^{1/2}$, lo cual es físicamente absurdo.
- **c) $3\sqrt{\sigma}$:** Falsa. Padece del mismo error dimensional y confunde la suma de varianzas con la multiplicación lineal del factor de escala.

QUIZ 4: Análisis comparativo de Canny y Otsu (Diapositiva 87)

Enunciado:

¿Cuál de las siguientes afirmaciones sobre los algoritmos de Canny y Otsu es correcta?

a) El detector de bordes de Canny se comporta como un filtro lineal dado que emplea filtrado Gaussiano para suavizar/emborronar la imagen y, a continuación, emplea filtrado lineal para calcular el gradiente.

b) El umbral óptimo en el algoritmo de Otsu se obtiene minimizando la varianza inter-clase o maximizando la varianza intra-clase.

c) En el algoritmo de Canny obtendremos bordes más discontinuos/fragmentados si reducimos el umbral bajo.

d) Las tres respuestas anteriores son erróneas.

Respuesta correcta: **d) Las tres respuestas anteriores son erróneas**

Respuesta breve:

Opción **d) Las tres respuestas anteriores son erróneas**. Canny no es lineal (incorpora supresión de no máximos e histéresis); Otsu maximiza la varianza inter-clase (no la minimiza); y reducir el umbral bajo en Canny genera bordes más continuos y conectados, no más fragmentados.

Justificación analítica:

Demostramos la falsedad individual de cada una de las proposiciones anteriores:

- **Refutación de la afirmación a:**

El detector de Canny consta de cuatro etapas: 1. Suavizado Gaussiano (lineal). 2. Cálculo de gradiente por derivadas direccionales (lineal). 3. **Supresión de no máximos (*Non-Maximum Suppression*, NMS):** Operación de adelgazamiento que compara la magnitud de cada píxel con

sus dos vecinos en la dirección normal al gradiente y anula el píxel si no es el máximo local estricto. Es una función de conmutación no lineal condicionada. 4. **Umbralización con histéresis:** Clasifica píxeles en fuertes, débiles y fondo mediante dos umbrales y preserva los débiles únicamente si forman una cadena conectada de 8-vecindad con un borde fuerte. La conectividad topológica y el umbralizado son operaciones fuertemente no lineales.

En consecuencia, el detector de Canny en su conjunto es un sistema **no lineal**.

- **Refutación de la afirmación b:**

En la formulación matemática de Otsu (1979), la varianza total de las intensidades de la imagen σ_T^2 es constante e invariante respecto al umbral t, satisfaciendo la descomposición:

$$\sigma_T^2 = \sigma_W^2(t) + \sigma_B^2(t)$$

donde $\sigma_W^2(t)$ es la varianza intra-clase (*within-class variance*, dispersión interna de los dos grupos) y $\sigma_B^2(t)$ es la varianza inter-clase (*between-class variance*, distancia cuadrática entre las medias ponderadas de ambos grupos).

Para encontrar la separación que maximiza la discriminación estadística entre fondo y objeto, Otsu busca el umbral óptimo t^* mediante:

$$t^* = \arg\max_t \sigma_B^2(t) \quad \Longleftrightarrow \quad t^* = \arg\min_t \sigma_W^2(t)$$

La opción b invierte deliberadamente el criterio al enunciar: "minimizando la varianza inter-clase o maximizando la intra-clase", lo cual generaría la peor segmentación posible.

- **Refutación de la afirmación c:**

En el umbralizado por histéresis de Canny, el umbral alto T_{high} inicia contornos con alta confianza, mientras que el umbral bajo T_{low} actúa como cota de corte inferior para extender dichos contornos a través de zonas donde el gradiente se debilita.

Si **reducimos** T_{low}, admitimos gradientes más débiles para prolongar las cadenas de bordes, permitiendo cerrar discontinuidades y logrando contornos **más continuos y conectados**. Los bordes se volverían más discontinuos o fragmentados si *aumentáramos* T_{low} (o T_{high}).

Al ser a, b y c estrictamente falsas, la opción válida es la **d**.

QUIZ 5: Propiedades del gradiente y derivadas espaciales (Diapositiva 88)

Enunciado:

¿Cuál de las afirmaciones siguientes sobre procesado de imagen es cierta?

a) Las derivadas en X detectan bordes horizontales, y las derivadas en Y detectan bordes verticales.

b) La magnitud del gradiente puede tener valores negativos, dado que el gradiente puede hacer referencia a pendientes positivas o negativas.

c) El gradiente en una imagen es mayor en las regiones planas que en las zonas con bordes.

d) Ninguna de las anteriores es correcta.

Respuesta correcta: **d) Ninguna de las anteriores es correcta**

Respuesta breve:

Opción **d) Ninguna de las anteriores es correcta**. Las derivadas en X detectan bordes verticales (no horizontales); la magnitud euclídea del gradiente es una norma no negativa ($\|\nabla I\| \geq 0$); y en zonas planas el gradiente es nulo, alcanzando su máximo en los bordes.

Justificación analítica:

Examinamos la falsedad de las opciones planteadas:

- **Refutación de la afirmación a:**

La derivada parcial respecto a X, $\frac{\partial I}{\partial x}$, mide la tasa de variación de intensidad a lo largo del eje horizontal (de izquierda a derecha). Por definición geométrica, un cambio brusco horizontal se produce al atravesar un **borde vertical**. De forma análoga, $\frac{\partial I}{\partial y}$ mide el cambio vertical al atravesar un **borde horizontal**. Las correspondencias están cruzadas en el enunciado.

- **Refutación de la afirmación b:**

El vector gradiente espacial se define como $\nabla I = \left[\frac{\partial I}{\partial x}, \frac{\partial I}{\partial y}\right]^T$. Aunque las derivadas parciales individuales pueden tomar valores negativos (indicando pendientes descendentes de intensidad), la **magnitud del gradiente** es su norma euclídea:

$$\|\nabla I\| = \sqrt{\left(\frac{\partial I}{\partial x}\right)^2 + \left(\frac{\partial I}{\partial y}\right)^2}$$

Por propiedades de la métrica euclídea, la norma es una cantidad real no negativa ($\|\nabla I\| \geq 0$). El signo o sentido de la transición queda codificado en el ángulo de orientación del gradiente ($\theta = \text{atan2}(I_y, I_x)$), jamás en su módulo.

- **Refutación de la afirmación c:**

En una región plana o uniforme de una imagen, la intensidad es prácticamente constante ($I(x, y) \approx c$). Sus derivadas parciales son nulas ($\partial I/\partial x \approx 0, \partial I/\partial y \approx 0$), lo que da lugar a una magnitud de gradiente próxima a cero. El gradiente alcanza sus valores más elevados precisamente en las fronteras entre regiones (bordes).

Al ser todas las anteriores afirmaciones erróneas, la única alternativa válida es la **d**.

QUIZ 6: Equivariancia de la convolución bidimensional (Diapositiva 88)

Enunciado:

¿Cuáles de las siguientes afirmaciones relativas a la operación de convolución son correctas?

a) La convolución es equivariante con la traslación.

b) La convolución no es equivariante con el escalado.

c) La convolución no es equivariante con la rotación.

d) Todas las anteriores son correctas.

Respuesta correcta: **d) Todas las anteriores son correctas**

Respuesta breve:

Opción **d) Todas las anteriores son correctas**. La convolución espacial es equivariante ante traslaciones, pero no lo es ante escalados (el filtro tiene tamaño fijo en píxeles) ni ante rotaciones (los kernels direccionales no giran con la imagen).

Justificación analítica:

Esta cuestión sintetiza los fundamentos matemáticos demostrados en la Cuestión 1 del Bloque I:

1. **Equivariancia con la traslación (Proposición a):** Es una propiedad intrínseca de los sistemas lineales e invariantes en el espacio (LSI). Desplazar la entrada una distancia $\mathbf{x}_0$ desplaza idénticamente la respuesta: $(I(\cdot - \mathbf{x}_0) * K)(\mathbf{x}) = (I * K)(\mathbf{x} - \mathbf{x}_0)$.
2. **Falta de equivariancia con el escalado (Proposición b):** El soporte de la máscara K está definido sobre una cuadrícula fija de píxeles. Si la imagen se amplía o reduce, el filtro muestrea una escala espacial distinta de la escena, requiriendo pirámides espaciales para compensarlo.
3. **Falta de equivariancia con la rotación (Proposición c):** Para un kernel direccional general (como Sobel o Prewitt), rotar la imagen no rota la orientación preferente del filtro, por lo que la convolución estándar no conmuta con rotaciones espaciales en el caso general.

Al ser las tres proposiciones verdaderas, la opción correcta es la **d**.

QUIZ 7: Reconocimiento del perfil de un kernel 1D (Diapositiva 89)

Enunciado:

La siguiente figura representa el perfil de un kernel 1D. ¿Qué tipo de filtro representa?

(Gráfica: Función unidimensional continua y suave, simétrica respecto a $x = 0$, no negativa en todo su soporte $[-7, 7]$, con un único valor máximo unitario en el origen y decaimiento asintótico hacia cero en los extremos).

a) Un kernel de suavizado Gaussiano.

b) Un kernel de primeras derivadas.

c) Un kernel de segundas derivadas.

d) Ninguno de los anteriores.

Respuesta correcta: **a) Un kernel de suavizado Gaussiano**

Respuesta breve:

Opción **a) Un kernel de suavizado Gaussiano**. La función es simétrica par, estrictamente no negativa en todo el intervalo $[-7, 7]$, con un único valor máximo unitario en $x = 0$ y decaimiento exponencial asintótico a cero en las colas.

Justificación analítica:

Analizamos la estructura funcional de la señal representada:

1. **Simetría par:** $f(x) = f(-x)$, simétrica respecto al eje de ordenadas $x = 0$.
2. **No negatividad:** $f(x) \geq 0$ para todo $x \in [-7, 7]$. Todos los pesos son positivos, lo que define una operación de promedio ponderado local (filtro paso bajo).
3. **Monotonía y concavidad:** Presenta un único máximo central en $x = 0$ ($f(0) = 1,0$), con puntos de inflexión característicos a una distancia proporcional a σ y decaimiento exponencial

hacia cero en las colas.

Esta función reproduce de forma exacta la campana de Gauss unidimensional sin normalizar:

$$g(x) = \exp\left(-\frac{x^2}{2\sigma^2}\right)$$

Observando los valores del gráfico: en $x = \pm 3$, el valor es aproximadamente $0,55$; en $x = \pm 7$, desciende por debajo de $0,05$. Ajustando la ecuación $\exp\big(-3^2/(2\sigma^2)\big) \approx 0,55$, obtenemos $\sigma \approx 2,75$, plenamente compatible con el decaimiento observado en la ventana $[-7, 7]$.

Análisis de las opciones incorrectas:

- **b) Kernel de primeras derivadas:** Una primera derivada (como la derivada de una Gaussiana $\frac{d}{dx}G(x) = -\frac{x}{\sigma^2}G(x)$) es una función **impar y antisimétrica** ($f(-x) = -f(x)$). Debe presentar obligatoriamente un lóbulo positivo y un lóbulo negativo que sumen cero.
- **c) Kernel de segundas derivadas:** Una segunda derivada (como el Laplaciano de la Gaussiana $\frac{d^2}{dx^2}G(x) = \frac{x^2-\sigma^2}{\sigma^4}G(x)$) presenta perfil de sombrero mexicano (*Mexican hat*): un pico central positivo (o negativo) flanqueado por dos lóbulos laterales de signo opuesto, con integral total nula.