



UNIVERSIDAD
DE GRANADA

Aprendizaje Automático

Apuntes de la asignatura

Ismael Sallami Moreno

Recursos Ingeniería Informática y Ade

Licencia

Este trabajo está bajo una Licencia Creative Commons BY-NC-ND 4.0.

Permisos: Se permite compartir, copiar y redistribuir el material en cualquier medio o formato.

Condiciones: Es necesario dar crédito adecuado, proporcionar un enlace a la licencia e indicar si se han realizado cambios. No se permite usar el material con fines comerciales ni distribuir material modificado.



Aprendizaje Automático

Ismael Sallami Moreno

<https://elblogdeismael.github.io>

Índice general

1	Teoría	9
1.1	Tema 1. Conceptos básicos	9
1.2	Tema 2. Aprendizaje Supervisado	11
1.3	Tema 3. Calidad de Datos	13
1.4	Tema 4. Aprendizaje No Supervisado	15
1.5	Tema 5. Aprendizaje Profundo. Fundamentos	17
1.6	Tema 6. Aprendizaje Profundo en Diferentes Tipos de Datos	19
1.7	Tema 9. Aspectos Avanzados, Retos y Desafíos	21

Teoría

Repaso completo orientado a examen tipo test. Cada término clave aparece en **negrita** con su definición. Redacción impersonal, sin relleno.

1.1 Tema 1. Conceptos básicos

1.1.1 ¿Qué es el Aprendizaje Automático (AA)?

- **Definición clásica (Arthur Samuel, 1959):** ciencia y arte de programar ordenadores para que aprendan de los datos sin ser programados explícitamente.
- **Definición de ingeniería (Tom Mitchell, 1997):** un programa aprende de la **experiencia E**, respecto a una **tarea T** y una **medida de rendimiento P**, si su rendimiento en T (medido por P) mejora con la experiencia E.
- **Formalización:** consiste en estimar una función $f(x, w)$ que minimice el riesgo o pérdida promedio sobre un conjunto de datos de entrenamiento (x_i, y_i) .
- **¿Cuándo conviene usarlo?** En problemas complejos donde las reglas explícitas son ineficientes, en entornos fluctuantes (los datos cambian) y para descubrir patrones ocultos en grandes volúmenes de información (minería de datos).

1.1.2 Tipos de Aprendizaje Automático

- **Aprendizaje Supervisado:** se entrena con datos que incluyen las soluciones deseadas, llamadas **etiquetas**. Dos tareas principales:
 - **Clasificación:** predecir una clase o categoría (p. ej. filtro antispam).
 - **Regresión:** predecir un valor numérico objetivo a partir de unas características o predictores (p. ej. el precio de un coche).
- **Aprendizaje No Supervisado:** los datos no están etiquetados; el sistema aprende sin “profesor”. Tareas:
 - **Agrupamiento (Clustering):** detectar grupos similares (K-Means, DBSCAN; segmentación de clientes).
 - **Detección de anomalías:** identificar casos inusuales (fraude, defectos; Isolation Forest).
 - **Reducción de dimensionalidad y visualización:** simplificar datos complejos (PCA, t-SNE).
 - **Reglas de asociación:** descubrir relaciones entre atributos (algoritmo **Apriori**).
- **Aprendizaje Semi-supervisado:** combina pocos datos etiquetados con muchos sin etiquetar; útil cuando etiquetar es caro.
- **Aprendizaje por Refuerzo:** un **agente** observa un **entorno**, ejecuta **acciones** y recibe **recompensas** o penalizaciones, aprendiendo una **política** que maximiza la recompensa acumulada (AlphaGo, bots de videojuegos).

1.1.3 Enfoques: Instancias vs. Modelos

- **Basado en instancias:** memoriza los ejemplos y clasifica los casos nuevos por una medida de **similitud** (distancia) frente a los datos almacenados. No requiere entrenamiento previo (p. ej. k-NN).
- **Basado en modelos:** construye un modelo que generaliza, usando una **función de pérdida** (error) y un método de **optimización**.

1.1.4 Evaluación y Generalización

- Los datos se dividen en **conjunto de entrenamiento** y **conjunto de test**.
- **Generalización:** mide el comportamiento ante datos nuevos (no vistos en entrenamiento). Para estimarla se usa la **validación cruzada (k-fold)**, que particiona los datos en k bloques y rota cuál actúa como test.
- **Estimación de densidad:** estimar la función de densidad de probabilidad (PDF) que generó los datos; útil para detectar anomalías (zonas de baja densidad).
- **Criterios de evaluación:** además de la precisión, se valoran velocidad, robustez (tratar valores desconocidos), escalabilidad, interpretabilidad y complejidad del modelo.

1.1.5 Retos en el Entorno Real

- **Teorema “No Free Lunch” (NFL):** sin suposiciones sobre los datos, no hay razón para preferir un modelo sobre otro. No existe un algoritmo óptimo para todos los problemas.
- **Sobreajuste (Overfitting):** el modelo va muy bien en entrenamiento pero generaliza mal. Se combate con **regularización** y ajuste de hiperparámetros.
- **Subajuste (Underfitting):** el modelo es demasiado simple para capturar la estructura de los datos.
- **Datos no representativos:** si validación y test no representan la realidad, el modelo falla en producción.

1.1.6 Calidad de Datos y Enfoques de Desarrollo

- Era del **Big Data:** el dato es el recurso clave y abarca múltiples tipos (texto, imagen, audio, series temporales).
- **Data-Centric vs Model-Centric:** transición desde mejorar el modelo (Model-Centric) hacia el enfoque **Data-Centric**, donde la arquitectura se estandariza y el esfuerzo se concentra en iterar, adquirir, limpiar y auditar los datos.

1.1.7 Regulación y Ética

- **AI Act:** marco regulatorio europeo que clasifica la IA por nivel de riesgo (inaceptable, alto, limitado, mínimo).
- **IA Fiable (Trustworthy AI):** exige sistemas robustos, lícitos y éticos: transparencia, privacidad y supervisión humana durante todo el ciclo de vida.
- **AI Safety:** estudio de la seguridad y vulnerabilidades frente a adversarios (p. ej. patrones en ropa que actúan como “capa de invisibilidad” ante detectores de objetos).

1.2 Tema 2. Aprendizaje Supervisado

1.2.1 Evaluación de Modelos (Métricas)

Antes de construir modelos, es necesario saber cómo evaluarlos.

- **Para Regresión:**
 - **RMSE (Raíz del Error Cuadrático Medio):** medida preferida; penaliza más los errores grandes y se basa en la norma Euclídea (L_2).
 - **MAE (Error Medio Absoluto):** con muchos valores atípicos (*outliers*), el MAE (norma Manhattan, L_1) es preferible por ser más robusto.
- **Para Clasificación:**
 - **Matriz de confusión:** recoge verdaderos positivos (TP), falsos positivos (FP), verdaderos negativos (TN) y falsos negativos (FN).
 - **Precisión (Precision):** exactitud de las predicciones positivas, $TP/(TP + FP)$.
 - **Recuperación / Sensibilidad (Recall):** capacidad de encontrar todos los positivos, $TP/(TP + FN)$. Existe un **compromiso (trade-off) precision/recall**: subir el umbral de decisión sube la precisión y baja el recall.
 - **F1:** media armónica de precisión y recall.
 - **Curva ROC y AUC:** la ROC traza sensibilidad frente a 1-especificidad; el **AUC** es el área bajo la curva (1 = perfecto, 0,5 = azar).

1.2.2 Aprendizaje Basado en Instancias vs. Modelos

- **Basado en instancias (k-NN):** memoriza el entrenamiento y clasifica midiendo similitud (distancia) con los vecinos más cercanos. Sin fase de entrenamiento real. Clasificación: “regla de la mayoría” de los vecinos; regresión: media del vecindario.
- **Basado en modelos:** construye una función matemática que minimiza un error.

1.2.3 Modelos Lineales y Regularización (Regresión)

- **Regresión Lineal:** predice una suma ponderada de las características más un término de sesgo (bias). Se entrena minimizando el MSE.
 - Resolución directa con la **Ecuación Normal** (pseudoinversa o SVD) o iterativa con **Descenso de Gradiente**. Como el coste es convexo, el descenso de gradiente garantiza el mínimo global.
- **Regresión Polinómica:** ajusta datos no lineales añadiendo potencias de las características. Un grado alto provoca **sobreajuste**.
- **Regularización** (restringir pesos para evitar el sobreajuste):
 - **Ridge:** penalización L_2 sobre el MSE. Mantiene los pesos pequeños. Buena opción por defecto.
 - **Lasso:** penalización L_1 . Elimina características inútiles forzando pesos exactamente a cero (modelo disperso).
 - **Elastic Net:** término medio entre Ridge y Lasso; preferible a Lasso cuando hay características muy correlacionadas.
 - **Parada Anticipada (Early Stopping):** regulariza métodos iterativos deteniendo el entrenamiento cuando el error de validación alcanza un mínimo.

1.2.4 Clasificación Probabilística: Regresión Logística y Naïve Bayes

- **Regresión Logística:** estima la probabilidad de pertenencia a una clase (si $> 50\%$, predice positivo). Coste convexo: **Pérdida Logarítmica (Log Loss)**.
- **Regresión Softmax:** generaliza la logística a múltiples clases sin clasificadores binarios separados. Coste: **Entropía Cruzada**.
- **Naïve Bayes:** se basa en el Teorema de Bayes y la hipótesis (ingenua) de independencia entre características; aplica la regla **MAP (Maximum A Posteriori)** para devolver la clase más probable.

1.2.5 Máquinas de Vectores de Soporte (SVM)

Basadas en la Teoría del Aprendizaje Estadístico.

- **SVM Lineal (Clasificación):** busca la “calle” (margen) más ancha posible entre clases.
 - **Vectores de soporte:** instancias situadas en el borde de la calle que determinan el margen. Muy sensibles a la **escala** de las características.
 - **Margen Duro vs Blando:** el duro no permite violaciones (sensible a outliers, exige separabilidad lineal). El **margen blando** usa el hiperparámetro C para equilibrar: permite algunas violaciones para generalizar mejor. C grande $\rightarrow$ menos regularización.
- **Regresión SVM:** invierte el objetivo: mete el mayor número de instancias *dentro* de la calle, cuyo ancho controla el hiperparámetro ϵ (modelo ϵ -insensible).
- **SVM No Lineal (truco del Kernel):** para datos no separables linealmente. En vez de añadir características polinómicas (costoso), usa funciones **Kernel** (Polinómico, **Gaussiano RBF**, Sigmoides) apoyándose en el **Teorema de Mercer** para operar en dimensiones superiores sin calcularlas explícitamente.

1.2.6 Árboles de Decisión y Ensembles

- **Árboles de Decisión (CART):** árbol de preguntas ($\text{¿pétalo} < 2,45 \text{ cm?}$). Clasificación: minimizan impureza **Gini** o **Entropía**; regresión: minimizan el MSE. Son **no paramétricos**, por lo que sin restricciones (`max_depth`, `min_samples_leaf`) tienden fuertemente al sobreajuste. Tienen **alta varianza** y son sensibles a la orientación de los ejes.
- **Ensembles (sabiduría de la multitud):** combinar varios modelos.
 - **Voto duro vs blando:** el duro agrega por mayoría de clases predichas; el blando promedia probabilidades (suele rendir mejor si los modelos las estiman bien).
 - **Bagging y Pasting:** entrena un mismo modelo en subconjuntos aleatorios. *Bagging* con reemplazo; *Pasting* sin él. Agregación final por moda (clasificación) o media (regresión).
 - **Evaluación Out-of-Bag (OOB):** en bagging, cada predictor se valida con las instancias que no le tocaron en su muestreo, sin necesitar conjunto de validación aparte.
 - **Random Patches / Random Subspaces:** muestrean también las características (no solo las instancias).
 - **Random Forests:** ensemble (bagging) de árboles que además aleatoriza el subconjunto de características en cada división. Promediar muchos árboles reduce drásticamente la varianza. Permite medir la **importancia de las características**.
 - **Extra-Trees (Extremely Randomized Trees):** como Random Forest pero con umbrales de división aleatorios; más rápido y con más sesgo y menos varianza.
 - **Boosting:** entrena modelos en secuencia, cada uno corrigiendo los fallos del anterior. **AdaBoost** da más peso a las instancias mal clasificadas; **Gradient Boosting** ajusta

cada nuevo predictor a los errores residuales del conjunto.

- **Stacking:** entrena un meta-modelo (*blender*) que aprende a combinar las predicciones de varios modelos base.

1.2.7 Estrategias Multiclase

Para que un clasificador binario puro (como SVM) prediga sobre 3+ clases:

- **OvO (One-vs-One):** un modelo binario por cada par de clases.
- **OvA / OvR (One-vs-All / One-vs-Rest):** un clasificador por clase frente al resto; gana la clase con mayor confianza. Suele preferirse por entrenar menos modelos.

Claves de examen (Tema 2). Frente al sobreajuste, los recursos principales son la **regularización** (hiperparámetros como C , α , profundidades de árbol; Ridge/Lasso/Elastic Net) y el **ensamblado** que reduce varianza (Random Forests). RMSE penaliza errores grandes; MAE es más robusto a outliers. Precision mide acierto de los positivos; recall, cobertura de los positivos.

1.3 Tema 3. Calidad de Datos

Principio rector: “**Garbage In, Garbage Out**” (datos basura $\rightarrow$ resultados basura). El preprocesamiento convierte datos brutos en *Smart Data* y llega a ocupar el **80 % del tiempo** de un proyecto de minería de datos.

1.3.1 Integración, Limpieza y Transformación

- **Integración:** combinar datos de múltiples fuentes, detectar duplicados y eliminar atributos redundantes (p. ej. por correlación).
- **Limpieza de datos imperfectos:**
 - **Valores perdidos (Missing values):** ignorarlos (poco recomendable), rellenar con una constante, usar media/desviación, o imputarlos con algoritmos de AA (KNNI, SVMI, etc.).
 - **Ruido:** ejemplos mal etiquetados o erróneos. Se filtran con *ensembles* de clasificadores por votación: **Ensemble Filter (EF)**, **Cross-Validated Committees Filter (CVCF)**, **Iterative-Partitioning Filter (IPF)**.
 - **Outliers:** datos muy diferentes del resto; se detectan por distancias o por *clustering* parcial.
- **Transformación:**
 - **Agregación y generalización:** resumir (ventas diarias $\rightarrow$ mensuales) o subir en la jerarquía (edad numérica $\rightarrow$ “joven/adulto”).
 - **Normalización:** escalar valores numéricos para métodos sensibles a la distancia (k-NN, redes neuronales), llevando los rangos a $[0, 1]$ o $[-1, 1]$ (escala min-max, escala decimal, estandarización z-score).

1.3.2 Reducción de Datos

Objetivo: un conjunto más pequeño y manejable que conserve la relevancia, para aprender más rápido y generalizar mejor.

A. Discretización

Convierte valores numéricos continuos en intervalos nominales; facilita la comprensión y es obligatoria para algunos algoritmos.

- **No supervisada:** sin usar la clase. Igual amplitud (intervalos del mismo tamaño) o igual frecuencia (mismo número de datos por intervalo).
- **Supervisada:** usa la clase para cortes más informados. Destacan el algoritmo de **Fayyad e Irani** basado en **Entropía (criterio MDLP)** y los métodos basados en **Chi-cuadrado**.

B. Selección de Características (Feature Selection)

Busca el subconjunto óptimo de variables; demasiadas aumentan la complejidad y empeoran la generalización. Combina estrategias de búsqueda (añadir o quitar variables) con funciones de evaluación:

- **Filtro (Filter):** métricas matemáticas (correlación, entropía, distancias). Rápido, pero tiende a seleccionar muchas variables.
- **Envoltorio (Wrapper):** usa el propio algoritmo de aprendizaje para evaluar el subconjunto. Más exacto, pero **muy costoso** y sesgado hacia ese clasificador concreto.
- **Embebido (Embedded):** la selección ocurre dentro del entrenamiento (p. ej. Lasso, importancia en árboles).

C. Selección de Instancias

Elige las filas (ejemplos) más relevantes, eliminando ruido y redundancia; útil para métodos perezosos (k-NN) y para reducir tamaño en árboles.

- **Condensación (CNN):** retiene instancias de las fronteras de decisión y descarta las interiores. Rápido (incremental) pero dependiente del orden.
- **Edición (ENN):** elimina instancias mal clasificadas por sus k vecinos. Suaviza fronteras (quita ruido) pero no elimina redundancia.
- **Híbridos y evolutivos:** combinan ambos. Destacan **DROP3**, algoritmos genéticos (**CHC**) y **SSMA**.
- **Muestreo (Sampling):** seleccionar un subconjunto aleatorio representativo.

1.3.3 Reducción de Dimensionalidad

- **Maldición de la dimensionalidad:** a más dimensiones, los datos se vuelven dispersos, las distancias pierden significado y se necesita exponencialmente más datos. Proyectar a menos dimensiones ayuda.
- **Proyección:** los datos reales suelen vivir cerca de un subespacio de menor dimensión; proyectar sobre él reduce dimensiones (falla si el subespacio se “retuerce”).
- **Aprendizaje de variedades (Manifold Learning):** asume que los datos yacen sobre una variedad de baja dimensión “enrollada” en el espacio (p. ej. desenrollar el *Swiss roll* de 3D a 2D).
- **PCA (Análisis de Componentes Principales):** método estrella. Halla el hiperplano que preserva la **máxima varianza** y proyecta sobre él, apoyándose en la **Descomposición en Valores Singulares (SVD)**.
 - **PCA incremental:** procesa los datos por lotes (mini-batches), apto para conjuntos que no caben en RAM o flujos.

- **PCA aleatorio / Proyección aleatoria:** proyecta sobre un subespacio aleatorio; muy rápido y con garantías teóricas (lema de Johnson-Lindenstrauss).
- **LLE (Locally Linear Embedding):** técnica no lineal de *manifold learning*; conserva las relaciones lineales locales entre vecinos al reducir dimensiones. Bueno con datos no lineales sin ruido.

Claves de examen (Tema 3). Conviene distinguir **Selección de Características** (eliminar *columnas/variables*) de **Selección de Instancias** (eliminar *filas/ejemplos*). Los enfoques *Wrapper* son más exactos pero mucho más lentos que los *Filter*. PCA preserva varianza vía SVD; reduce dimensiones, no instancias.

1.4 Tema 4. Aprendizaje No Supervisado

1.4.1 Tareas Principales

Se buscan patrones naturales sin etiquetas. Tres áreas:

- **Clustering (Agrupamiento):** asignar instancias similares a grupos (segmentación de clientes, motores de búsqueda, segmentación de imágenes).
- **Detección de anomalías:** aprender el aspecto de los datos “normales” (inliers) para identificar instancias raras (fraude, defectos).
- **Estimación de densidad:** estimar la PDF del proceso generador; útil para análisis y para detectar anomalías (baja densidad).

1.4.2 Algoritmos de Clustering

A. Familia K-Means

Rápido y sencillo: inicializa k centroides, asigna cada punto al más cercano y recalcula el centroide (media) hasta converger. Minimiza la **inercia** (suma de distancias al cuadrado a su centroide).

- **Límites:** exige conocer k de antemano; debe ejecutarse varias veces para no caer en óptimos locales; falla con clusters de distinta densidad, tamaño o forma no esférica.
- **Variantes:**
 - **K-Means++:** inicialización inteligente: separa al máximo los centroides iniciales, reduciendo soluciones subóptimas.
 - **K-Means acelerado (Elkan):** usa la desigualdad triangular para evitar cálculos de distancia innecesarios.
 - **Mini-Batch K-Means:** actualiza con pequeños lotes; mucho más rápido y apto para datos que no caben en RAM, con inercia algo peor.

B. Número óptimo de clusters (k)

- **Método del Codo (Elbow):** la inercia siempre baja al subir k ; se busca el “codo” (punto de inflexión) en la curva inercia vs k .
- **Puntuación de Silueta (Silhouette):** más precisa. Para cada punto, $(b - a) / \max(a, b)$, con a = distancia media intra-cluster y b = distancia media al cluster más cercano. Va de -1 a $+1$ (cerca de $+1$ = bien agrupado).

C. DBSCAN (*Basado en Densidad*)

Define clusters como regiones continuas de alta densidad. Hiperparámetros: radio de vecindad ϵ y mínimo de muestras (`min_samples`).

- Clasifica los puntos como **centrales** (con el mínimo de vecinos), **de borde** o **anomalías**.
- **Ventajas:** no exige k , detecta formas arbitrarias y es robusto a outliers.
- **Desventajas:** falla con densidades muy distintas y escala mal, $O(m^2n)$.

D. Otros algoritmos

- **Clustering Aglomerativo:** árbol jerárquico de abajo arriba, emparejando los clusters más cercanos.
- **BIRCH:** para datasets enormes; construye un árbol sobre la marcha limitando memoria.
- **Mean-Shift:** desplaza círculos hacia la zona de mayor densidad (máximo local). Cualquier forma, pero lento.
- **Affinity Propagation:** los puntos intercambian mensajes “votando” por un ejemplar representativo; calcula k automáticamente.
- **Clustering Espectral:** reduce la dimensionalidad de una matriz de similitud y aplica k -means. Excelente para grafos (redes sociales).

1.4.3 Medidas de Calidad del Clustering

- **Índice de Davies-Bouldin:** relación dispersión intra-cluster / separación entre centroides. **Mejor cuanto más pequeño.**
- **Silueta:** mide cercanía a los propios y lejanía del borde. **Mejor cuanto más próximo a +1.**
- **Índice de Dunn:** distancia mínima entre clusters / diámetro máximo de un cluster. **Mejor cuanto más alto.**
- **Estadística pseudo-F:** distancias entre-clusters / intra-clusters. **Mejor cuanto más alto.**

1.4.4 Detección de Anomalías

Eventos raros (fraude, intrusiones, enfermedades raras). Retos: la “normalidad” cambia con el tiempo, la frontera es imprecisa y el ruido se camufla.

A. Tipos de Anomalías

- **Puntuales:** un punto individual alejado del resto.
- **Contextuales / Condicionales:** anómalo solo en su contexto (un bajón de temperatura es normal en invierno, anómalo en verano).
- **Colectivas:** una secuencia o grupo es anómalo en conjunto (arritmia en un ECG) aunque cada punto parezca normal.

B. Técnicas de Detección

- **Basadas en distancia (k-NN):** anomalía = punto con mayor distancia a su k -ésimo vecino. Falla con densidades distintas.

- **Basadas en densidad (LOF, Local Outlier Factor):** compara la densidad de un punto con la de sus vecinos; densidad mucho menor $\rightarrow$ outlier. Resuelve el problema de densidad variable de k-NN.
- **Basadas en modelos (One-Class SVM):** envuelve las instancias normales (maximizando el margen desde el origen o con una hiperesfera mínima) para aislar la clase objetivo.
- **Basadas en ensembles (Isolation Forest, iForest):** bosques de “árboles de aislamiento” con divisiones aleatorias. Clave: **las anomalías son más fáciles de aislar** y caen en ramas más cortas (menor profundidad) $\rightarrow$ score de anomalía alto.

1.5 Tema 5. Aprendizaje Profundo. Fundamentos

1.5.1 Del Perceptrón al MLP

- **Redes Neuronales Artificiales (RNA):** núcleo del aprendizaje profundo; versátiles, potentes y escalables. Primer modelo: **McCulloch y Pitts (1943)**, con neuronas de entradas/salida binarias capaces de calcular proposiciones lógicas.
- **Perceptrón (Rosenblatt, 1957):** basado en la **unidad lógica de umbral (TLU/LTU)**. Calcula $z = w^\top x + b$ y le aplica una **función escalón** (Heaviside o signo). Equivale a una clasificación lineal binaria. Una **capa densa / totalmente conectada** conecta cada TLU con todas las entradas.
- **Regla de aprendizaje del perceptrón:** refuerza las conexiones que ayudan a reducir el error; converge **solo si los datos son linealmente separables**.
- **Limitación (Minsky y Papert, 1969):** el perceptrón no resuelve problemas no lineales (p. ej. la función **XOR**), como cualquier modelo lineal.
- **Perceptrón Multicapa (MLP):** apila una **capa de entrada**, una o más **capas ocultas** y una **capa de salida**. Resuelve el XOR y patrones complejos.

1.5.2 Retropropagación (Backpropagation)

- **Retropropagación:** combinación de **diferenciación automática en modo inverso** y **descenso de gradiente**. En dos pasadas calcula el gradiente del error respecto a cada parámetro.
- **Paso hacia delante (forward):** calcula y guarda las salidas de cada capa hasta la salida final.
- **Paso hacia atrás (backward):** mide, vía **regla de la cadena**, cuánto contribuye cada peso al error, propagando el gradiente de salida a entrada.
- **Paso de descenso de gradiente:** ajusta pesos y sesgos para reducir el error.
- **Detalles clave:** se procesa por **minilotes** (p. ej. 32 instancias); una pasada completa al conjunto es una **época**. Los pesos ocultos se **inician aleatoriamente** (si no, el entrenamiento falla). La **función escalón** se sustituyó por la **sigmoide** $\sigma(z) = 1/(1 + e^{-z})$ porque tiene derivada no nula y permite progresar al gradiente.
- **Tipos de salida del MLP:** regresión (una neurona por valor a predecir, sin activación o con ReLU); clasificación binaria (1 neurona sigmoide); multiclase (una neurona por clase + **softmax**, con pérdida de **entropía cruzada**).

1.5.3 Problema de los Gradientes Inestables

- **Gradientes que se desvanecen (vanishing):** al retropropagar, los gradientes se hacen cada vez más pequeños en las capas inferiores, que casi no se actualizan y no convergen.

Causa típica: sigmoide + mala inicialización (saturación).

- **Gradientes que explotan (exploding)**: crecen sin control y el algoritmo diverge; frecuente en redes recurrentes.
- **Inicialización Glorot (Xavier)**: mantiene igual la varianza de entradas y salidas (usa fan_{avg}). Variante **LeCun** (fan_{in}). **Inicialización He (Kaiming)**: para ReLU y variantes.

1.5.4 Funciones de Activación

Necesarias y **no lineales**: sin ellas, una pila de capas equivale a una sola transformación lineal.

- **Sigmoide / tanh**: forma de S. La **tanh** va de -1 a 1 (centrada en 0 , converge algo mejor que la sigmoide). Saturan en los extremos $\rightarrow$ gradientes que se desvanecen.
- **ReLU** = $\max(0, z)$: rápida y sin saturación para valores positivos; opción por defecto. Problema de las **ReLU moribundas** (neuronas que solo dan 0).
- **Leaky ReLU** = $\max(\alpha z, z)$: pendiente pequeña para $z < 0$ evita la muerte de neuronas. Variantes: **RReLU** (α aleatorio, regulariza) y **PReLU** (α aprendible).
- **ELU**: toma valores negativos (media más cercana a 0), suave en $z = 0$; mejora ReLU pero más lenta.
- **SELU (ELU escalada)**: en un MLP de solo capas densas, **autonormaliza** (media 0 , desviación 1) y resuelve los gradientes inestables; sujeta a restricciones estrictas.
- **GELU / SiLU / Swish**: variantes suaves de ReLU, no convexas ni monótonas; suelen rendir mejor en tareas complejas a mayor coste. $\text{Swish}_\beta(z) = z \sigma(\beta z)$.
- **Recomendación práctica**: ReLU por defecto en tareas simples; Swish/GELU en tareas complejas; SELU en MLP profundos.

1.5.5 Estabilización del Entrenamiento

- **Normalización por lotes (Batch Normalization, BN)**: centra en cero y normaliza las entradas de cada capa usando la media y desviación del minilote, y luego las **reescala y desplaza** con dos parámetros aprendibles (γ, β). En test usa medias móviles. Acelera el entrenamiento, reduce la sensibilidad a la inicialización y actúa como **regularizador**.
- **Recorte de gradiente (Gradient Clipping)**: recorta los gradientes para que no superen un umbral; mitiga la explosión, sobre todo en redes recurrentes.

1.5.6 Reutilización de Capas y Transfer Learning

- **Transfer Learning**: reutilizar capas de una red preentrenada en un problema similar; ahorra datos y tiempo y mejora la generalización.
- **Pretraining no supervisado**: con muchos datos sin etiquetar, se preentrena capa a capa (p. ej. con autoencoders) y luego se ajusta.
- **Pretraining en tarea auxiliar**: entrenar primero en una tarea con datos etiquetados abundantes y reutilizar lo aprendido.

1.5.7 Optimizadores Más Rápidos

- **SGD (Descenso de Gradiente Estocástico)**: actualización básica con la tasa de aprendizaje.
- **Momentum**: acumula un “impulso” de gradientes anteriores; acelera en direcciones consistentes.
- **Nesterov (NAG)**: mide el gradiente un poco más adelante en la dirección del momentum; suele converger algo más rápido.

- **AdaGrad**: adapta la tasa por parámetro; buena para problemas simples, pero se frena demasiado pronto en redes profundas.
- **RMSProp**: corrige a AdaGrad usando una media móvil de los gradientes al cuadrado.
- **Adam (Adaptive Moment Estimation)**: combina Momentum + RMSProp; opción por defecto muy robusta. Variante **AdaMax** (norma L_∞).
- **Programación del ritmo de aprendizaje (learning rate scheduling)**: reducir la tasa durante el entrenamiento. Estrategias: **power scheduling**, **exponencial**, **constante a trozos**, **performance scheduling** (baja al estancarse la validación) y **1-cycle** (sube y luego baja; logra *superconvergencia*).

1.5.8 Regularización en Redes Neuronales

- **Parada anticipada (early stopping)** y la propia **Batch Normalization** ya regularizan.
- **Regularización ℓ_1 / ℓ_2** : ℓ_2 restringe los pesos; ℓ_1 produce modelos dispersos (muchos pesos a 0).
- **Dropout**: en cada paso, cada neurona (salvo las de salida) se “apaga” con probabilidad p (tasa típica 10–50 %). Impide la coadaptación y hace la red más robusta; equivale a promediar un enorme ensemble de subredes. Tras entrenar, se compensan los pesos por $(1 - p)$.
- **MC Dropout**: aplica dropout también en test y promedia varias pasadas; mejora el rendimiento y estima la **incertidumbre** sin reentrenar.
- **Max-Norm**: restringe la norma de los pesos entrantes de cada neurona, $\|w\|_2 \leq r$.

1.5.9 Autoencoders

- **Autoencoder**: arquitectura **encoder–decoder** que aprende a reconstruir su entrada pasando por un **espacio latente** comprimido. Usos: compresión, reducción de dimensionalidad, detección de anomalías y pretraining no supervisado.
- **Denoising Autoencoder**: se corrompe la entrada a propósito (ruido o enmascarado) y la red aprende a reconstruir la versión limpia, forzando una codificación robusta.
- **ML vs Deep Learning**: el DL aprende las características automáticamente (*feature learning*) en lugar del diseño manual (*feature engineering*) del ML clásico.

1.6 Tema 6. Aprendizaje Profundo en Diferentes Tipos de Datos

1.6.1 Redes Neuronales Profundas (DNN)

- **DNN**: modelos con muchas capas que aprenden **representaciones jerárquicas** de los datos (características de bajo nivel $\rightarrow$ medio $\rightarrow$ alto). Más capas $\rightarrow$ funciones más complejas.

1.6.2 Redes Neuronales Convolucionales (CNN / ConvNets)

- **CNN**: red con al menos una capa de **convolución**; pensada para datos en forma de matriz/rejilla (imágenes).
- **Convolución**: operación local lineal con una **máscara** / **filtro** / **kernel**. El filtro se multiplica elemento a elemento sobre una región, se suman los productos y el resultado forma el **mapa de activación** / **mapa de características (feature map)**. Ejemplos clásicos: filtro Gaussiano (suavizado), Sobel (bordes).
- **Idea clave**: en una CNN los **coeficientes del filtro se aprenden** (son pesos), no los fija

un experto. (LeNet-5, LeCun 1998.)

- **Capa convolucional vs densa:** la densa conecta todo con todo (muchos pesos); la convolucional opera localmente con muchos menos pesos.

Ventajas de las ConvNets:

- **Conectividad dispersa:** cada unidad “ve” solo una región local $\rightarrow$ menos operaciones.
- **Compartición de parámetros (weight sharing):** el mismo filtro recorre toda la imagen $\rightarrow$ pocos parámetros (actúa como **regularización**).
- **Equivarianza a la traslación:** si el objeto se traslada, su representación se traslada igual ($f(g(x)) = g(f(x))$). No es equivariante a escala ni rotación.

Elementos y dimensiones:

- Las capas convolucionales se intercalan con **funciones de activación no lineales** (ReLU y variantes). Los filtros tienen la **misma profundidad** que el volumen de entrada.
- **Stride (paso):** desplazamiento del filtro. **Padding (relleno):** añadir bordes (p. ej. *zero-padding*) para conservar el tamaño y no reducir la dimensionalidad demasiado rápido.
- **Tamaño de salida:** $\text{Output} = ((N + 2P - F)/S) + 1$, con N entrada, F filtro, P padding, S stride.
- **Pooling (max / average):** reduce dimensionalidad e introduce **invarianza** a pequeñas traslaciones.
- **Flatten:** aplanar el volumen de feature maps a un vector para las capas densas finales.
- **Softmax:** activación final que da la probabilidad de cada clase.

1.6.3 Transformers

Para **secuencias** (texto, series temporales, audio, vídeo): elementos + orden + contexto. Cada elemento se convierte primero en un vector (**embedding**).

Antecedentes y sus límites:

- **Red densa:** trata la entrada como bloque fijo, ignora el orden y no admite longitud variable.
- **CNN:** capta patrones **locales** pero no bien las dependencias largas.
- **RNN (recurrentes):** procesan paso a paso con una memoria (estado oculto); pierden información lejana en secuencias largas.
- **LSTM:** añaden puertas (**olvido, entrada, salida**) para regular qué recordar; siguen siendo secuenciales (no paralelizables) y lentas.

Mecanismo de Atención:

- **Atención:** cada elemento (token) consulta directamente al resto y combina la información según su relevancia (suma ponderada), en lugar de comprimir todo en una memoria secuencial.
- **Query (Q), Key (K), Value (V):** de cada embedding se generan tres vectores. Q = “qué busco”, K = “qué ofrezco”, V = “qué información transmito”. Se comparan Q con K para decidir a quién atender y se combinan los V.
- **Scaled Dot-Product Attention:** compara Q con K, escala para estabilizar, aplica **softmax** (pesos que suman 1) y mezcla los V.
- **Self-attention:** Q, K y V salen de la misma secuencia; cada token se contextualiza con todos los demás (dependencias largas y directas).
- **Cross-attention:** Q de una secuencia, K y V de otra (conecta lo que se genera con la entrada).
- **Máscaras de atención:** impiden mirar tokens futuros (generación de texto).
- **Multi-head attention:** varias atenciones en paralelo, cada “cabeza” capta un tipo de relación (sintáctica, semántica, posiciones, dependencias lejanas).

Bloque y arquitectura Transformer:

- **Positional encoding:** la atención no conoce el orden $\rightarrow$ se suma información de posición al embedding. Entrada = contenido + posición.
- **Bloque Transformer:** Multi-head Attention (mezcla info entre tokens) + **Feed-Forward Network (FFN)** (transforma cada token por separado).
- **Conexiones residuales:** suman la entrada original a la transformada (estabilizan el gradiente, evitan olvidar).
- **Layer Normalization:** normaliza cada representación para un entrenamiento estable.
- **Encoder:** Self-attention + Add&Norm + FFN + Add&Norm; produce representaciones contextuales.
- **Decoder:** Masked self-attention + Cross-attention + FFN; genera la salida paso a paso.
- **Arquitecturas:** *encoder-only* (comprender/embeddings), *decoder-only* (generación; base de los LLM), *encoder-decoder* (completa, traducción).

Propiedades, coste y aplicaciones:

- **Ventajas:** capturan dependencias a largo plazo, **procesan en paralelo** (clave para escalar a miles de millones de parámetros) y aprenden relaciones flexibles.
- **Coste:** la atención es **cuadrática** $O(T^2)$ en la longitud T de la secuencia; exige mucha memoria y datos; sin posición no entiende el orden; difícil de interpretar.
- **LLM modernos:** Transformers escalados, con ajuste por instrucciones, alineamiento con preferencias humanas, contexto largo, multimodalidad y uso de herramientas.
- **Aplicaciones:** texto, **series temporales** (Informer, Autoformer, PatchTST, Chronos), **visión** (Vision Transformer: dividir la imagen en parches $\rightarrow$ embeddings $\rightarrow$ Transformer).

1.7 Tema 9. Aspectos Avanzados, Retos y Desafíos

1.7.1 Inteligencia Artificial Explicable (XAI)

- **Motivación:** la precisión no basta. Ejemplo clásico **LIME** (husky vs lobo): un clasificador con 94 % de acierto en test miraba la **nieve del fondo**, no el animal (*shortcut learning*). Hay que auditar **qué** aprende el modelo.
- **Tres motivos para XAI:** **confianza** (medicina, conducción autónoma), **depuración** (sesgos ocultos, *data leakage*, atajos) y **cumplimiento** legal (EU AI Act, derecho a explicación del GDPR).
- **RED vs BLUE XAI:** RED (orientada al modelo): investigar, explorar, depurar y garantizar seguridad. BLUE (orientada al humano): confianza, ética y explicaciones para el usuario.
- **Taxonomía (3 ejes):**
 - **Temporal:** **Pre-hoc** (modelo interpretable de origen: árboles, reglas, modelos lineales) vs **Post-hoc** (caja negra explicada a posteriori: LIME, SHAP).
 - **Alcance:** **Local** (una predicción) vs **Global** (todo el modelo).
 - **Modelo:** **Agnóstico** (cualquier arquitectura) vs **Específico** (requiere acceso interno).
- **Métodos clave:**
 - **LIME:** perturba la entrada localmente y ajusta un modelo simple que aproxima la caja negra en esa vecindad. Agnóstico pero **inestable**.
 - **SHAP:** valores de **Shapley** (teoría de juegos); reparte la contribución de cada característica de forma justa (eficiencia, simetría, linealidad, dummy). Coste **exponencial** en número de características.
 - **Contraejemplos (Counterfactuals):** “si tu ingreso fuera 5.000 € mayor, se aprobaría”; intuitivos y alineados con el razonamiento causal.

- **Integrated Gradients:** integra el gradiente desde una *baseline* hasta la entrada real (específico de redes neuronales).
- **LRP (Layer-wise Relevance Propagation):** propaga la relevancia hacia atrás capa a capa con reglas de conservación; produce *heatmaps* por píxel.
- **CRP:** extiende LRP de píxeles a **conceptos** de alto nivel.
- **ProtoPNet (basado en prototipos):** clasifica diciendo “esto se parece a este prototipo”; la explicación es el razonamiento del modelo (XAI intrínseca / RED).
- **Métricas:** *Quantus* (fidelidad, localización, complejidad, robustez); propuestas DASI: **REVEL**, **X-SHIELD** (regulariza ocultando características espurias), **STOOD-X** (XAI + detección OOD), **CUBIC** (detecta sesgos conceptuales).
- **EU AI Act:** para sistemas de **alto riesgo** exige trazabilidad, explicabilidad, supervisión humana y documentación. La XAI deja de ser opcional.
- **Desafíos:** las explicaciones post-hoc pueden ser engañosas (*confirmation bias*), no hay métrica única, alto coste (SHAP exponencial), XAI multimodal y de cadenas de agentes.

1.7.2 AI Safety y Detección Out-of-Distribution (OOD)

- **AI Safety:** campo interdisciplinar que previene accidentes, usos indebidos y daños de los sistemas de IA. **AI safety** $\neq$ **AI security**.
- **Robustez:** capacidad de mantener el rendimiento frente a perturbaciones y entradas **adversarias** a lo largo del ciclo de vida (anomalías, ataques adversarios, usos maliciosos, puertas traseras).
- **Mundo cerrado vs mundo abierto:** el supuesto de “mundo cerrado” (todas las clases vistas en entrenamiento) provoca sobreocupación del espacio y no se adapta a datos nuevos. El mundo real es **abierto**.
- **Detección Out-of-Distribution (OOD):** identificar entradas que no pertenecen a la distribución de entrenamiento (**ID = in-distribution**). Se distingue **Near-OOD** (parecido, p. ej. CIFAR-10 vs CIFAR-100) de **Far-OOD** (muy distinto, p. ej. EMNIST). Relacionado con el **Open Set Recognition**.

1.7.3 Aprendizaje Continuo (Continual Learning)

- **Definición:** paradigma donde el modelo aprende **secuencialmente** tareas a lo largo del tiempo. Los humanos lo hacen de forma natural; las redes, no.
- **Olvido catastrófico (Catastrophic Forgetting):** al entrenar la Tarea B, el rendimiento en la Tarea A cae drásticamente (caída de *accuracy*).
- **Escenarios:** **Task-Incremental** (se sabe a qué tarea pertenece el test), **Domain-Incremental** (misma tarea, distinta distribución), **Class-Incremental** (nuevas clases en cada tarea, el más difícil).
- **Backward Transfer (BWT):** métrica del olvido: $BWT = \frac{1}{N-1} \sum_{j=1}^{N-1} [A(N, j) - A(j, j)]$. $BWT < 0$ olvido; $= 0$ sin olvido; > 0 transferencia positiva.
- **Estrategias:**
 - **EWC (Elastic Weight Consolidation):** penaliza cambiar los pesos importantes para tareas previas, ponderando por la **Matriz de Información de Fisher (FIM)**. A diferencia de ℓ_2 puro (que penaliza todos los pesos por igual), protege selectivamente.
 - **LoRA y variantes:** adaptadores de bajo rango ($B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$) que congelan los pesos base W_0 y entrenan un adaptador por tarea. Variantes: **O-LoRA** (ortogonaliza adaptadores), **LoRA-Pro**, *Adapter Merging*.
- **Machine Unlearning:** problema inverso: hacer que un modelo **olvide** información específica (p. ej. por el “derecho al olvido”, GDPR Art. 17). Reentrenar desde cero es inviable.

- **SISA (Sharded, Isolated, Sliced, Aggregated)**: trocea los datos; para olvidar un dato basta reentrenar el *shard/slice* afectado, dejando intactos los demás.
- **Algoritmo SSD (Selective Synaptic Dampening)**: usa la FIM para identificar y **amortiguar (dampening)** los pesos específicos del dato a olvidar.
- **Reto**: verificar el olvido (distinguir un dato olvidado de uno nunca visto).

1.7.4 Causalidad en Aprendizaje Automático

- **Correlación $\neq$ Causalidad**: ejemplo clásico helados vs ahogamientos: su correlación positiva es **espuria**; el **calor** es una **variable confusora (confounder)** que aumenta ambos por separado.
- **Shortcut learning / correlaciones espurias**: el modelo aprende atajos (la nieve para “lobo”, el fondo “playa” para una vaca) que no generalizan.
- **Causal Discovery**: inferir la estructura del **grafo causal (DAG, grafo acíclico dirigido)** a partir de dependencias e independencias condicionales, cuando no se puede intervenir. Requisitos: **suficiencia causal** (haber observado todos los confusores) y ausencia de ciclos.
- **Causal Representation Learning**: separar el **espacio latente en contenido** Z_C (mecanismos invariantes: la vaca) y **estilo** Z_S (factores espurios: el fondo/playa). Mediante **supervisión débil** e intervenciones sobre Z_S , se aprenden representaciones invariantes.
- **V-REx (Variance Risk Extrapolation)**: $R_{V-REx} = \sum_e R_e + \beta \cdot \text{Var}(\{R_e\})$. Minimiza el riesgo medio y la **varianza** del rendimiento entre entornos, forzando representaciones Z_C invariantes que ignoran los factores espurios Z_S .

Claves de examen (Tema 9). XAI: distinguir pre-hoc/post-hoc, local/global, agnóstico/específico; LIME (inestable, local, agnóstico), SHAP (Shapley, exponencial). OOD: mundo abierto, Near vs Far. Continual learning: olvido catastrófico, EWC+Fisher, BWT negativo = olvido. Causalidad: confounder $\rightarrow$ correlación espuria; separar contenido invariante del estilo espurio.