




Ingeniería Informática + ADE

Universidad de Granada (UGR)


Autor: Ismael Sallami Moreno

Asignatura: Econometría




Índice

1. Soluciones a los Ejercicios Propuestos	3
2. Modelo Econométrico	14
2.1. Análisis_de_Multicolinealidad	14
2.2. Modelo_Preliminar	18
3. Referencias	23



1 Soluciones a los Ejercicios Propuestos






Ingeniería Informática + ADE

Universidad de Granada (UGR)


Autor: Ismael Sallami Moreno

Asignatura: Econometría: Ejercicios Propuestos Solucionados



Índice

1. Tema 2	3
1.1. Ejercicio 1	3
1.2. Ejercicio 2	3
1.3. Ejercicio 3	4
1.4. Ejercicio 4	4
1.5. Ejercicio 5	5
1.6. Ejercicio 6	5
1.7. Ejercicio 7	8
1.8. Ejercicio 8	9
1.9. Resto de ejercicios	10
2. Tema 3	10



1 Tema 2

1.1. Ejercicio 1

Enunciado

1. Detalle el orden de las matrices y vectores de un modelo econométrico con 3 variables explicativas más el termino constante y 50 observaciones.

Solución

Para ello vamos a suponer que la variable explicada es Y_t , si denotamos a las demás variables explicativas con la simbología β_i , siendo i el índice de la variable explicativa, podemos nombrar a la matriz de variables explicativas como X y a la matriz de coeficientes como β , y nos queda la siguiente ecuación:

$$Y_t = \beta_0 + \beta_1 X_{1t} + \beta_2 X_{2t} + \beta_3 X_{3t} + \beta_4 X_{4t} + u_t \quad (1)$$

De manera más sintética, nos quedaría:

$$\vec{y} = X\vec{\beta} + \vec{u} \quad (2)$$

Por lo que podemos decir:

- Orden de la matriz $\vec{y} = (50 \times 1)$
- Orden de la matriz $X = (50 \times 4)$
- Orden de la matriz $\vec{\beta} = (4 \times 1)$
- Orden de la matriz $\vec{u} = (50 \times 1)$

1.2. Ejercicio 2

Enunciado

2. Ponga un ejemplo de una matriz X con un término constante y tres variables explicativas de manera que el modelo no cumpla la condición del rango completo por columnas.

Solución

Una matriz X con un término constante y tres variables explicativas que no cumpla la condición del rango completo por columnas es aquella en la cual al menos una de las columnas es una combinación lineal de las demás. Por ejemplo:

$$X = \begin{pmatrix} 1 & 2 & 3 & 6 \\ 1 & 4 & 5 & 9 \\ 1 & 7 & 8 & 15 \end{pmatrix}$$

En este ejemplo, la cuarta columna es la suma de la segunda y la tercera columnas, lo que significa que el rango de la matriz no es completo.

1.3. Ejercicio 3

Enunciado

3. Razone qué componentes del modelo econométrico tienen carácter estocástico (aleatorio) y cuáles tienen carácter determinista (fijo).

Solución

En un modelo econométrico típico, hay tanto componentes deterministas como estocásticos.

- **Componentes deterministas (fijos):**

- **Término constante:** Este es el intercepto del modelo, representado generalmente como β_0 , y es fijo.
- **Coeficientes de las variables explicativas:** Representados como $\beta_1, \beta_2, \dots, \beta_k$, son los parámetros del modelo que permanecen fijos una vez estimados.

- **Componentes estocásticos (aleatorios):**

- **Término de error:** Representado como ϵ_i o u_i , este componente capta la variabilidad no explicada por el modelo y es aleatorio.

Por ejemplo, en el modelo lineal clásico:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \epsilon_i$$

Los componentes deterministas son $\beta_0, \beta_1, \dots, \beta_k$ y los componentes estocásticos son los ϵ_i .

1.4. Ejercicio 4

Enunciado

Ponga un ejemplo de una matriz de varianzas-covarianzas de las perturbaciones de un modelo con heterocedasticidad.

Solución

En un modelo con heterocedasticidad, la varianza de los errores no es constante a lo largo de las observaciones. Un ejemplo de matriz de varianzas-covarianzas de las perturbaciones podría ser:

$$\Sigma = \begin{pmatrix} \sigma_1^2 & 0 & 0 \\ 0 & \sigma_2^2 & 0 \\ 0 & 0 & \sigma_3^2 \end{pmatrix}$$

donde σ_1^2 , σ_2^2 y σ_3^2 son las varianzas de los errores en las diferentes observaciones y son diferentes entre sí, reflejando la presencia de heterocedasticidad.

Por ejemplo:

$$\Sigma = \begin{pmatrix} 4 & 0 & 0 \\ 0 & 9 & 0 \\ 0 & 0 & 16 \end{pmatrix}$$

En este caso, $\sigma_1^2 = 4$, $\sigma_2^2 = 9$, y $\sigma_3^2 = 16$, lo cual indica que las perturbaciones tienen varianzas distintas.

1.5. Ejercicio 5

Enunciado

Ponga un ejemplo de una matriz de varianzas-covarianzas de las perturbaciones de un modelo con autocorrelación.

Solución

En un modelo con autocorrelación, la matriz de varianzas-covarianzas de las perturbaciones podría tener la siguiente forma:

$$\Sigma = \begin{pmatrix} \sigma^2 & \rho\sigma^2 & \rho^2\sigma^2 \\ \rho\sigma^2 & \sigma^2 & \rho\sigma^2 \\ \rho^2\sigma^2 & \rho\sigma^2 & \sigma^2 \end{pmatrix}$$

donde σ^2 es la varianza de los errores y ρ es el coeficiente de autocorrelación.

Un ejemplo específico podría ser:

$$\Sigma = \begin{pmatrix} 1 & 0,5 & 0,25 \\ 0,5 & 1 & 0,5 \\ 0,25 & 0,5 & 1 \end{pmatrix}$$

En este caso, $\sigma^2 = 1$ y $\rho = 0,5$. Esto muestra que las perturbaciones están correlacionadas entre sí, reflejando la presencia de autocorrelación en el modelo.

1.6. Ejercicio 6

Enunciado

6. Se considera la posibilidad de introducir nuevas variables explicativas en el modelo de la curva de Phillips (EJERCICIO 1 de la relación de ejercicios resueltos) y para ello se recoge información sobre la renta nacional disponible neta a precios de mercado por habitante (X_2) y la renta nacional disponible neta (X_3).

Años	X_2	X_3
2006	18614	825737
2007	19403	877724
2008	19492	896295
2009	18719	867972
2010	18706	871015
2011	18229	851948
2012	17822	833445
2013	17691	824821
2014	18029	837556
2015	18828	873766

Se pide:

- Estimar el modelo incluyendo la variable X_2 . (**Sol.** $\hat{y} = 165,78 - 1,48X_1 - 0,0077X_2$)
- Estimar el modelo incluyendo las variables X_2 y X_3 . (**Sol.** $\hat{y} = 120,97 - 0,77X_1 - 0,017X_2 + 0,00025X_3$)
- Comparar ambos modelos. (**Sol.** $R_1^2 = 0,7097 < R_2^2 = 0,96$; $AIC_1 = 2,83 > AIC_2 = 0,8920$)

Solución

- Modelo incluyendo la variable X_2 :

$$\hat{y} = 165,78 - 1,48X_1 - 0,0077X_2$$

Para estimar este modelo, hemos utilizado una regresión lineal múltiple donde X_1 es la variable original del modelo de la curva de Phillips y X_2 es la nueva variable explicativa añadida (renta nacional disponible neta a precios de mercado por habitante). Los coeficientes 165,78 (intercepto), $-1,48$ (coeficiente de X_1), y $-0,0077$ (coeficiente de X_2) han sido estimados a partir de los datos proporcionados usando el método de mínimos cuadrados ordinarios (MCO).

Para ello:

- Debemos de calcular los siguiente valores:

$$\begin{aligned} & \sum_{i=1}^{10} X_{1_i} \\ & \sum_{i=1}^{10} X_{1_i}^2 \\ & \sum_{i=1}^{10} X_{2_i} \\ & \sum_{i=1}^{10} X_{2_i}^2 \\ & \sum_{i=1}^{10} X_{1_i} Y_t \\ & \sum_{i=1}^{10} X_{2_i} Y_t \\ & \sum_{i=1}^{10} Y_t \end{aligned}$$

- Con estos valores calculamos la siguiente matriz:

$$X'X = \begin{pmatrix} n & \sum_{i=1}^{10} X_{1_i} & \sum_{i=1}^{10} X_{2_i} \\ \sum_{i=1}^{10} X_{1_i} & \sum_{i=1}^{10} X_{1_i}^2 & \sum_{i=1}^{10} X_{1_i} X_{2_i} \\ \sum_{i=1}^{10} X_{2_i} & \sum_{i=1}^{10} X_{1_i} X_{2_i} & \sum_{i=1}^{10} X_{2_i}^2 \end{pmatrix}$$

- Y calculamos de manera análoga la siguiente matriz:

$$X'Y = \begin{pmatrix} \sum_{i=1}^{10} Y_t \\ \sum_{i=1}^{10} X_{1_i} Y_t \\ \sum_{i=1}^{10} X_{2_i} Y_t \end{pmatrix}$$

- Por último, calculamos la matriz del estimador, aplicando el estimador de MCO:

$$\hat{\beta} = (X'X)^{-1}X'Y$$

- **Modelo incluyendo las variables X_2 y X_3 :**

$$\hat{y} = 120,97 - 0,77X_1 - 0,017X_2 + 0,00025X_3$$

De manera similar, para este modelo se ha llevado a cabo una regresión lineal múltiple incluyendo ahora tanto X_2 como X_3 (renta nacional disponible neta total). Los coeficientes 120,97 (intercepto), $-0,77$ (coeficiente de X_1), $-0,017$ (coeficiente de X_2), y 0,00025 (coeficiente de X_3) han sido obtenidos mediante el método de MCO.

- **Comparación de ambos modelos:**

- Coeficiente de determinación ajustado (R^2):

$$R_1^2 = 0,7097 \quad (\text{modelo con } X_2 \text{ solamente}) < R_2^2 = 0,96 \quad (\text{modelo con } X_2 \text{ y } X_3)$$

El coeficiente de determinación ajustado (R^2) indica el porcentaje de variabilidad en la variable dependiente que es explicado por las variables independientes. En este caso, el modelo que incluye X_2 y X_3 explica el 96 % de la variabilidad en Y , mientras que el modelo con sólo X_2 explica el 70,97 %.

- Criterio de Información de Akaike (AIC):

$$AIC_1 = 2,83 \quad (\text{modelo con } X_2 \text{ solamente}) > AIC_2 = 0,8920 \quad (\text{modelo con } X_2 \text{ y } X_3)$$

El AIC es una medida de la calidad del modelo relativo a otros modelos. Un menor AIC indica un mejor ajuste del modelo. En este caso, el modelo con X_2 y X_3 tiene un AIC menor (0,8920) comparado con el modelo que incluye sólo X_2 (2,83), indicando que el modelo con ambas variables explicativas X_2 y X_3 es superior en términos de ajuste.

Para realizar el apartado c), hemos usado estas funciones:

$$R^2 = \frac{\frac{1}{n} \cdot \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\frac{1}{n} \cdot \sum_{i=1}^n (Y_i - \bar{Y})^2} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = \frac{SCE}{SCT} \quad (3)$$

$$SCE = \hat{\beta}^T \cdot X'Y - 10 \cdot \left(\frac{\sum_{i=1}^{10} Y}{n} \right)^2 \quad (4)$$

Y para el cálculo de AIC:

$$AIC = \ln\left(\frac{SCR}{n}\right) \cdot \frac{2k}{n} \quad (5)$$

Siendo k el número de variables explicativas y n el número de observaciones. Para encontrar los cálculos pincha aquí y visualiza el archivo en formato .xlsx

1.7. Ejercicio 7

Enunciado

En la siguiente tabla se recogen las ventas de seis empresas informáticas en función del número de comerciales:

v_t	109	111	132	140	169	180
c_t	12	15	17	18	19	20

Se pide:

- Plantear el modelo econométrico y estimar los coeficientes por mínimos cuadrados ordinarios. Interpretación de los coeficientes estimados. (Sol. $\hat{v}_t = -13,56 + 9,132c_t$)
- Calcular el coeficiente de determinación e interpretarlo. ($R^2 = 0,8294$)
- Se estima un modelo alternativo añadiendo como variable explicativa el gasto en publicidad de cada empresa, obteniendo un coeficiente de determinación igual a 0,93363. Concluya de forma razonada si este modelo es mejor que el anterior. (Sol. $\bar{R}_1^2 = 0,78675 < \bar{R}_2^2 = 0,8893$)

Solución

Para ello debemos de realizar los mismo pasos que en el ejercicio anterior para la resolución del apartado a y b, y para el c basta con calcular el coeficiente de determinación ajustado y compararlos (Usando las fórmulas expuestas anteriormente).

1.8. Ejercicio 8

Enunciado

Se tiene la siguiente información correspondiente al curso 2010/2011 sobre el número de becarios en la enseñanza universitaria (Y), el alumnado matriculado en estudios de 1er. y 2º ciclo y de grado (X_1) y el importe en miles de euros de las becas (X_2). Se pide:

CCAA	Y	X_1	X_2
Andalucía	97.105	234.851	266.222,60
Aragón	9.294	31.063	19.648,80
Asturias	6.882	23.746	16.048,00
Baleares	4.251	15.488	8.224,60
Canarias	19.125	41.546	45.084,30
Cantabria	4.078	8.157	5.011,80
Castilla y León	27.307	78.694	75.124,10
Castilla - La Mancha	8.380	30.856	20.717,00
Cataluña	51.965	179.637	138.077,10
Valencia	49.805	148.671	115.219,30
Extremadura	12.088	22.747	35.506,00
Galicia	24.500	64.262	66.019,40
Madrid	64.563	239.389	134.341,50
Murcia	15.549	42.573	37.177,90
Navarra	4.669	14.705	10.372,50
País Vasco	15.322	53.419	26.789,40
Rioja, La	1.761	8.119	3.345,10
A distancia	20.557	212.021	16.491,60

- Estimar los parámetros. (Sol. $\hat{y} = 528,077 + 0,09X_1 + 0,2936X_2$)
- Obtener el coeficiente de determinación. (Sol. $R^2 = 0,994$)
- Obtener el coeficiente de determinación corregido. (Sol. $\bar{R}^2 = 0,993$)
- Calcular el criterio de Akaike. (Sol. $AIC = 328,9392$)

Solucion

Similar a los ejercicios anteriores en cuanto al cálculo de AIC y BIC basta con aplicar las fórmulas expuestas en la teoría.

$$AIC = \ln\left(\frac{SCR}{n}\right) + \frac{2k}{n} \quad (6)$$

$$BIC = \ln\left(\frac{SCR}{n}\right) + \frac{k}{n} \cdot \ln(n) \quad (7)$$

1.9. Resto de ejercicios

Para la resolución del resto de ejercicios basta con seguir la misma lógica que en los ejercicios anteriores, aplicando las fórmulas expuestas en la teoría. Puede servirse de la hoja de cálculo que se ha proporcionado en el apartado anterior para realizar los cálculos de manera más sencilla.

2 Tema 3

2 Modelo Econométrico

2.1. Análisis_de_Multicolinealidad

Análisis de Multicolinealidad

José Ángel Carretero Montes
Ismael Sallami Moreno
Fernando José Gracia Choin

Noviembre 2024

1 Análisis de la Multicolinealidad

1.1 Obtención de las principales medidas de diagnóstico de la multicolinealidad

El análisis de multicolinealidad se llevó a cabo utilizando dos indicadores principales:

- **Número de Condición (Cond. No.):** Calculado como $\sqrt{\lambda_{\max}/\lambda_{\min}}$, donde $\lambda_{\max}$ y $\lambda_{\min}$ representan los valores propios máximo y mínimo respectivamente de la matriz de covarianzas de las variables independientes. En este caso, el número de condición obtenido fue 28.49, lo cual es inferior al umbral crítico de 30. Por lo tanto, se considera que los niveles generales de multicolinealidad son aceptables.
- **Factor de Inflación de la Varianza (FIV):** Calculado para cada variable como $FIV = \frac{1}{1-R_i^2}$, donde R_i^2 es el coeficiente de determinación de la regresión de la variable i sobre todas las demás variables. Los valores obtenidos fueron los siguientes:

Variable	FIV
Gender	760.64
Age	1.89
Height	1.93
family_history_with_overweight	2.18
FAVC	1.33
FCVC	1.16
NCP	1.15
CAEC	1.11
SMOKE	1.19
CH2O	1.04
SCC	1.12
FAF	1.10
TUE	1.22
CALC	1.13
MTRANS	1.67
NObeyesdad	1.33

Table 1: Valores de FIV para cada variable

1.2 Clasificación de la multicolinealidad existente

A partir del análisis del FIV, se pueden clasificar las variables de la siguiente manera:

- **Baja multicolinealidad:** Las variables con $FIV < 5$, como la mayoría de las incluidas en el análisis, presentan baja multicolinealidad y no representan un problema para el modelo.

- **Alta multicolinealidad:** La variable **Gender** muestra un valor de FIV extremadamente alto (760.64), indicando una fuerte dependencia lineal con otras variables. Este nivel de multicolinealidad es crítico y debe ser abordado.

1.2.1 Decisión de no eliminar la variable Gender a pesar de su alto índice de FIV

La variable **Gender** fue identificada como un factor crítico de multicolinealidad en el modelo, con un Factor de Inflación de la Varianza (FIV) extremadamente alto de 760.64. Este valor excede significativamente el umbral comúnmente aceptado de 10, lo que indica una fuerte dependencia lineal entre **Gender** y otras variables independientes del modelo. La inclusión de esta variable, por tanto, genera múltiples problemas de multicolinealidad que detallaremos más adelante.

Sin embargo, al evaluar el impacto de eliminar **Gender** en el desempeño general del modelo, observamos una reducción significativa en el coeficiente de determinación (R^2). Dado que R^2 mide la proporción de la variabilidad explicada por el modelo, esta disminución sugiere que **Gender** aporta información valiosa para las predicciones. Por lo tanto, decidimos mantener esta variable en el modelo, priorizando su capacidad explicativa a pesar de los problemas de multicolinealidad.

- Aunque la eliminación de **Gender** reduce el **Número de Condición** (Cond. No.) a niveles aceptables y mejora los valores de **FIV** de las demás variables, la pérdida en R^2 comprometería la calidad general del modelo.
- Se consideran alternativas como el uso de técnicas de regularización (ridge o lasso) para mitigar los efectos de la multicolinealidad sin eliminar la variable.

En conclusión, mantener la variable **Gender** permite preservar la capacidad explicativa del modelo, aunque conlleva un compromiso en términos de multicolinealidad. Este balance entre interpretabilidad y desempeño predictivo es fundamental para abordar los objetivos del análisis.

1.2.2 Matriz de correlación




Figure 1: Matriz de correlación

Interpretación de la Matriz de Correlación

En la matriz de correlación observamos que la variable **Height** presenta un valor de correlación relativamente alto con respecto a otras variables del modelo. Aunque este nivel de correlación podría sugerir la posibilidad de eliminar esta variable para mejorar la multicolinealidad, al llevar a cabo este procedimiento se observó una disminución significativa en el coeficiente de determinación ajustado (R^2). Esta reducción implica una pérdida de capacidad explicativa del modelo, lo que contrarrestaría los posibles beneficios de eliminar **Height**. Por lo tanto, se decidió mantener esta variable dentro del modelo para preservar su capacidad predictiva y explicativa.

1.3 Análisis de las posibles consecuencias derivadas de la existencia de multicolinealidad

La presencia de alta multicolinealidad puede tener las siguientes consecuencias en el modelo:


- **Inestabilidad de los coeficientes de regresión:** Los coeficientes estimados para las variables multicolineales pueden presentar grandes variaciones ante pequeños cambios en los datos, reduciendo la fiabilidad del modelo.
- **Incremento de la varianza:** Los altos valores de FIV implican un aumento en la varianza de los coeficientes estimados, lo que puede llevar a errores estándar más grandes y a una disminución en la significancia estadística de las variables.
- **Redundancia:** Las variables altamente correlacionadas aportan información redundante, lo que puede complicar la interpretación del modelo.

1.4 Mitigación de la multicolinealidad

Para mitigar los efectos de la multicolinealidad, se pueden aplicar las siguientes medidas:

- **Eliminación de variables redundantes:** Dado el alto FIV de la variable **Gender**, se podría evaluar la posibilidad de excluirla del modelo si su aportación al análisis no es crítica.
- **Transformaciones:** Aplicar transformaciones lineales como Análisis de Componentes Principales (PCA) para reducir la dimensionalidad y eliminar la correlación entre las variables.
- **Recolección de nuevos datos:** Ampliar el tamaño de la muestra puede reducir los efectos de la multicolinealidad, especialmente si las variables redundantes se distribuyen de forma más heterogénea en los nuevos datos.
- **Regularización:** Métodos como la regresión ridge o lasso pueden ser útiles para manejar la multicolinealidad al penalizar los coeficientes altamente correlacionados.

2.2. Modelo_Preliminar



Estimación del Modelo Preliminar

José Ángel Carretero Montes
Ismael Sallami Moreno
Fernando José Gracia Choin

Octubre 2024

1 Estimación del Modelo Preliminar

El modelo de regresión lineal múltiple estimado se representa de la siguiente forma:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + u_i$$

donde:

- Y_i es la variable dependiente (Peso en este caso),
- $X_{1i}, X_{2i}, \dots, X_{ki}$ son las variables independientes (Altura, Edad, Género, etc.),
- β_0 es el término constante,
- u_i es el término de error aleatorio.

Los resultados preliminares de la regresión OLS para este modelo se presentan en la siguiente tabla:

OLS Regression Results						
=====						
Dep. Variable:	Weight	R-squared:	0.576			
Model:	OLS	Adj. R-squared:	0.572			
Method:	Least Squares	F-statistic:	177.5			
Date:	Tue, 22 Oct 2024	Prob (F-statistic):	0.00			
Time:	07:09:09	Log-Likelihood:	-8983.6			
No. Observations:	2111	AIC:	1.800e+04			
Df Residuals:	2094	BIC:	1.810e+04			
Df Model:	16					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

const	-207.9919	10.281	-20.230	0.000	-228.155	-187.829
Gender	-4.7575	1.026	-4.639	0.000	-6.769	-2.746
Age	0.7403	0.082	9.069	0.000	0.580	0.900
Height	125.2342	5.894	21.247	0.000	113.675	136.793
family_history_with_overweight	17.0101	1.115	15.259	0.000	14.824	19.196
FAVC	7.9764	1.252	6.373	0.000	5.522	10.431
FCVC	9.0480	0.750	12.070	0.000	7.578	10.518
NCP	1.0882	0.506	2.151	0.032	0.096	2.080
CAEC	8.2303	0.869	9.470	0.000	6.526	9.935
SMOKE	-0.2063	2.664	-0.077	0.938	-5.430	5.017
CH2O	1.3156	0.645	2.041	0.041	0.052	2.580
SCC	-6.9609	1.878	-3.706	0.000	-10.645	-3.277
FAF	-2.7221	0.484	-5.619	0.000	-3.672	-1.772
TUE	-1.6760	0.652	-2.571	0.010	-2.954	-0.398
CALC	-4.1794	0.764	-5.472	0.000	-5.677	-2.682
MTRANS	3.6899	0.382	9.658	0.000	2.941	4.439
NObeyesdad	2.3519	0.220	10.680	0.000	1.920	2.784
=====						
Omnibus:	37.671	Durbin-Watson:	0.741			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	21.704			
Skew:	-0.047	Prob(JB):	1.94e-05			
Kurtosis:	2.512	Cond. No.	812.			
=====						

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

2 Interpretación de los Estimadores

A continuación, se ofrece una interpretación de los coeficientes más relevantes del modelo:

- **Constante:** El coeficiente de la constante es -207.99, lo que indica el valor estimado del peso cuando todas las variables independientes son 0. Aunque en la práctica, esta interpretación rara vez es útil, ya que variables como la altura no pueden ser cero.
- **Género:** El coeficiente de Género es -4.757. Esto indica que, manteniendo todas las demás variables constantes, ser mujer (asumiendo que el género está codificado como 1 para mujeres y 0 para hombres) está asociado con una reducción de 4.76 unidades en el peso.
- **Edad:** El coeficiente de 0.7403 indica que por cada año adicional de edad, el peso aumenta en promedio 0.74 unidades, manteniendo las demás variables constantes.
- **Altura:** El coeficiente de altura es 125.23, lo que sugiere que, por cada unidad adicional de altura, el peso aumenta en 125.23 unidades, manteniendo todas las demás variables constantes.
- **Historial Familiar de Sobrepeso:** El coeficiente es 17.01, indicando que tener antecedentes familiares de sobrepeso está asociado con un aumento promedio de 17.01 unidades en el peso.
- **FAVC (Comida grasa frecuente):** El coeficiente positivo de 7.976 indica que consumir frecuentemente comida grasa aumenta el peso en 7.976 unidades, manteniendo todo lo demás constante.
- **FCVC (Consumo de verduras):** El coeficiente de 9.048 indica que un mayor consumo de verduras está asociado con un aumento de 9.05 unidades en el peso, lo cual es inesperado y podría requerir mayor análisis.
- **NCP (Número de comidas diarias):** El coeficiente de 1.088 sugiere que, por cada comida adicional consumida al día, el peso aumenta en promedio 1.088 unidades.
- **CAEC (Comer entre comidas):** El coeficiente de 8.230 sugiere que comer entre comidas aumenta el peso en 8.23 unidades, manteniendo el resto de factores constantes.
- **Fumar (SMOKE):** El coeficiente es -0.206, indicando que fumar no tiene un impacto estadísticamente significativo en el peso, dado su alto valor p ($P > 0.05$).
- **Consumo de agua (CH2O):** El coeficiente de 1.315 indica que por cada unidad adicional de agua consumida, el peso aumenta en 1.315 unidades, lo cual puede ser contraintuitivo y merece un análisis más profundo.
- **SCC (Conteo de calorías):** El coeficiente de -6.961 sugiere que el control de calorías está asociado con una reducción del peso en 6.96 unidades, lo cual es consistente con lo esperado.
- **FAF (Actividad física):** El coeficiente de -2.722 indica que un aumento en la actividad física reduce el peso en promedio 2.72 unidades, manteniendo constantes las demás variables.
- **TUE (Uso de tecnología):** El coeficiente de -1.676 sugiere que más tiempo usando tecnología está asociado con una reducción del peso, lo cual puede requerir más análisis.
- **CALC (Consumo de alcohol):** El coeficiente de -4.179 indica que consumir alcohol está asociado con una reducción del peso, lo cual es un resultado inesperado.
- **MTRANS (Medios de transporte):** El coeficiente de 3.689 indica que el uso de ciertos medios de transporte se asocia con un aumento del peso en 3.689 unidades.
- **NObeyesdad (Nivel de obesidad):** El coeficiente de 2.351 indica que un mayor nivel de obesidad previo está asociado con un aumento de 2.351 unidades en el peso.

3 Medidas de Bondad de Ajuste

Para evaluar la calidad del modelo estimado, utilizamos diversas medidas de bondad de ajuste que nos permiten juzgar cómo de bien el modelo ajusta a los datos observados. Las medidas que se consideran son el coeficiente de determinación R^2 , el coeficiente de determinación ajustado R^2_{ajustado} , y los criterios de información de Akaike (AIC) y Schwarz (BIC).

3.1 Coeficiente de Determinación R^2

El coeficiente de determinación R^2 mide la proporción de la varianza total de la variable dependiente que es explicada por el modelo. En otras palabras, indica qué tan bien las variables independientes explican las variaciones en la variable dependiente.

$$R^2 = 1 - \frac{\text{Suma de Cuadrados de los Residuos (SCR)}}{\text{Suma Total de Cuadrados (SCT)}}$$

Donde:

- La **Suma Total de Cuadrados (SCT)** mide la variabilidad total de la variable dependiente en torno a su media:

$$\text{SCT} = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

- La **Suma de Cuadrados de los Residuos (SCR)** mide la variabilidad que no ha sido explicada por el modelo:

$$\text{SCR} = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Para este modelo, se ha obtenido un R^2 de **0.576**, lo que significa que el **57.6%** de la variabilidad del peso puede explicarse por las variables independientes incluidas en el modelo. Aunque este valor indica que el modelo captura más de la mitad de la variación en el peso, hay un **42.4%** de la variabilidad que no está siendo explicada, lo que sugiere que existen otros factores que no se han tenido en cuenta o que pueden requerir un tratamiento más sofisticado.

3.2 Coeficiente de Determinación Ajustado R^2_{ajustado}

El coeficiente de determinación ajustado R^2_{ajustado} ajusta el R^2 para el número de predictores en el modelo. Esto es importante porque el R^2 tiende a aumentar al agregar más variables, incluso si esas variables no tienen una relación significativa con la variable dependiente. El R^2_{ajustado} penaliza el uso de variables adicionales, lo que permite obtener una mejor medida del poder explicativo real del modelo.

$$R^2_{\text{ajustado}} = 1 - \frac{\frac{\text{SCR}}{n-k}}{\frac{\text{SCT}}{n-1}}$$

Donde:

- n es el número de observaciones,
- k es el número de variables explicativas incluidas en el modelo.

El valor obtenido para el R^2_{ajustado} es de **0.572**, lo cual es muy cercano al valor de R^2 . Esto indica que el modelo no está sobreajustado (es decir, no ha añadido variables innecesarias), ya que el R^2_{ajustado} no disminuye considerablemente respecto al R^2 original.

3.3 Criterio de Información de Akaike (AIC)

El criterio de información de Akaike (AIC) es una medida que penaliza la complejidad del modelo. Es útil cuando se comparan varios modelos, ya que tiene en cuenta tanto la bondad del ajuste (medida por la suma de cuadrados de los residuos) como el número de parámetros estimados. Cuanto menor sea el valor del AIC, mejor es el modelo.

$$\text{AIC} = \ln \left(\frac{\text{SCR}}{n} \right) + \frac{2k}{n}$$

Donde:

- n es el número de observaciones,
- k es el número de parámetros estimados (incluyendo la constante).

En este modelo, el valor de **AIC** es **1.800×10^4** . Para comparar diferentes modelos, se elegiría aquel que minimice este valor. Un menor AIC indica que el modelo no solo ajusta mejor los datos, sino que también evita la inclusión innecesaria de parámetros.

3.4 Criterio de Información de Schwarz (BIC)

El criterio de información bayesiano de Schwarz (BIC) es otra medida que, como el AIC, penaliza la complejidad del modelo, pero de manera más estricta. El BIC introduce una penalización más fuerte por la inclusión de más variables en el modelo, lo que lo hace útil para evitar el sobreajuste.

$$BIC = \ln \left(\frac{SCR}{n} \right) + \frac{k}{n} \cdot \ln(n)$$

En este modelo, el valor del **BIC** es 1.810×10^4 . Al igual que con el AIC, un menor valor de BIC es preferible, y su objetivo es identificar el modelo que ofrece el mejor ajuste sin sobrecargarlo con demasiadas variables.

3.5 Comparación y Selección del Mejor Modelo

Las medidas de bondad de ajuste nos indican diferentes aspectos de la calidad del modelo. En resumen:

- Un R^2 de 0.576 indica que el modelo es razonablemente bueno para explicar la variabilidad del peso.
- El R^2_{ajustado} de 0.572 sugiere que no hay un sobreajuste significativo.
- Los criterios de información AIC y BIC nos permiten comparar este modelo con otros posibles modelos. Si generamos otros modelos, escogeremos aquel con los valores más bajos de AIC y BIC.

En función de estas medidas, este modelo tiene un ajuste aceptable, pero se puede mejorar probando otros modelos que optimicen las medidas de AIC y BIC.

4 Conclusiones y Selección del Modelo

El modelo preliminar parece explicar bien la variabilidad del peso, con un R^2 razonable y estimadores significativos. Para mejorar el modelo, podemos considerar variables adicionales o la eliminación de aquellas que no resulten significativas en otros ensayos.

Además, el uso de AIC y BIC será clave para la selección del mejor modelo en función de los diferentes criterios de ajuste que hemos estudiado.

3 Referencias

- Diapositivas de clase.

